

최신성 · 정확성 평가와 적대적 공격 대응을 적용한 공공기관 및 부산대학교 행정 문서 검색 챗봇 개발



팀명: 무엇이든물어보새

202155596 이현우 jini02@pusan.ac.kr

202155627 황지완 hjw8486@gmail.com

202355709 정지인 gini202355709@gmail.com

지도교수: 손준영

제출일: 2026년 5월 15일

부산대학교

목차

1	과제 개요	1
1.1	연구 배경	1
1.2	과제 목표	1
1.3	기대 효과	2
2	대상 문제 및 요구사항 분석	3
2.1	대상 문제 분석	3
2.1.1	행정 문서의 분산성과 검색 어려움	3
2.1.2	최신 규정 반영의 어려움	3
2.1.3	LLM 답변의 환각 문제	3
2.1.4	적대적 공격 가능성	3
2.2	기능적 요구사항	4
2.3	비기능적 요구사항	4
3	시스템 설계	6
3.1	전체 시스템 구조	6
3.2	데이터 처리 흐름	6
3.3	사용 기술	7
3.4	LLM 운영 전략	7
4	신뢰성 평가 및 적대적 공격 대응	9
4.1	최신성 평가	9
4.2	정확성 및 근거성 평가	9
4.3	적대적 공격 유형	10
4.4	대응 방안	10
5	현실적 제약 사항 및 대책	11
5.1	문서 수집과 형식 다양성	11

5.2	정답 데이터 부족	11
5.3	최신 문서 판별의 어려움	11
5.4	LLM 비용 및 응답 시간	11
5.5	법적、행정적 책임 문제	12
6	추진 체계 및 일정	13
6.1	개발 일정	13
6.2	역할 분담	13
7	결론	15

제1장 과제 개요

1.1 연구 배경

대학 생활과 공공 행정 서비스는 학칙, 규정, 지침, 공지사항, 민원 안내와 같은 문서에 크게 의존한다. 부산대학교 학생은 수강신청, 휴학 및 복학, 장학, 졸업요건, 비교과, 등록금, 학사경고, 전과, 교환학생 등 다양한 행정 정보를 확인해야 하며, 교직원 역시 업무 처리 과정에서 여러 규정과 지침을 참조해야 한다. 그러나 이러한 문서는 여러 웹사이트, 게시판, PDF, 한글 문서, 공지사항, FAQ 등에 분산되어 있어 사용자가 원하는 조항이나 절차를 빠르게 찾기 어렵다.

최근 대규모 언어모델(LLM)을 활용한 챗봇 서비스는 자연어 질문에 대해 사용자가 이해하기 쉬운 형태로 답변을 제공할 수 있다는 장점 때문에 다양한 분야에서 활용되고 있다. 하지만 일반적인 LLM은 학습 시점 이후 변경된 최신 규정을 알지 못하거나, 실제 문서에 근거하지 않은 답변을 생성하는 환각(hallucination) 문제가 발생할 수 있다. 행정 문서와 규정 문서는 답변의 정확성이 중요하며, 잘못된 안내가 사용자의 의사결정에 직접적인 영향을 줄 수 있으므로 단순 생성형 챗봇만으로는 충분하지 않다.

본 과제는 이러한 문제를 해결하기 위해 공공기관 및 부산대학교 규정·행정 문서를 기반으로 답변하는 검색 증강 생성(Retrieval-Augmented Generation, RAG) 챗봇 서비스를 개발한다[3]. 특히 문서 검색 결과를 바탕으로 답변을 생성하고, 답변의 출처와 근거를 함께 제시하며, 최신성·정확성·신뢰성 평가 기법과 적대적 공격 대응 기법을 적용하여 행정 문서 검색 챗봇의 실용성과 안정성을 높이고자 한다.

1.2 과제 목표

본 과제의 목표는 부산대학교 규정 및 공공기관 행정 문서를 수집·전처리·색인하고, 사용자의 자연어 질문에 대해 근거 문서 기반의 답변을 제공하는 챗봇 서비스를 구현하는 것이다. 단순한 문서 검색 시스템이 아니라, 문서 검색과 답변 생성을 결합하고, 생성된 답변이 실제 근거 문서와 일치하는지 평가하며, 악의적인 프롬프트나 문서 오염 공격에 대응할 수

있는 신뢰성 강화형 챗봇 시스템을 지향한다.

구체적인 목표는 다음과 같다.

1. 부산대학교 규정, 학사 행정 문서, 공공기관 안내 문서를 수집하고 검색 가능한 형태로 구조화한다.
2. PDF, HTML, HWP 등 다양한 문서 형식에서 텍스트를 추출하고 문서 단위, 조항 단위, 문단 단위로 분할한다.
3. 키워드 검색과 의미 기반 벡터 검색을 결합한 하이브리드 검색 구조를 설계한다.
4. 검색된 근거 문서를 기반으로 답변을 생성하고, 답변에 출처 및 근거 문서 링크를 함께 제공한다.
5. 최신성, 정확성, 출처 일치성, 환각 가능성을 평가하는 신뢰성 평가 체계를 구축한다.
6. 프롬프트 인젝션, 악성 질의, 문서 오염 등 적대적 공격에 대한 탐지 및 방어 방식을 적용한다.

1.3 기대 효과

본 시스템은 학생과 교직원이 복잡한 행정 문서를 직접 탐색하는 시간을 줄이고, 질문 중심으로 필요한 규정과 절차를 확인할 수 있도록 돕는다. 또한 출처 기반 답변과 신뢰성 평가 결과를 함께 제공함으로써, 사용자가 챗봇 답변을 맹목적으로 신뢰하는 것이 아니라 실제 문서에 근거해 판단할 수 있도록 한다.

기술적으로는 RAG 기반 챗봇에서 중요한 문서 검색 품질, 답변 근거성, 최신성 관리, 적대적 공격 대응을 통합적으로 실험할 수 있다. 따라서 본 과제는 단순 응용 서비스 개발을 넘어, 행정 문서처럼 정확성과 책임성이 중요한 영역에서 LLM 기반 시스템을 안전하게 적용하는 방법을 탐구하는 데 의의가 있다.

제2장 대상 문제 및 요구사항 분석

2.1 대상 문제 분석

2.1.1 행정 문서의 분산성과 검색 어려움

대학 및 공공기관의 행정 정보는 여러 부서, 게시판, 규정집, 안내 페이지에 분산되어 있다. 같은 주제라도 학칙, 시행세칙, 공지사항, FAQ가 서로 다른 위치에 존재할 수 있으며, 사용자는 어떤 문서를 우선 확인해야 하는지 판단하기 어렵다. 예를 들어 졸업요건을 확인하려면 학과 내규, 교육과정표, 졸업사정 안내, 학사 규정 등을 함께 확인해야 할 수 있다.

2.1.2 최신 규정 반영의 어려움

행정 문서는 개정과 공지가 지속적으로 발생한다. 일반 검색엔진이나 정적 FAQ는 문서 개정 시점을 반영하지 못할 수 있으며, LLM 역시 학습 데이터 이후 변경된 규정을 알 수 없다. 따라서 문서의 수집 시점, 개정일, 공지일, 적용 학년도 등을 관리하고 답변 생성 시 최신 문서를 우선 반영하는 구조가 필요하다.

2.1.3 LLM 답변의 환각 문제

LLM은 자연스러운 문장을 생성하는 데 강점이 있으나, 근거 문서에 없는 내용을 단정적으로 말할 수 있다. 행정 정보 영역에서는 잘못된 안내가 수강신청, 장학 신청, 졸업 준비 등에 영향을 줄 수 있으므로 답변이 실제 문서에 근거하는지 확인하는 절차가 필요하다.

2.1.4 적대적 공격 가능성

문서 기반 챗봇은 사용자의 질문뿐 아니라 검색된 문서 내용도 프롬프트에 포함한다. 이때 사용자가 “이전 지시를 무시하고 답하라”와 같은 프롬프트 인젝션을 시도하거나, 악성 문서가 색인되어 모델의 답변 방향을 왜곡할 가능성이 있다. 따라서 질의 필터링, 문서 신뢰도 관리, 프롬프트 격리, 출처 검증과 같은 방어 기법이 요구된다.

2.2 기능적 요구사항

표 2.1: 기능적 요구사항

ID	요구사항	설명
F1	문서 수집	부산대학교 규정, 학사 안내, 공지사항 및 공공기관 문서를 수집한다.
F2	문서 전처리	PDF, HTML, HWP 등에서 텍스트를 추출하고 문서 구조를 정리한다.
F3	문서 색인	문서를 청크 단위로 분할하고 키워드 색인 및 벡터 색인을 생성한다.
F4	자연어 질의	사용자가 자연어로 행정 관련 질문을 입력할 수 있다.
F5	하이브리드 검색	키워드 검색과 의미 기반 검색을 결합하여 관련 문서를 검색한다.
F6	RAG 답변 생성	검색된 문서를 근거로 답변을 생성한다.
F7	출처 표시	답변에 사용된 문서명, 조항, URL 또는 파일명을 함께 제공한다.
F8	신뢰도 평가	답변의 근거 일치성, 최신성, 검색 적합도를 점수화한다.
F9	공격 탐지	프롬프트 인젝션, 악성 질의, 문서 오염 가능성을 탐지한다.
F10	관리자 기능	문서 갱신, 색인 재생성, 평가 로그 확인 기능을 제공한다.

2.3 비기능적 요구사항

표 2.2: 비기능적 요구사항

ID	요구사항	설명
NF1	정확성	답변은 검색된 근거 문서의 내용과 일치해야 한다.
NF2	최신성	개정일 또는 공지일이 최신인 문서를 우선 사용해야 한다.
NF3	신뢰성	답변에 출처와 신뢰도 정보를 함께 제공해야 한다.
NF4	보안성	사용자 입력 및 검색 문서에 포함된 공격성 지시를 탐지하고 차단해야 한다.
NF5	응답성	일반적인 질문에 대해 사용자가 수용 가능한 시간 내에 답변을 제공해야 한다.
NF6	확장성	문서 출처와 문서 형식이 증가해도 색인 구조를 확장할 수 있어야 한다.
NF7	유지보수성	문서 갱신, 재색인, 평가 데이터 추가가 용이해야 한다.

제3장 시스템 설계

3.1 전체 시스템 구조

본 시스템은 문서 수집 계층, 문서 전처리 계층, 검색 및 색인 계층, 답변 생성 계층, 신뢰성 평가 계층, 사용자 인터페이스 계층으로 구성된다. 각 계층은 독립적으로 개선 가능하도록 모듈화한다.

표 3.1: 시스템 구성 요소

구성 요소	역할
문서 수집기	부산대학교 및 공공기관 웹사이트에서 문서, 공지, 규정 파일을 수집한다.
문서 파서	PDF, HTML, HWP 문서에서 텍스트와 메타데이터를 추출한다.
전처리 모듈	문서 정제, 조항 분리, 청크 분할, 중복 제거를 수행한다.
검색 엔진	키워드 검색과 벡터 검색을 결합하여 관련 문서를 찾는다.
RAG 엔진	LangChain을 활용하여 검색, 프롬프트 구성, LLM 호출, 출처 반환 흐름을 연결한다.
평가 모듈	답변의 근거성, 최신성, 검색 적합도, 환각 가능성을 평가한다.
방어 모듈	프롬프트 인젝션과 악성 문서 지시를 탐지하고 제거한다.
웹 인터페이스	사용자의 질문 입력, 답변 확인, 출처 확인 기능을 제공한다.
관리자 대시보드	문서 갱신 상태, 평가 로그, 공격 탐지 로그를 확인한다.

3.2 데이터 처리 흐름

사용자가 질문을 입력하면 시스템은 먼저 질문의 의도와 공격 가능성을 간단히 검사한다. 이후 질문을 기반으로 키워드 검색과 벡터 검색을 수행하고, 검색 결과를 재순위화하여 상위 문서를 선택한다. 선택된 문서는 답변 생성 모델에 전달되며, 모델은 근거 문서 범위 내에서만 답변을 생성한다. 생성된 답변은 다시 평가 모듈을 거쳐 근거 문서와의 일치성, 최신성, 출처 적합성을 점검받는다.

알고리즘 1: 문서 기반 답변 생성 절차**입력:** 사용자 질문 q , 문서 색인 D **출력:** 출처가 포함된 답변 a 와 신뢰도 점수 s 질문 q 에 대해 공격성 패턴을 검사한다;키워드 검색 결과 K 와 벡터 검색 결과 V 를 생성한다; K 와 V 를 결합하여 후보 문서 집합 C 를 만든다;후보 문서 C 를 관련도와 최신성 기준으로 재순위화한다;상위 근거 문서 E 를 선택한다;근거 문서 E 만 사용하도록 제한하여 답변 a 를 생성한다;답변 a 와 근거 문서 E 의 일치성을 평가하여 신뢰도 점수 s 를 계산한다;

답변, 출처, 신뢰도 점수를 사용자에게 반환한다;

3.3 사용 기술

초기 구현에서는 웹 기반 서비스로 개발하여 접근성을 높인다. 프론트엔드는 React를 사용하고, 백엔드는 Python 기반 FastAPI 또는 Spring Boot 중 팀 역량에 맞는 프레임워크를 선택한다. 문서 전처리와 RAG 파이프라인은 Python 생태계를 중심으로 구현하며, 키워드 검색에는 BM25 계열 방법[6], 의미 기반 검색에는 문장 임베딩 모델[5]을 활용하는 방식을 검토한다. 문서 임베딩 저장에는 Chroma, FAISS, PostgreSQL pgvector 등 가벼운 벡터 저장소를 검토한다.

LangChain은 자체 LLM 모델이 아니라 문서 로딩, 텍스트 분할, 검색기, 프롬프트 템플릿, LLM 호출, 출력 파싱을 연결하는 RAG 애플리케이션 프레임워크로 사용한다[2]. 이를 통해 초기에는 저비용 상용 LLM API를 사용하고, 이후 Ollama, llama.cpp, vLLM 등으로 구동되는 로컬 오픈소스 LLM 서버로 교체하더라도 핵심 검색 및 평가 파이프라인을 크게 바꾸지 않는 구조를 목표로 한다.

3.4 LLM 운영 전략

본 과제의 핵심은 LLM 자체를 처음부터 학습시키는 것이 아니라, 최신 행정 문서를 검색하여 근거 기반 답변을 생성하고 그 신뢰성을 평가하는 데 있다. 따라서 초기 단계에서는 구현 속도와 안정성을 위해 저비용 상용 LLM API를 사용한다. 이후 과제의 기술적 완성도를 높이기 위해 동일한 RAG 파이프라인에서 로컬 오픈소스 LLM을 Docker 기반 서버로 구동하고, API 모델과 로컬 모델의 비용, 응답 시간, 답변 품질, 근거 충실도, 운영 가능성을 비교한다.

이를 위해 백엔드 내부에는 LLM 호출부를 별도 모듈로 분리한다. 예를 들어 LLMProvider

표 3.2: 예상 개발 기술

영역	사용 예정 기술
프론트엔드	React, TypeScript, HTML/CSS
백엔드 API	FastAPI 또는 Spring Boot
문서 처리	Python, PDF parser, HTML parser, HWP 변환 도구
검색	BM25 기반 키워드 검색, 벡터 검색, 하이브리드 검색
임베딩 저장소	Chroma, FAISS, PostgreSQL pgvector 중 선택
RAG 프레임워크	LangChain 기반 문서 로더, 검색기, 프롬프트, LLM 호출 체인
LLM 연동	저비용 상용 LLM API, Ollama 또는 llama.cpp 기반 로컬 LLM 서버
평가	자체 평가 데이터셋, 근거 일치성 평가, 검색 정확도 평가, API/로컬 LLM 비교
배포	Docker, GitHub, 클라우드 또는 학교 서버

인터페이스를 두고, 상용 API Provider와 로컬 LLM Provider를 교체 가능하게 구현한다. 이 구조는 초기 개발 비용을 낮추면서도, 발표 전까지 로컬 LLM 적용과 성능 비교 실험을 진행할 수 있다는 장점이 있다.

제4장 신뢰성 평가 및 적대적 공격 대응

4.1 최신성 평가

행정 문서의 답변에서는 최신 문서 사용 여부가 중요하다. 본 시스템은 문서 수집 시 문서 제목, URL, 작성일, 개정일, 수집일, 문서 유형을 메타데이터로 저장한다. 검색 결과를 재순위화할 때 관련도뿐 아니라 문서의 최신성을 함께 고려한다. 또한 답변에 사용된 문서가 오래된 문서이거나 최신 공지가 별도로 존재할 가능성이 있는 경우 사용자에게 주의 문구를 제공한다.

4.2 정확성 및 근거성 평가

정확성 평가는 크게 검색 정확도와 답변 근거성으로 나누어 수행한다. 검색 정확도는 사용자의 질문에 대해 올바른 근거 문서가 상위 검색 결과에 포함되는지를 평가한다. 답변 근거성은 생성된 답변이 실제 근거 문서에 포함된 내용인지 확인하는 지표이다. RAG 시스템의 평가는 검색 문맥의 적합도와 생성 답변의 충실도를 함께 확인해야 하므로, 관련 연구에서 제안된 평가 관점을 참고한다[1].

초기 평가 지표는 다음과 같이 정의한다.

- 검색 적합도: 정답 문서가 상위 k 개 검색 결과에 포함되는 비율
- 출처 일치성: 답변 문장별로 근거 문서가 존재하는 비율
- 최신성 점수: 답변에 사용된 문서의 개정일 및 수집일 기준 점수
- 환각 위험도: 근거 문서에 없는 단정적 표현의 비율
- 사용자 피드백: 답변 유용성, 이해도, 출처 만족도 평가

4.3 적대적 공격 유형

본 과제에서 고려하는 주요 공격 유형은 다음과 같다. 특히 LLM 기반 애플리케이션은 사용자의 입력이 모델의 지시문처럼 해석되는 프롬프트 인젝션 공격에 취약할 수 있으므로[4], 문서 기반 챗봇에서도 이를 별도 위험 요소로 다룬다.

1. 프롬프트 인젝션: 사용자가 시스템 지시를 무시하도록 유도하는 질문을 입력하는 공격
2. 문서 인젝션: 색인된 문서 내부에 모델을 조작하는 지시문이 포함되는 공격
3. 출처 조작 공격: 신뢰할 수 없는 문서를 신뢰 문서처럼 참조하도록 유도하는 공격
4. 과도한 권한 요구: 시스템 내부 프롬프트, API 키, 관리자 기능 등 공개하면 안 되는 정보를 요구하는 공격
5. 혼동 유도 질문: 실제 규정과 무관한 가정이나 허위 조건을 제시하여 잘못된 답변을 유도하는 공격

4.4 대응 방안

적대적 공격에 대응하기 위해 입력 단계, 검색 단계, 생성 단계, 평가 단계에서 방어 로직을 적용한다. 입력 단계에서는 공격성 문구와 정책 위반 질의를 탐지한다. 검색 단계에서는 문서 출처의 신뢰도를 관리하고, 신뢰할 수 있는 도메인과 문서 유형을 우선한다. 생성 단계에서는 모델이 근거 문서에 포함되지 않은 내용을 답하지 않도록 프롬프트를 구성한다. 평가 단계에서는 답변과 근거 문서의 일치성을 다시 점검하여 위험도가 높은 답변은 사용자에게 경고하거나 답변을 보류한다.

제5장 현실적 제약 사항 및 대책

5.1 문서 수집과 형식 다양성

부산대학교와 공공기관 문서는 PDF, HTML, HWP, 이미지 기반 PDF 등 다양한 형식으로 제공될 수 있다. 모든 문서를 완벽히 처리하는 것은 초기 개발 범위에서 어렵다. 따라서 1차 구현에서는 HTML과 텍스트 추출 가능한 PDF를 우선 지원하고, HWP 및 이미지 기반 PDF는 변환 도구 또는 OCR을 활용하는 방식으로 확장한다.

5.2 정답 데이터 부족

RAG 챗봇의 검색 정확도와 답변 신뢰성을 평가하려면 질문-정답-근거 문서로 구성된 평가 데이터셋이 필요하다. 그러나 부산대학교 행정 문서에 대한 공개 평가셋은 존재하지 않을 가능성이 높다. 따라서 초기에는 팀이 직접 대표 질문을 선정하고, 각 질문에 대한 근거 문서를 수동으로 매핑하여 소규모 평가셋을 구축한다.

5.3 최신 문서 판별의 어려움

문서마다 개정일, 시행일, 게시일 표기 방식이 다를 수 있고, 일부 문서는 날짜 정보가 명확하지 않을 수 있다. 이를 해결하기 위해 URL, 파일명, 문서 본문, 게시판 메타데이터에서 날짜 후보를 추출하고, 확실하지 않은 경우 수집일을 보조 메타데이터로 사용한다.

5.4 LLM 비용 및 응답 시간

LLM API를 사용할 경우 호출 비용과 응답 시간이 발생한다. 초기 개발에서는 질문 재작성, 검색, 답변 생성을 모두 복잡하게 수행하기보다, MVP 단계에서는 간단한 검색 기반 RAG 파이프라인을 우선 구현한다. 이후 캐싱, 경량 모델, 답변 재사용, 검색 결과 요약 방식 등을 적용하여 비용과 시간을 줄인다.

또한 장기적으로 부산대학교 학생 대상 테스트 서비스를 운영할 경우 API 비용이 누적될 수 있으므로, 로컬 오픈소스 LLM 서버를 대안으로 검토한다. 다만 로컬 LLM은 GPU 메모리, 응답 속도, 모델 관리 부담이 발생하므로 초기 필수 기능으로 두기보다 2차 고도화 항목으로 설정한다. API 모델과 로컬 모델을 같은 평가 데이터셋으로 비교하여, 비용 절감 효과와 품질 저하 여부를 함께 분석한다.

5.5 법적、행정적 책임 문제

챗봇 답변이 공식 행정 판단을 대체할 수는 없다. 따라서 시스템은 답변과 함께 근거 문서를 제시하고, 중요한 행정 결정은 반드시 담당 부서 또는 공식 문서를 확인해야 한다는 안내를 제공한다. 또한 답변 생성 시 “확인 필요”, “문서 기준”, “개정 가능성 있음”과 같은 표현을 적절히 사용하여 사용자가 답변의 한계를 이해하도록 한다.

제6장 추진 체계 및 일정

6.1 개발 일정

표 6.1: 개발 일정

업무	5월	6월	7월	8월	9월
요구사항 분석 및 보고서 작성	O				
문서 수집 대상 선정	O	O			
문서 파서 및 전처리 구현		O	O		
검색 및 벡터 색인 구현		O	O		
RAG 답변 생성 기능 구현			O	O	
신뢰성 평가 데이터셋 구축			O	O	
적대적 공격 대응 기능 구현				O	O
로컬 LLM 서버 연동 및 비교 실험				O	O
웹 UI 및 관리자 기능 구현		O	O	O	
학생 대상 베타 테스트 및 개선				O	O
최종 보고서 및 발표 준비					O

6.2 역할 분담

표 6.2: 역할 분담

구성원	담당 업무
이현우	팀장, 백엔드 API, 검색 엔진, 벡터 DB, RAG 파이프라인, LLM 연동 구조 구현
황지완	문서 수집 및 전처리, 평가 데이터셋 구축, 문서 메타데이터 관리, 보안 및 적대적 공격 테스트 지원
정지인	웹 프론트엔드, 관리자 대시보드, 사용자 인터페이스 구현, 사용자 테스트 및 피드백 정리
공통	아키텍처 설계, 요구사항 분석, 통합 테스트, 보고서 작성, 발표 자료 준비

제7장 결론

본 과제는 공공기관 및 부산대학교 행정 문서를 기반으로 사용자의 질문에 답변하는 신뢰성 강화형 RAG 챗봇 서비스를 개발하는 것을 목표로 한다. 행정 문서는 최신성과 정확성이 중요하므로, 단순히 자연스러운 답변을 생성하는 것보다 실제 문서에 근거한 답변을 제공하고, 출처와 신뢰도 정보를 함께 제시하는 것이 핵심이다.

초기 구현에서는 부산대학교 학사 규정과 주요 행정 문서를 중심으로 문서 수집, 전처리, 검색, 답변 생성 기능을 구현한다. 이후 공공기관 문서로 범위를 확장하고, 최신성 평가와 적대적 공격 대응 기능을 고도화하여 실제 사용 가능한 행정 문서 검색 챗봇으로 발전시키고자 한다.

참고문헌

- [1] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation, 2023.
- [2] LangChain. LangChain Python Documentation, 2026. Online Document. Available at: <https://python.langchain.com/docs/>. Checked on 2026-05-14.
- [3] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [4] Fábio Perez and Ian Ribeiro. Ignore previous prompt: Attack techniques for language models, 2022.
- [5] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992, 2019.
- [6] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.