



졸업과제 중간보고서

최신성 · 정확성 평가와 적대적 공격 대응을 적용한 공공기관 및 부산대학교 행정 문서 검색 챗봇 개발

무엇이든 물어보세

202155596 이현우

202155627 황지완

202355709 정지인

지도교수 손준영

2026년 7월 16일

부산대학교

목차

중간 요약	v
1 과제 개요 및 착수 대비 변화	1
1.1 연구 배경	1
1.2 중간 단계의 개발 목표	1
1.3 착수 계획 대비 주요 변경	2
2 요구사항과 구현 범위	3
2.1 기능 요구사항 이행 현황	3
2.2 비기능 요구사항 이행 현황	4
2.3 현재 MVP의 명시적 범위	5
3 시스템 설계와 구현	6
3.1 전체 아키텍처	6
3.2 병렬 프로토타입 비교 전략	6
3.3 문서 수집과 중복 관리	7
3.4 다형식 파싱과 청킹	7
3.5 BM25 검색 인덱스	8
3.6 하이브리드、리랭킹、Ollama 실험 프로토타입	8
3.7 RAG API와 근거 부착	9
3.8 사용자 인터페이스	10
3.9 기본 API 보호	11
4 구현 결과와 개발 진척	12
4.1 코퍼스 및 파싱 결과	12
4.2 개발 타임라인	13
4.3 자동 검증 결과	13

5	예비 평가	15
5.1	평가 범위	15
5.2	BM25 검색 지연시간	15
5.3	질적 동작 확인	16
5.4	병렬 프로토타입의 답변 품질 점검	16
5.5	현재 평가의 한계	19
6	발견된 문제와 대응 계획	20
6.1	파싱 품질	20
6.2	최신성	20
6.3	검색과 근거성	20
6.4	적대적 공격 대응	21
6.5	운영과 재현성	21
7	향후 일정과 추진 체계	23
7.1	향후 개발 일정	23
7.2	정량 평가 계획	23
7.3	역할 분담	24
8	결론	25
A	재현과 근거 파일	26
A.1	주요 실행 명령	26
A.2	내부 검증 근거	26

그림 목차

3.1	현재 저장소에 통합된 공문서 RAG 기준선의 종단 간 구조	6
3.2	부산대학교 범위를 선택한 실제 질의, 인용 답변 및 claim 근거 패널. 화면 캡처는 외부 API 키 없이 추출형 fallback 모드로 수행하였다.	11
4.1	기관별 파싱 문서 수와 전체 파일 처리 결과	12
5.1	별도 로컬 프로토타입의 차량 등록 질의. 정밀 재정렬과 근거 3개를 설정하고 Ollama 연결 상태에서 구조화된 인용 답변을 생성한 사례	17
5.2	모호한 연구자 등록 질의에서 서로 다른 규정을 혼합한 실패 사례. 질의 명확 화와 재정렬 효과 검증이 필요함을 보여준다	18

표 목 차

1.1	착수 계획 대비 중간 시점의 설계 결정	2
2.1	기능 요구사항 이행 현황	3
2.2	비기능 요구사항 이행 현황	4
3.1	팀 단위 병렬 개발 경로와 통합 조건	7
3.2	지원 문서 형식과 파서	8
3.3	현재 구현된 API 엔드포인트	9
4.1	전체 파일 처리 결과	13
4.2	Git 이력 기반 주요 개발 진척	13
4.3	현재 코드 자동 검증 결과	14
5.1	BM25 검색 지연시간 예비 측정	15
5.2	별도 로컬 프로토타입의 질적 답변 점검	16
6.1	핵심 위험과 완료 판정 기준	22
7.1	2026년 7월 이후 상세 일정	23
7.2	후속 정량 평가 지표와 잠정 목표	24
7.3	팀 역할 분담	24

중간 요약

본 과제는 부산대학교와 공공기관의 행정 문서를 수집하고, 검색된 원문 근거에 기반하여 답변과 출처를 함께 제공하는 RAG(Retrieval-Augmented Generation) 챗봇을 개발하는 것을 목표로 한다. 착수 단계에서는 최신성, 정확성 및 근거성, 적대적 공격 대응을 핵심 차별점으로 제시하였다.

중간 시점인 2026년 7월 16일 기준으로 7개 기관의 원문 파일 2,947개를 정리하였고, PDF, HWP, HWPX, Excel, PPTX 등 다형식 문서 파서를 구현하였다. 로컬 파이프라인 실행 결과 2,725개 문서를 파싱하여 42,744개 청크를 생성하였으며, 파싱 성공률은 전체 파일 대비 92.5%이다. 부산대학교 문서 389개는 모두 파싱되었다. 검색 단계는 한글 2-gram을 보강한 SQLite FTS5 기반 BM25 인덱스로 구현하였고, 인덱스에는 7개 기관의 42,744개 청크가 포함된다.

현재 저장소에 통합된 기준선의 질의 처리 흐름은 기관 필터, BM25 검색, Gemini API 또는 추출형 fallback을 이용한 답변 생성, 문장 단위 어휘 정합성 검사, 서버 측 출처 번호 부착, React UI의 검증, 문서, 위치 패널로 연결된다. Python 자동 테스트 7개, ESLint, TypeScript 검사, Vite 프로덕션 빌드는 모두 통과하였다.

한편 팀은 동일한 행정문서 질의에 대해 검색, 생성 조합을 비교하기 위해 키워드 검색과 의미 기반 검색, 정밀 재정렬, Ollama 기반 생성을 결합한 별도 로컬 프로토타입을 병렬로 개발하였다. 화면 시험에서는 근거 수 3개, 정밀 재정렬 활성화, Ollama 연결 상태와 인용 답변을 확인하였다. 다만 해당 프로토타입은 아직 현재 저장소에 통합되지 않았으므로, 본 보고서에서는 개인별 개발 진척이 아니라 “통합 기준선”과 “비교 실험군”이라는 팀 단위의 공통 개발 흐름으로 구분한다.

통합 기준선에는 최신 문서 판정과 재순위화, 의미 기반 근거성 평가, 프롬프트 및 문서 인젝션 탐지, 관리자 기능이 아직 구현되지 않았다. 하이브리드 검색, 리랭킹, 로컬 LLM은 실험 프로토타입까지 진행되었으나 공통 코드 통합과 정량 비교가 남아 있다. 따라서 본 보고서는 코드로 검증된 기준선과 화면으로 확인한 실험군의 증거 수준을 분리하고, 착수 목표와의 차이를 후속 일정과 평가 계획으로 연결한다.

제1장 과제 개요 및 착수 대비 변화

1.1 연구 배경

대학과 공공기관의 행정 문서는 규정, 지침, 공지, 서식, 보도자료 등 다양한 형식과 위치로 분산되어 있다. 사용자는 필요한 정보를 찾기 위해 여러 게시판과 첨부 문서를 반복해서 확인해야 하며, 같은 주제를 다룬 구버전과 신버전 문서가 함께 존재할 경우 실제 적용 규정을 판단하기 어렵다.

일반적인 LLM 챗봇은 자연스러운 답변을 제공하지만, 학습 시점 이후의 개정 내용을 반영하지 못하거나 원문에 없는 내용을 생성할 수 있다. 이에 본 과제는 검색 증강 생성 구조를 적용하여 답변의 근거 문서를 명시하고, 향후 문서 최신성과 적대적 입력에 대한 방어 기능을 결합하는 것을 목표로 한다[2, 3].

1.2 중간 단계의 개발 목표

중간 단계에서는 최종 기능을 모두 구현하는 것보다 실제 데이터를 대상으로 다음 중단 간 흐름을 먼저 연결하는 것을 우선하였다.

1. 여러 기관의 실제 문서를 수집하고 파싱 가능한 코퍼스로 정리한다.
2. 다양한 파일 형식을 동일한 문서, 청크 구조로 변환한다.
3. 로컬 검색 인덱스에서 기관별 근거 후보를 검색한다.
4. 검색된 근거만을 사용하여 답변을 생성하고 출처 번호를 부착한다.
5. 사용자가 답변 문장, 근거 문서, 원문 위치를 확인할 수 있는 UI를 제공한다.
6. API 입력, 응답 경계를 자동 테스트하여 기본적인 안전성을 확보한다.
7. 동일 질의, 평가셋에서 키워드, 의미 기반, 하이브리드, 재정렬 검색과 생성 모델 조합을 병렬 비교한다.

1.3 착수 계획 대비 주요 변경

표 1.1: 착수 계획 대비 중간 시점의 설계 결정

항목	착수 단계 계획	중간 시점 결정 및 근거	상태
백엔드	FastAPI 또는 Spring Boot 검토	파싱, 검색 모듈과 빠르게 통합하기 위해 Python 표준 라이브러리 기반 HTTP 서버로 MVP 구현	구현
검색	BM25와 벡터 검색을 결합한 하이브리드 검색	통합 기준선은 SQLite FTS5 BM25로 구현. 별도 프로토타입에서 키워드, 의미 기반 검색과 정밀 재정렬을 시험했으며 공통 저장소 통합과 비교 평가가 남음	부분 구현
LLM	상용 API와 로컬 LLM 비교	통합 기준선은 Gemini API와 추출형 fallback을 사용. 별도 프로토타입은 Ollama 연결을 확인했으며 모델 설정, 지연시간, 품질 비교가 남음	부분 구현
대상 데이터	부산대학교 및 공공기관 문서	부산대학교 포함 7개 기관 2,947개 파일 확보	구현
정확성	근거 기반 답변과 출처 제공	생성 문장을 원문과 어휘적으로 대조하고, 지지되는 문장에 서버가 출처 번호를 부착	부분 구현
최신성	개정일, 수집일 기반 재순위화	수집 시각과 파일 수정 시각 일부 저장. 버전 계보와 최신성 재순위화는 미구현	후속 구현
공격 대응	프롬프트, 문서 인젝션 탐지	CORS, 선택적 토큰, 입력 제한, 문서 내부 지시 무시 프롬프트까지 구현. 탐지기와 공격 평가는 후속	부분 구현
관리자	문서, 로그, 평가 관리 화면	핵심 검색과 답변 UI를 우선하여 관리자 기능은 후속 범위로 조정	후속 구현

제2장 요구사항과 구현 범위

2.1 기능 요구사항 이행 현황

착수보고서의 기능 요구사항을 코드와 실행 산출물에 대조하였다. “구현”은 실제 코드와 동작 증거가 있는 항목, “부분 구현”은 핵심 흐름 중 일부만 구현된 항목, “후속 구현”은 현재 코드에서 확인되지 않는 항목을 의미한다.

표 2.1: 기능 요구사항 이행 현황

ID	요구사항	상태	현재 구현 근거
F1	문서 수집	구현	7개 기관 2,947개 원문, 금융기관용 시드 기반 크롤러와 수집 매니페스트
F2	다형식 문서 처리	구현	PDF, HWP, HWPX, DOCX, XLSX, XLS, PPTX 파서와 문단 기반 청킹
F3	문서 갱신	부분 구현	수집 시각, 파일 수정 시각 저장. 주기 실행, 동일 URL 변경 감지, 자동 재색인은 없음
F4	자연어 질의	구현	React 입력 UI와 /chat API 연결, 기관 필터 지원
F5	하이브리드 검색	부분 구현	통합 기준선은 한글 2-gram 기반 BM25. 별도 로컬 프로토타입에서 키워드, 의미 기반 검색과 정밀 재정렬 옵션을 시험했으며 통합, 정량 평가는 진행 중
F6	RAG 답변 생성	구현	기준선의 Gemini, 추출형 fallback과 별도 프로토타입의 Ollama 연결 및 근거 기반 답변 화면 확인

ID	요구사항	상태	현재 구현 근거
F7	출처 표시	구현	답변 내 출처 배지, claim 별 근거, 검색 문서와 원문 위치 패널
F8	신뢰도 평가	부분 구현	문장-원문 어휘 정합성 휴리스틱 구현. 정답셋 기반 평가와 보정된 신뢰도는 없음
F9	공격 탐지	부분 구현	API hardening과 문서 내부 지시 무시 규칙 구현. 공격 탐지, 분류, 평가셋은 없음
F10	관리자 기능	후속 구현	업로드, 재파싱, 재색인, 로그, 평가 관리 기능 없음

2.2 비기능 요구사항 이행 현황

표 2.2: 비기능 요구사항 이행 현황

영역	상태	판단 근거
정확성	부분 구현	검색 근거 제한과 어휘 정합성 필터는 있으나 Recall@k, MRR, citation precision, faithfulness 측정은 없음
최신성	후속 구현	최신 버전 선택과 stale 문서 제외가 검색에 반영되지 않음
신뢰성	부분 구현	지지 claim과 출처를 표시하나 의미적 사실 검증은 아님
보안성	부분 구현	CORS, 선택적 API 토큰, 크기, 길이 제한과 내부 원문 비공개 구현
응답성	부분 구현	BM25 예비 측정 완료. Gemini 포함 종단 간 지연시간 측정은 미완료
추적성	구현	기관, 파일명, 상대 경로, chunk 번호, 검색 점수를 UI에서 확인 가능
유지보수성	부분 구현	수집, 파싱, 검색 스크립트가 분리되어 있으나 통합 파이프라인과 배포 자동화가 없음

2.3 현재 MVP의 명시적 범위

현재 저장소에 통합된 MVP는 “로컬 원문과 로컬 BM25 검색 인덱스를 사용하고, 외부 Gemini API 또는 로컬 추출형 로직으로 답변을 생성하는 시스템”이다. 이는 현재 저장소 기준으로 로컬 LLM 시스템이 아니다. 별도 로컬 실험군에서는 부산대학교 규정 코퍼스를 대상으로 키워드, 의미 기반 검색, 정밀 재정렬, Ollama 연결과 근거 포함 답변을 시험하였다. 두 경로는 개인별 결과로 구분하지 않고 공통 질의, 평가셋에서 비교한 뒤 하나의 시스템으로 통합한다. 또한 최신성, 공격 대응, 관리자 기능은 최종 목표이지만 현재 구현 완료 범위에 포함하지 않는다.

제3장 시스템 설계와 구현

3.1 전체 아키텍처



그림 3.1: 현재 저장소에 통합된 공문서 RAG 기준선의 종단 간 구조

그림 3.1는 현재 저장소에 통합된 기준선을 나타낸다. 기준선은 원문 수집, 다형식 파싱, 문단 청킹, BM25 검색, RAG API, React UI의 여섯 단계로 구성된다. 단계별 결과를 파일이나 DB로 분리하여 파싱 실패가 검색, UI 코드에 직접 전파되지 않도록 하였다.

3.2 병렬 프로토타입 비교 전략

팀은 각 구현을 개인별 완성도로 나열하지 않고, 공통 데이터와 질의 위에서 검색, 생성 조합을 비교하는 병렬 실험으로 관리한다. 현재 저장소의 기준선은 재현성과 자동 검증을 담당하고, 별도 로컬 프로토타입은 의미 검색, 정밀 재정렬, 로컬 생성 모델의 효과를 빠르게 확인하는 실험군이다.

표 3.1: 팀 단위 병렬 개발 경로와 통합 조건

구분	검색, 생성 흐름	현재 확인된 범위	다음 통합 조건
통합 기준선	BM25 → Gemini 또는 추출형 답변	7개 기관 인덱스, 서버 측 인 용, React UI, 자동 테스트	공통 평가 로그와 비교 인터페이스 유지
비교 실험군	키워드, 의미 후보 검색 → 정밀 재정렬 → Ol-lama 답변	부산대학교 규정 질의 화면, 근거수 3개, 재정렬 옵션, 인 용 답변	소스, 모델 설정 통합, 재정렬 전후 순위와 지연시간 기록
공통 평가	동일 질문과 gold 근거로 조합별 비교	성공, 실패 예시를 이용한 질적 점검 시작	Recall@K, MRR, citation precision, faithfulness 측정

3.3 문서 수집과 중복 관리

금융감독원, 한국은행, 한국거래소, 한국예탁결제원은 기관별 시드 URL과 허용 도메인을 설정한 크롤러로 수집하였다. 크롤러는 robots.txt 확인, 요청 간 지연, 재시도, 응답 크기 제한, URL 정규화, 파일명 정제를 수행한다. 다운로드 결과는 원문 URL, 출처 페이지, SHA-256, 수집 시각과 함께 JSONL 매니페스트에 기록한다.

별도 중복 제거 결과에는 392개 파일이 기록되어 있다. 동일 SHA-256 파일 27개와 동일 제목의 다른 형식 365개를 제거하여 약 162MB의 중복 데이터를 줄였다. 다만 이 중복 제거 CSV를 생성한 독립 실행 스크립트는 현재 저장소에 남아 있지 않아 재현성 보완이 필요하다.

3.4 다형식 파싱과 청킹

파서는 파일 형식별로 다음 방식을 사용한다.

표 3.2: 지원 문서 형식과 파서

형식	주요 도구	처리 방식
PDF	PyMuPDF, pypdf, pdf-plumber	1차 텍스트 추출 후 필요 시 fallback 파서 적용
HWP	olefile	HWP5 OLE 스트림과 압축 레코드에서 텍스트 추출
HWPX	ZIP, XML	section XML의 텍스트 노드를 순서대로 결합
DOCX	python-docx	본문 문단과 표 셀 텍스트 결합
XLSX	openpyxl	시트별 셀 값을 행 단위 텍스트로 변환
XLS	pandas, xlrd	레거시 Excel 시트를 텍스트로 변환
PPTX	ZIP, XML	슬라이드 XML 텍스트 추출

추출된 텍스트는 공백과 제어 문자를 정리한 뒤 문단 경계를 우선하여 최대 1,800자, 중첩 250자를 목표로 청킹한다. 각 문서와 청크에는 안정적인 해시 ID, 기관, 원본 파일명, 상대 경로, 파서, 글자 수가 포함된다. 성공, 빈 문서, 오류, 형식 제외, 대용량 보류 상태를 별도로 기록하여 실패 원인을 추적할 수 있다.

3.5 BM25 검색 인덱스

검색기는 SQLite FTS5와 BM25 순위를 사용한다[5]. 한국어 형태소 분석기 없이도 부분 일치를 높이기 위해 한글 문자열을 원 토큰과 2-gram으로 확장한다. 청크 본문뿐 아니라 기관명, 파일명, 상대 경로도 검색 텍스트에 포함하며, 사용자의 질의는 중복을 제거한 최대 32개 토큰의 OR 조건으로 변환한다.

인덱스의 주요 테이블은 원본 청크 메타데이터를 보관하는 chunks, FTS5 검색용 chunk_fts, 생성 시각과 문서 수를 기록하는 index_meta이다. 현재 인덱스 크기는 674,787,328 bytes이며 기관 필터와 Top-k 제한을 지원한다.

3.6 하이브리드, 리랭킹, Ollama 실험 프로토타입

본 프로젝트의 RAG 설계는 문서 수집, 청킹, 인덱싱, 검색, 생성, 평가의 여섯 단계로 구분한다. 식별자, 정확한 문구에 강한 BM25와 동의어, 자연어 표현에 강한 dense 검색을 상호 보완적인 비교 대상으로 설정하고, 두 결과를 결합한 hybrid 검색도 함께 비교한다.

검색 단계에서는 후보 검색과 정밀 재정렬을 분리하며, Recall@K와 MRR은 검색 성능, faithfulness와 citation precision은 생성, 출처 품질로 각각 측정한다.

이 설계를 참고하여 팀은 부산대학교 규정 코퍼스에 대해 키워드 검색과 의미 기반 검색으로 후보를 만들고, 정밀 재정렬 후 상위 근거를 Ollama 기반 RAG 답변에 사용하는 별도 로컬 프로토타입을 시험하였다. 2026년 7월 15일 화면 기록에서는 문서 분류, 사용할 근거 수 3개, 정밀 재정렬 활성화, API 및 Ollama 정상 상태, 근거 번호가 포함된 답변을 확인하였다.

다만 이 프로토타입의 소스와 실행 설정은 현재 저장소 기준선에 아직 합쳐지지 않았다. 따라서 화면은 병렬 실험이 실제로 진행되었음을 보여주는 증거로 사용하되, dense 인덱스 종류, 검색 점수 결합식, reranker 모델명, Ollama 모델명, 지연시간과 재정렬 전후 순위는 통합 시 별도 로그로 검증한다. RRF는 두 검색기의 점수 척도가 다를 때 순위만으로 결합할 수 있는 비교 기준으로 우선 검토한다.

3.7 RAG API와 근거 부착

API 서버는 Python ThreadingHTTPServer로 구현되며 표 3.3의 네 엔드포인트를 제공한다.

표 3.3: 현재 구현된 API 엔드포인트

메서드, 경로	목적	주요 응답
GET /health	서버와 인덱스 상태	준비 여부, 체크 수, 기관 수, 생성 모드
GET /institutions	기관 목록	인덱스에 포함된 기관명
GET /search	검색 검증	점수, 파일, 경로, chunk, 미리보기
POST /chat	근거 기반 답변	answer, cited answer, claims, 검색 결과

Algorithm 1: 현재 구현된 근거 기반 답변 생성 절차**Input:** 질문 q , 선택 기관 o , 검색 개수 k **Output:** 출처가 부착된 답변, claim 검증 결과, 공개 검색 결과질문의 공백, 길이, 요청 크기와 k 의 범위를 검증한다;기관 필터를 적용하여 BM25 상위 k 개 청크를 검색한다;

검색 근거와 질문으로 Gemini 프롬프트를 구성한다;

Gemini 후보 모델을 순회하고 실패 시 추출형 답변으로 fallback한다;

답변을 최대 5개의 claim으로 분리한다;

각 claim과 원문 후보의 어휘 중첩 점수를 계산한다;

임계값 이상인 출처를 연결하고, 지지되지 않은 claim은 최종 답변에서 제외한다;

서버가 출처 번호를 부착하고 내부용 전체 원문을 제거한 뒤 응답한다;

LLM이 직접 출처 번호를 생성하게 하지 않고 서버가 검색 결과 ID와 번호를 대응시키므로 존재하지 않는 인용 번호가 생성되는 위험을 줄였다. 다만 현재 claim 검증은 의미적 함의 판정이 아니라 어휘 중첩 임계값 0.18을 사용하는 1차 필터이다.

3.8 사용자 인터페이스

프론트엔드는 React, TypeScript, Vite 기반 단일 페이지 애플리케이션이다. 데스크톱에서는 좌측 기관, 인덱스 패널, 중앙 채팅, 우측 근거 패널의 3열 구조를 사용한다. 980px 이하에서는 좌우 패널을 drawer로 전환한다.

주요 기능은 기관 필터, 추천 질의, 질문 1,000자 제한, 45초 timeout, 처리 단계 안내, 답변 내 출처 배치, 지지 claim 비율, 검색 문서 미리보기, 원문 위치 표시이다. 처리 단계 안내는 서버 이벤트 스트리밍이 아니라 클라이언트 타이머에 기반한 진행 표현이다.




그림 3.2: 부산대학교 범위를 선택한 실제 질의, 인용 답변 및 claim 근거 패널. 화면 캡처는 외부 API 키 없이 추출형 fallback 모드로 수행하였다.

3.9 기본 API 보호

현재 구현된 보호 기능은 적대적 공격 탐지기라기보다 로컬 MVP의 API hardening에 해당한다.

- 허용 Origin 목록과 선택적 API 토큰
- 요청 본문 기본 32KiB, 질문 1,000자, Top-k 최대 20 제한
- 동시 Gemini 생성 기본 2개, 초과 요청에 429 반환
- 내부 검색용 전체 청크를 공개 응답에서 제거
- 검색 문서 내부의 지시문을 따르지 않도록 생성 프롬프트에 명시
- X-Content-Type-Options: nosniff 헤더

제4장 구현 결과와 개발 진척

4.1 코퍼스 및 파싱 결과




그림 4.1: 기관별 파싱 문서 수와 전체 파일 처리 결과

표 4.1: 전체 파일 처리 결과

상태	파일 수	전체 대비 비율
파싱 성공	2,725	92.5%
5MB 초과 보류	111	3.8%
지원하지 않는 형식	53	1.8%
파싱 오류	30	1.0%
빈 문서	28	1.0%
합계	2,947	100.0%

파싱 성공 문서에서 총 42,744개 청크가 생성되었다. 부산대학교는 HWP 386개와 HWPX 3개로 구성되며, 통합 파이프라인에서 389개 모두 파싱되어 1,228개 청크가 생성되었다. 가장 많은 코퍼스는 금융감독원 1,082개 문서와 27,717개 청크이다.

4.2 개발 타임라인

표 4.2: Git 이력 기반 주요 개발 진척

날짜	커밋	주요 산출물
2026.04.09	3b8fa2e	저장소 초기 구성
2026.05.11	4d74576	산지니 기반 React 챗봇 UI
2026.05.13	bd87fcf	부산대학교 규정 문서 추가
2026.06.29	77c16ed 외	KIOST, KISA 문서와 기관별 데이터 정리
2026.06.30	31cceeef 외	금융기관 크롤러, 중복 제거 보고서, 대규모 금융 코퍼스
2026.07.06	ff89505	파싱, BM25, RAG API, React UI 종단 간 통합
2026.07.07	9ae2871	API hardening과 자동 테스트 7개
2026.07.09	5f22839	부산대학교 문서 변환 보조 경로 실험

4.3 자동 검증 결과

2026년 7월 16일 현재 작업 트리에서 표 4.3의 검증을 다시 실행하였다.

표 4.3: 현재 코드 자동 검증 결과

검증 항목	결과	확인 내용
Python unittest	통과, 7/7	환경 변수, Top-k, 질문 길이, CORS, 토큰, 내부 원문 비공개, HTTP 401, 403, 200
ESLint	통과	프론트엔드 정적 분석 오류 없음
TypeScript	통과	프로젝트 참조를 포함한 tsc -b 성공
Vite build	통과	48개 모듈 변환, 프로덕션 번들 생성
로컬 UI smoke test	통과	API 상태, 기관 선택, 질문 전송, 답변, claim, 출처 패널 동작 확인

프론트엔드 전용 단위 테스트와 브라우저 E2E 테스트는 아직 없다. 현재 npm test는 Python 테스트만 실행하므로 후속 단계에서 사용자 흐름을 자동화한 E2E 테스트가 필요하다.

제5장 예비 평가

5.1 평가 범위

현재 평가는 구현 연결성과 시스템 동작을 확인하는 예비 평가이다. 검색 정답셋을 이용한 Recall@k, MRR, 답변 정확도, citation precision, recall, 최신 문서 선택률, 공격 성공률은 아직 측정하지 않았다. 따라서 본 장의 수치를 최종 RAG 품질로 해석하지 않는다.

5.2 BM25 검색 지연시간

부산대학교, 한국거래소, 금융감독원, 한국은행의 대표 질의 5개를 사용하였다. 각 질의를 1회 warm-up 한 뒤 기관 필터와 Top-k 8 조건에서 질의당 20회, 총 100회를 측정하였다. 측정 범위는 search_index 함수만 포함하며 HTTP와 답변 생성 시간은 제외한다.

표 5.1: BM25 검색 지연시간 예비 측정

지표	지연시간(ms)
평균	153.90
최솟값	106.78
P50	158.60
P95	193.26
최댓값	202.99

현재 검색기는 로컬 단일 프로세스와 warm SQLite 캐시 조건에서 P95 200ms 이내에 근접하였다. 그러나 동시 사용자, cold start, HTTP 직렬화, Gemini 응답 지연을 포함한 종단 간 성능은 별도 측정해야 한다.

5.3 질적 동작 확인

그림 3.2의 질의에서는 부산대학교 기관 필터와 Top-k 8을 적용하여 휴학 관련 문장을 추출하고, 각 claim에 서버가 출처 번호를 부착하였다. UI는 답변과 함께 근거 후보 수, 지지 claim 수, 문서와 원문 위치를 표시하였다.

이 결과는 전체 흐름이 동작한다는 증거이지만, 정답성을 보장하지 않는다. 실제로 BM25는 질문과 단어가 겹치는 교원양성위원회 규정, 방문학생 규정, 부설고등학교 학칙 등을 상위 후보에 포함시키기도 했다. 이는 기관 필터만으로 문서 유형과 권위 체계를 구분하기 어렵고, 하이브리드 검색, reranking, 문서 유형 필터가 필요함을 보여준다.

5.4 병렬 프로토타입의 답변 품질 점검

별도 로컬 프로토타입의 두 질의를 성공, 실패 사례로 함께 검토하였다. 성공 화면만 제시하지 않고 모호 질의의 실패 원인을 같이 기록함으로써, reranking 옵션의 존재와 실제 품질 향상을 구분하였다.

표 5.2: 별도 로컬 프로토타입의 질적 답변 점검

질의	판정	관찰 결과
교내 차량등록 어떻게 해?	부분 성공	총무과 등록, 온라인 또는 행정실 신청, 기재 정보와 주차료를 결론, 세부 내용, 확인 필요사항으로 구조화하였다. 다만 화면의 근거 수는 3개인데 답변에 “[근거 4]”가 나타나 인용 번호 대응을 확인해야 한다.
연구자등록 어떻게 해	실패	총장임용후보자 등록과 장영실 AI융합연구원 연구과제 참여 규정을 한 답변에 혼합하였다. 모호한 “연구자등록”의 의미를 확인하지 않은 채 관련 단어가 있는 서로 다른 규정을 결합한 사례이다.




그림 5.1: 별도 로컬 프로토타입의 차량 등록 질의. 정밀 재정렬과 근거 3개를 설정하고 Ollama 연결 상태에서 구조화된 인용 답변을 생성한 사례




그림 5.2: 모호한 연구자 등록 질의에서 서로 다른 규정을 혼합한 실패 사례. 질의 명확화와 재정렬 효과 검증이 필요함을 보여준다

차량 등록 답변은 절차를 읽기 쉽게 정리하고 확인이 필요한 항목을 분리한 점이 양호하다. 반면 연구자 등록 답변은 인용 형식을 갖추었더라도 질문 의도에 맞지 않는 문서를 조합하면 답변 품질이 낮아질 수 있음을 보여준다. 따라서 모호도가 높은 질의에는 즉시 답하기보다 “어떤 종류의 연구자 등록을 의미하는가”를 묻는 명확화 단계 또는 신뢰도 미달 시 답변 보류 정책을 적용한다.

후속 비교에서는 동일 질의에 대해 BM25 단독, dense 단독, hybrid, hybrid와 reranker 조합을 실행한다. 각 단계의 후보 문서와 순위, reranker 점수, 최종 근거 ID, 답변, 지연시간을 저장하고 재정렬 비활성, 활성 결과를 나란히 비교한다. 이를 통해 검색 실패, 재정렬 실패, 생성 실패와 인용 번호 오류를 분리한다.

5.5 현재 평가의 한계

- 검색 정답 문서와 정답 chunk가 표시된 gold set이 없다.
- claim 검증은 의미 기반 entailment가 아니라 어휘 중첩 휴리스틱이다.
- Gemini와 추출형 fallback의 결과가 로그에서 구분되지 않는다.
- 최신 문서와 구버전 문서가 충돌하는 테스트가 없다.
- 공격 입력과 정상 입력을 구분하는 평가셋이 없다.
- 사용자 평가, 응답 비용, 중단 간 지연시간을 측정하지 않았다.
- 별도 로컬 프로토타입의 소스, 임베딩, reranker, Ollama 모델 설정과 실행 로그가 현재 저장소에 통합되지 않았다.
- 정밀 재정렬 비활성, 활성 조건의 후보 순위와 품질 지표를 동일 질의에서 비교하지 않았다.
- 차량 등록 화면은 근거 수 3개와 “[근거 4]”가 함께 나타나 최종 인용 ID 재매핑을 확인해야 한다.

제6장 발견된 문제와 대응 계획

6.1 파싱 품질

현재 파이프라인에서는 HWP 제어 레코드가 U+6364/U+7365, U+6C20/U+7462와 같은 깨진 문자로 남는 사례가 있다. 특정 패턴만 기준으로도 5,056개 청크, 전체의 11.83%에서 발견되었다. 또한 스캔형 PDF용 OCR이 없고, 5MB 초과 문서 111개는 보류되었다. 목표 청크 크기는 1,800자지만 문단 결합 과정에서 618개 청크가 목표를 초과하며 최댓값은 2,052자이다.

대응 방안은 HWP 정제 로직을 메인 파서에 통합하고, 파일 형식별 품질 샘플링과 OCR fallback을 도입하며, 청크를 추가할 때마다 길이를 재검사하는 것이다.

6.2 최신성

크롤러는 SHA-256과 수집 시각을 기록하고 파서는 파일 수정 시각을 저장한다. 그러나 수정 시각은 청크 메타데이터에 전달되지 않으며 DB 스키마에도 날짜 필드가 없다. 검색 SQL은 BM25 점수만으로 정렬한다. 또한 동일 URL이나 파일명이 이미 존재하면 본문 변경 여부를 확인하기 전에 건너뛸 수 있어 같은 주소의 개정본을 놓칠 수 있다.

후속 구현에서는 게시일, 시행일, 개정일, 수집일, 기관 권위, 문서 유형, 상위·하위 규정 관계를 공통 스키마로 정의한다. URL 재방문 시 새 본문 해시를 비교하고, 버전 계보와 활성 상태를 저장한 뒤 BM25 또는 hybrid 점수에 최신성 점수를 결합한다.

6.3 검색과 근거성

통합 기준선의 BM25는 빠르고 해석 가능하지만 동의어와 의미적 유사성에 약하며, 현재 지지 claim 판정도 단어 중첩 임계값에 의존한다. 별도 로컬 프로토타입에서 키워드·의미 기반 검색과 정밀 재정렬 흐름을 시험했으므로, 다음 단계는 프로토타입 소스·설정의 공통 저장소 통합과 실제 동작·효과 검증이다. Sentence-BERT 계열 임베딩[4]을 이용한 dense 검색을 구성하고, BM25 단독, dense 단독, RRF 기반 hybrid, hybrid와 reranker 조합을

동일 평가셋에서 비교한다. 평가는 Recall@5, Recall@10, MRR, nDCG, citation precision, recall과 faithfulness를 사용한다[1].

6.4 적대적 공격 대응

현재는 문서 내부 지시를 따르지 말라는 프롬프트와 API hardening만 구현되어 있다. 이는 직접, 간접 프롬프트 인젝션을 체계적으로 탐지하거나 차단하는 기능이 아니다. 공격 단계별로 다음 항목을 추가한다.

1. 입력 단계: 정책 위반, prompt override, 인코딩, 다국어 우회 패턴 탐지
2. 수집 단계: 출처 도메인, 문서 해시, 관리자 승인과 quarantine 상태
3. 검색 단계: 문서 신뢰도와 권위 기반 필터, 의심 문서 제외
4. 생성 단계: 시스템 지시와 검색 근거 분리, 민감정보 및 과도한 권한 요구 차단
5. 평가 단계: 공격 성공률, 정상 질의 통과율, 오답률, 답변 품질 유지율 측정

6.5 운영과 재현성

현재 서버는 localhost용 개발 브리지이며 Docker, CI workflow, 배포 manifest, 구조화 로그와 관리자 기능이 없다. 파서 기본 출력 경로와 검색기 기본 입력 경로도 일치하지 않아 README 명령만으로 전체 파이프라인을 재현하기 어렵다. 크롤링, 파싱, 인덱싱, smoke test를 단일 명령으로 실행하는 통합 스크립트와 실행 manifest를 추가할 예정이다.

표 6.1: 핵심 위험과 완료 판정 기준

위험	대응 작업	완료 판정 기준
파싱 노이즈	HWP 정제 통합, OCR fallback, 형식별 표본 검사	지원 대상 파일의 파싱 성공률 95% 이상, 노이즈 패턴 현저히 감소
검색 오답	병렬 프로토타입 통합, BM25, dense, hybrid, reranker ablation	PNU gold set에서 Recall@5와 MRR 기준 달성, 재정렬 전후 개선 확인
구버전 답변	버전 스키마, 변경 감지, 최신성 재순위화	충돌 문서셋에서 최신 문서 선택률 측정 및 stale answer 감소
공격 우회	공격 데이터셋, 입력, 문서 탐지, 정책 필터	방어 전후 ASR과 정상 질의 오답률 비교
운영 불안정	통합 pipeline, 구조화 로그, E2E test	신규 환경에서 문서 처리부터 UI smoke test까지 재현

제7장 향후 일정과 추진 체계

7.1 향후 개발 일정

표 7.1: 2026년 7월 이후 상세 일정

기간	핵심 작업	산출물
7월 17일부터 7월 31일	HWP 정제와 파이프라인 정리, 별도 hybrid、reranker、Ollama 프로토타입의 공통 인터페이스 통합, 인용 ID 수정, 모호 질의 정책, PNU gold 질문 작성	재현 가능한 실행 명령, 통합 실험 경로, 성공、실패 질의와 평가셋 초안
8월 1일부터 8월 15일	BM25、dense、hybrid、reranker ablation, 모델、지연시간 비교, 최신성 점수 baseline	단계별 검색 비교표, Recall@k、MRR、지연시간과 재정렬 전후 결과
8월 16일부터 8월 31일	prompt、문서 인젝션 데이터셋, 방어 로직, 근거성 평가와 로그	공격 전후 ASR、오답률, citation、faithfulness 결과
9월 1일부터 9월 15일	최소 관리자 기능, 사용자 beta test, 종단 간 성능、비용 측정	관리자 화면, 사용자 피드백, P50、P95、비용표
9월 16일부터 9월 30일	오류 수정, 데모 안정화, 최종 보고서와 발표 준비	최종 시스템, 시연 영상, 최종 보고서

7.2 정량 평가 계획

다음 목표값은 현재 달성값이 아니라 후속 구현의 잠정 수용 기준이다. baseline 측정 후 난이도에 맞게 최종 확정한다.

표 7.2: 후속 정량 평가 지표와 잠정 목표

평가 축	지표	잠정 목표
파싱	지원 대상 성공률	95% 이상
검색	Recall@5, MRR	Recall@5 0.85 이상, MRR 0.70 이상
근거성	citation precision, faithfulness	각각 0.90, 0.85 이상
최신성	최신 문서 선택률, stale answer rate	0.95 이상, 0.05 이하
공격 대응	공격 성공률, 정상 질의 오탐률	각각 0.10 이하, 0.05 이하
성능	BM25 P95, 종단 간 P95	300ms 이하, 8초 이하
사용성	task success, 유용성 평점	0.85 이상, 5점 만점 4.0 이상

7.3 역할 분담

착수 단계의 역할을 기준으로 하되, 통합과 평가 작업은 공동으로 수행한다. Git 작성자 이름은 개인의 전체 기여를 정확히 나타내지 않을 수 있으므로 본 보고서에서는 팀이 합의한 담당 영역을 기준으로 정리한다.

표 7.3: 팀 역할 분담

구성원	담당 업무
이현우	팀장, 백엔드 API, 검색 엔진, BM25, hybrid 검색, RAG pipeline, LLM 연동 구조
황지완	문서 수집, 전처리, 파싱 품질, 메타데이터, 최신성, 평가 데이터셋, 보안, 공격 테스트
정지인	프론트엔드, 사용자 인터페이스, 관리자 화면, 사용자 테스트와 피드백 정리
공동	병렬 검색, 생성 모델 비교와 통합, 요구사항 조정, 정량 평가, 문서 작성, 데모와 발표 준비

제8장 결론

본 과제는 착수 단계의 설계를 실제 문서 코퍼스와 동작 가능한 RAG 기준선으로 발전시켰다. 7개 기관의 원문 2,947개를 정리하고 2,725개 문서를 파싱하여 42,744개 청크와 SQLite FTS5 BM25 인덱스를 구성하였다. 검색 결과를 Gemini 또는 추출형 방식으로 답변에 반영하고, 생성 문장과 원문의 어휘 정합성을 검사한 뒤 출처 번호를 서버가 부착한다. React UI에서는 기관 선택, 인용 답변, claim 검증, 문서와 원문 위치를 확인할 수 있으며 자동 테스트 7개와 프론트엔드 정적 분석, 빌드도 통과하였다.

동시에 팀은 부산대학교 규정 코퍼스에서 키워드, 의미 기반 검색, 정밀 재정렬, Ollama 생성과 근거 표시를 결합한 별도 로컬 프로토타입을 병렬 시험하였다. 차량 등록 질의에서는 구조화된 답변을 확인했지만 인용 번호 대응 문제가 있었고, 연구자 등록 질의에서는 서로 다른 규정을 혼합하는 실패가 나타났다. 이는 reranking 옵션만으로 품질이 보장되지 않으며 명확화 질문, 검색 단계별 로그, 공통 평가셋이 필요함을 보여준다.

중간 점검을 통해 최신성, 의미 기반 정확성, 적대적 공격 대응은 여전히 핵심 연구 과제로 남아 있음을 확인하였다. 향후에는 개인별 결과를 나열하지 않고 통합 기준선과 비교 실험군을 공통 인터페이스에 합친 뒤, BM25, dense, hybrid, reranker 조합, 최신성 재순위화와 공격 방어를 동일 데이터와 지표로 검증할 예정이다.

제 A 장 재현과 근거 파일

A.1 주요 실행 명령

```
python scripts/parse_documents.py --input src/data --output processed/
    current --max-file -mb 5
python scripts/bm25_search.py build --chunks processed/current/chunks.
    jsonl --index processed/index/bm25.sqlite
python scripts/search_api.py --host 127.0.0.1 --port 8000 --env-file .
    env
npm run dev -- --host localhost
npm run check
```

A.2 내부 검증 근거

- 파싱 요약: processed/current/parse_summary.json
- 파싱 세부 보고서: processed/current/parse_report.csv
- 검색 인덱스: processed/index/bm25.sqlite
- 검색 예비 측정: output/pdf/midterm_report/benchmark_search.json
- API 、보안 테스트: tests/test_api_hardening.py
- 프론트엔드: src/App.tsx, src/App.css
- 파싱 、검색 、API: scripts/parse_documents.py, scripts/bm25_search.py, scripts/search_api.py

참고문헌

- [1] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation, 2023.
- [2] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [3] Fábio Perez and Ian Ribeiro. Ignore previous prompt: Attack techniques for language models, 2022.
- [4] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992, 2019.
- [5] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.