
최신성, 정확성, 적대적공격대응을
적용한 부산대학교 및 공공기관
행정문서 챗봇



202155596 이현우 kodokugourmet@gmail.com
202155627 황지완 hjw8486@pusan.ac.kr
202355709 정지인 gini202355709@gmail.com

지도교수: 손준영

목차

1	서론	1
1.1	연구 배경	1
1.2	기존 문제점	2
1.3	연구 목표	2
2	연구 배경	4
2.1	검색 증강 생성과 문서 근거	4
2.2	어휘 검색과 의미 검색	4
2.3	문서 분할과 문맥 구성	5
2.4	답변 품질과 자동 평가	5
2.5	문서 내부 공격 지시와 검사 경계	6
3	연구 내용	7
3.1	시스템의 전체 구조와 구현 범위	7
3.2	공식 문서 수집과 입력 코퍼스 확정	8
3.2.1	수집 범위와 재개 가능한 실행	8
3.2.2	평가 문서의 실제 수집 절차와 설정	9
3.2.3	선별 manifest와 원본 추적	10
3.3	이질적 문서의 구조화와 청킹	10
3.3.1	공통 데이터 구조	10
3.3.2	형식과 품질에 따른 Cascade 파싱	10
3.3.3	표·섹션 보존과 색인 허용 판정	11
3.3.4	실제 표의 원문·Block·청크 연결	12
3.4	검색 후보 선정과 문맥 구성	14
3.4.1	BM25와 문서 다양성	14
3.4.2	복합 질문의 누락 근거 보완	14
3.4.3	기관 필터와 역할의 구분	15
3.4.4	최신성: 문서 시점 확인과 갱신 범위	15
3.5	근거 기반 생성과 문장별 판정	15
3.5.1	질문별 요청·응답 계약	15
3.5.2	근거의 존재와 주장 지지 여부 분리	16
3.6	생성 전후 보안 검사	17
3.7	실제 질의의 검색·답변·인용 흐름	19
3.7.1	대학생활원 공지 확인 사례	19
3.7.2	출처를 확인하여 적용 범위 판단	20
3.8	사용자 인터페이스와 실패 대응	21
3.8.1	질문 작성에서 근거 확인까지	21
3.8.2	대화 기록과 요청 일관성	22

3.8.3	취소·연결 오류·근거 부족의 처리	22
3.9	규칙 기반 처리의 항목과 적용 범위	23
3.10	대표 설계 변경과 구현상의 판단	24
3.11	구성원 역할 및 수행 일정	25
4	연구 결과 분석 및 평가	26
4.1	평가 목적과 실험 구성	26
4.1.1	Q&A 평가셋의 출처와 구성	27
4.1.2	실험 기록과 재현 조건	29
4.2	코퍼스 구축과 파서 평가	29
4.2.1	코퍼스 구축 결과	29
4.2.2	형식별 근거 보존	30
4.3	DEV45 검색 비교	31
4.3.1	9월 2일 검색 방식 비교	31
4.3.2	9월 4일 의도별 후속 검색 보완	32
4.4	DEV45 생성 및 근거 결속 평가	33
4.4.1	C0·C1의 독립 생성 비교	33
4.4.2	동일 답변에 대한 Judge 반복	34
4.4.3	C2의 주장·인용 동시 생성 실험	34
4.4.4	저장 초안의 후처리 진단	34
4.5	Shadow60의 검색·생성 진단	35
4.5.1	출처 분리와 검색 결과	35
4.5.2	생성 완결성과 결과	36
4.5.3	대표 실패 사례	36
4.6	보안 검사 파일럿	37
4.7	최종 holdout 평가와 사람 검수	38
4.7.1	평가셋과 실행 조건	38
4.7.2	자동 평가 결과	39
4.7.3	검색 단계와 생성·검증 단계의 분리	39
4.7.4	사람 1인 검수와 Judge의 일치도	41
4.8	종합 해석과 검증 범위	43
5	결론 및 향후 연구 방향	46
5.1	연구 결과 요약	46
5.2	향후 연구 방향	47
	참고문헌	49

제1장 서론

1.1 연구 배경

대학과 공공기관의 행정 업무에서는 답변의 자연스러움만큼 적용 대상, 시행 시점, 예외 조건을 정확하게 전달하는 일이 중요하다. 학생이 장학금 신청 자격을 확인하거나 연구자가 연구비 집행 절차를 찾을 때, 필요한 정보가 하나의 안내문에 모두 담겨 있지 않을 수 있다. 공지 본문에는 개요만 있고 신청 기간은 첨부 표에, 예외 조항은 별도의 규정이나 자주 묻는 질문에 제시된다. 사용자는 부서별 홈페이지를 이동하고 서로 다른 형식의 파일을 열어 관련 내용을 직접 연결해야 한다.

기관의 규정이 개정되거나 한시적 행정 지침이 함께 적용되면 문서를 찾은 뒤에도 어느 조건이 현재 업무에 해당하는지 확인해야 한다. 게시일이 최근이라는 이유만으로 모든 질문에 우선 적용할 수는 없으며 규정의 시행 시점과 안내문의 대상이 다를 수 있다. 따라서 본 과제는 문서 탐색과 함께 신청 대상·기간·예외를 확인하는 과정을 연구 대상으로 삼았다.

본 과제는 이러한 탐색 과정을 줄이기 위해 부산대학교 및 공공기관의 공식 문서를 검색하고 검색 근거에 연결된 답변을 제공하는 행정 문서 질의응답 시스템을 구현하였다. 과제팀의 명칭은 ‘무엇이든 물어보세’이며 구현 화면은 ‘PNU Docs’로 표시하였다. 사용자가 질문에 대한 답변과 함께 문장별 출처, 원문 발췌, 원문 링크를 확인할 수 있도록 구성하였다. 외부 문서를 찾아 생성 모델의 입력에 제공하는 검색 증강 생성(Retrieval-Augmented Generation, RAG)을 적용하였다[1]. 기관 문서의 수집·검색, 근거 기반 생성과 인용 검사를 연결한 RAG 응용 시스템이다.

시스템의 대상은 부산대학교에 한정되지 않는다. 금융감독원, 한국거래소, 한국예탁결제원, 한국은행, 한국인터넷진흥원, 한국해양과학기술원의 문서도 기관별로 구분하여 다룬다. 주요 정량 평가는 부산대학교 행정 문서로 구성된 개발용 질문과 개발에 사용하지 않은 별도 평가 질문을 대상으로 수행하였다.

1.2 기존 문제점

첫 번째 문제는 문서 형식과 구조의 불균일성이다. HTML 안내문, 텍스트 기반 PDF, 스캔 PDF, HWP와 HWPX, Office 문서는 텍스트를 얻는 방법이 서로 다르다. 동일한 PDF에서도 문단 순서와 표 셀의 관계가 깨질 수 있다. 추출에 성공했다는 사실만으로 금액과 대상, 날짜와 절차의 대응 관계까지 보존되었다고 볼 수 없으므로 파싱 이후의 품질 검사와 근거 위치 정보가 필요하다.

두 번째 문제는 검색 성공과 답변 성공 사이의 간극이다. 정답 문서가 검색되어도 답변에 필요한 표 행이나 예외 조항이 생성기에 전달되지 않으면 응답이 불완전해진다. 반대로 많은 문서를 한꺼번에 전달하면 관련성이 낮은 문맥이 핵심 근거를 가리거나 서로 다른 연도의 조건을 섞을 수 있다. 질문의 핵심 표현, 문서 제목, 연도, 문서별 검색 결과의 다양성을 함께 고려해야 한다.

세 번째 문제는 생성 결과의 검증 가능성이다. 출처 목록만 붙인 답변은 각 문장이 어느 근거에서 나온 것인지 알기 어렵다. 또한 문서 내부에 모델의 행동을 바꾸려는 문장이 포함되면, 원래 질문과 무관한 출력을 유도할 수 있다. 따라서 공식 도메인에서 수집한 자료라도 생성 모델의 지시문으로 취급해서는 안 되며 문서 내용의 격리와 출력 인용의 검사가 필요하다.

네 번째 문제는 평가 결과의 해석이다. 상위 검색 결과에 정답 문서가 포함된 비율은 최종 답변의 정확도와 다르다. 개발에 반복 사용한 질문에서 얻은 개선도 새로운 질문에 그대로 유지된다고 볼 수 없다. 본 과제는 검색, 생성, 인용 무결성, 보안 동작을 별도의 평가 대상으로 나누고 각 실험의 표본과 조건을 명시하였다.

1.3 연구 목표

본 과제의 목표는 기관 행정 문서를 검색 가능한 형태로 구축하고 사용자의 질문에 대해 근거를 확인할 수 있는 답변을 제공하는 것이다. 이를 위해 다형식 문서의 수집·선별·파싱, 문서와 절의 구조를 유지하는 분할, 검색 인덱스 구축, 질문과 역할을 반영한 검색, 생성 전후 보안 검사, 원문 확인 인터페이스를 구현하였다.

연구 질문은 다음과 같다. 첫째, 이질적인 한국어 행정 문서를 근거 위치를 유지한 채 검색 시스템에 연결할 수 있는가. 둘째, 질의와 문서의 특성을 고려한 검색 조정이 개발용 질문의 검색 및 생성 품질에 어떤 영향을 주는가. 셋째, 문서 입력과 인용 출력의 검사 기능이 실제 생성 흐름에서 어떻게 작동하는가. 넷째, 개발용 질문에서 확인한 개선은 출처가 다른 진단 질문에서도 유지되는가.

표 1.1. 연구 목표

구분	구현 목표	확인 방법
문서 처리	여러 형식의 문서를 공통 구조로 변환하고 위치 정보를 보존	수집·파싱 산출물과 파서 비교
근거 검색	관련 문서와 필요한 내용이 검색되도록 후보를 구성	문서 적중률·순위·지정 근거 회수율
답변 제공	문장별 인용과 원문 확인 수단을 제공	실제 생성 기록·서비스 화면
입력과 출력 검사	문서 속 공격 지시 및 잘못된 인용을 검사	합성 기능 시험·생성 포함 보안 파일럿
평가 재현성	질문·코드·응답·판정과 실행 조건을 연결	실험별 산출물·해시·집계 기록

본 보고서는 확인된 구현과 저장된 실험 결과를 기술한다. 개발에 사용하지 않은 holdout 36문항의 최종 실행과 개발자 1인의 채점 결과를 포함하되, 독립된 두 사람의 검수는 수행하지 못했음을 명시한다. 문서의 최신성은 수집 시점과 원문으로 확인하는 속성이며 모든 규정의 최신 개정 반영이나 실제 행정 판단의 자동화를 보장하는 기능으로 정의하지 않는다.

본 보고서에서 **파싱**은 문서의 글과 표를 추출하는 처리, **체크**는 검색을 위해 나눈 문서 조각, **문맥**은 답변 모델에 전달하는 근거 묶음을 뜻한다. **DEV**는 개발 중 반복해서 본 질문, **holdout**은 개발에 사용하지 않은 평가 질문이다. **Judge**는 정해진 기준으로 답변을 채점하는 모델이며, **GFC**는 내용·근거·인용을 모두 충족한 완전정답물이다. 이하에서는 구현 여부와 실제 성능을 구분하여 설명한다.

제2장 연구 배경

2.1 검색 증강 생성과 문서 근거

RAG는 생성 모델 내부의 지식에 외부 검색 결과를 결합하여 답변을 생성하는 접근이다 [1]. 본 과제에서는 질문에 맞는 기관 문서의 일부를 검색하여 생성 입력을 구성하고 응답과 출처를 연결한다. 문서가 갱신되면 검색 인덱스를 다시 구축할 수 있으며 사용자는 답변의 근거가 된 원문을 확인할 수 있다.

이 구조에서 검색기는 어떤 정보를 생성기에 보여 줄지 결정하고 생성기는 제공받은 정보를 질문에 맞게 정리한다. 검색된 문서가 적절하지 않거나 필요한 조건이 빠져 있으면 생성기의 언어 능력만으로 이를 해결하기 어렵다. 따라서 문서 수집 범위와 파싱 품질, 검색 결과의 구성, 생성 결과의 근거성을 함께 다루는 설계가 필요하다. 본 시스템은 근거가 충분하지 않은 경우 부분 답변이나 답변 보류를 허용하고 생성 호출 실패 시에는 원문 추출형 답변을 제공하는 경로를 둔다.

2.2 어휘 검색과 의미 검색

BM25는 질의 용어의 문서 내 출현 빈도, 전체 문서 집합에서의 희소성, 문서 길이 정규화를 결합하는 어휘 기반 검색 방식이다 [2]. 행정 문서에 자주 등장하는 사업명, 기관명, 규정명, 연도처럼 정확한 문자열의 구분이 필요한 경우 유용한 기준선이 된다. 본 시스템의 기본 서비스 검색은 SQLite FTS5에 구축한 BM25 인덱스를 사용한다.

Dense 검색은 질의와 문서를 벡터로 표현하여 표현상의 차이를 보완하는 방식이다. DPR은 질문과 지문을 각각 인코딩하는 이중 인코더 구조를 통해 밀집 벡터 검색을 수행하였다 [3]. 본 과제에서는 한국어 임베딩 모델을 선택하여 의미 유사도 검색 경로를 구현하고 해당 코퍼스에서 BM25와 비교하였다.

BM25의 점수와 벡터 유사도는 척도가 다르므로 원점수를 단순히 더하면 한 검색기의 값이 결합 결과를 지배할 수 있다. Reciprocal Rank Fusion(RRF)은 검색기별 순위를 이용하여 후보를 통합한다 [4]. 후보 문서 d 에 대한 점수는 각 검색기의 순위 r 을 이용한 $1/(c+r)$ 의 합으로

계산한다. 여기서 c 는 상위 순위의 영향을 조절하는 양의 상수이며, $\text{Hit}@k$ 의 검색 개수 k 와 구분한다. 이러한 결합은 어휘 일치와 의미 유사도를 함께 활용하며, 그 효과는 동일 질문과 문서에서 비교하여 확인한다.

본 과제는 서비스의 기본 경로와 탐색 실험을 분리하였다. 부산대학교 서비스의 주요 비교는 Cascade 파싱과 BM25 검색을 유지한 채 검색 조정을 적용한 전후 비교이다. Dense·Hybrid 검색과 연구비 규정의 재정렬 실험은 별도 조건으로 기록하였으며 이 실험 구성은 대표 서비스 요청의 기본 구성과 구분된다.

2.3 문서 분할과 문맥 구성

긴 문서는 검색 단위인 청크로 분할한다. 청크를 지나치게 짧게 나누면 조건과 예외가 떨어지고 지나치게 길게 나누면 핵심 정보의 비중이 작아질 수 있다. 본 과제에서는 문서 제목, 절의 경로, 표 여부, 페이지나 청크 위치를 보존하여 검색 결과를 원문에 다시 연결할 수 있도록 하였다.

긴 입력에서는 관련 정보의 위치에 따라 모델의 활용 능력이 달라질 수 있다[5]. 본 시스템은 문서별 청크 수를 제한하여 특정 문서가 문맥을 독점하지 않도록 하고 필요한 경우 같은 문서의 인접 구간을 이용하여 질문이 요구한 서로 다른 항목을 보완한다. 문맥은 질문에 필요한 근거를 중심으로 구성한다.

2.4 답변 품질과 자동 평가

RAG의 평가는 검색과 생성을 나누어야 한다. RAGAS는 검색된 문맥의 적절성, 응답의 근거성, 질문과의 관련성 등 구성 요소별 평가의 필요성을 제시하였다[6]. 본 과제는 검색에 문서 적중률과 순위 지표를 적용하고, 답변에는 자체 평가표의 0~2점 점수와 근거 충족 완전정답률(GFC)을 사용한다. GFC(Grounded Full-Correct Rate)는 본 과제에서 정의한 지표로, 필요한 내용을 빠짐없이 정확하게 답하고 근거와 인용 조건을 충족한 답변의 비율이다.

LLM은 여러 답변을 같은 형식으로 평가할 수 있으나 답변 순서·길이·모델 계열에 따른 편향이 보고되었다[7]. 본 과제의 생성기와 평가자는 같은 Gemini 계열이므로 점수는 해당 평가 설정에서 얻은 자동 평가 결과로 해석한다. 반복 생성은 질문 내부의 변동을 확인하는 데 사용하며, 분석 단위는 질문이나 관련 질문군으로 유지하였다.

2.5 문서 내부 공격 지시와 검사 경계

프롬프트 주입은 입력에 섞인 명령으로 모델이 원래 지시와 다른 행동을 하도록 유도하는 공격이다. Perez와 Ribeiro의 *Ignore Previous Prompt*는 목표와 다른 출력을 유도하는 목표 탈취(goal hijacking)와 원래 프롬프트를 노출시키는 프롬프트 유출(prompt leaking)을 구분하고 PromptInject 실험 틀을 제시하였다[8]. 예를 들어 “앞의 지시를 무시하고 지정한 문구만 출력하라”는 문장은 답변의 목표를 바꾸려는 지시다. 이 논문은 악성 지시문을 설명하는 근거 문헌이며, 본 과제의 평가 문항을 그대로 가져온 데이터셋 출처는 아니다.

검색 시스템에서는 사용자가 직접 쓴 질문뿐 아니라 검색된 문서도 공격 경로가 될 수 있다. Greshake 등의 연구는 외부 콘텐츠를 통해 모델 동작을 바꾸는 간접 프롬프트 주입을 다루었다[9]. 본 과제의 문서 내부 공격 실험은 이 위협 상황에 해당한다. 문서 본문과 파일명은 답변 자료이지 모델의 역할을 바꾸는 명령이 아니다. 따라서 생성 전에 문서 속 공격 지시를 검사하고, 생성 후에는 답변 형식과 인용이 원문에 연결되는지 검사한다.

인용문이 원문에 있고 파일 식별값이 맞더라도 답변이 정답이라는 뜻은 아니다. 해당 문장이 질문의 대상·연도·조건을 실제로 뒷받침하는지 따로 확인해야 한다. 본 과제에서는 공격 지시 차단, 인용 연결 검사, 의미적 정답 평가를 구분하였다.

제3장 연구 내용

3.1 시스템의 전체 구조와 구현 범위

웹 기반 질의응답 시스템은 기관 문서를 검색하여 한국어 답변과 근거를 제공한다. 사용자가 원문과 적용 범위를 확인할 수 있도록 문서 수집부터 답변의 출처 표시까지 문서 식별자와 원문 위치를 유지하였다.



그림 3.1. 문서 준비와 질의응답을 분리한 시스템 구성

그림 3.1과 같이 시스템은 오프라인 문서 준비와 온라인 질의응답으로 나뉜다. 오프라인 단계에서는 공식 웹페이지와 첨부파일을 수집하고 범위·중복·무결성을 검사한 후 형식별 파싱과 청킹을 수행한다. 품질 기준에 따라 허용된 결과로 검색 인덱스를 구축한다. 온라인

단계에서는 질문과 기관·역할 설정을 받아 근거 후보를 검색하고 필요한 문맥을 보완한 뒤 생성 전 보안 검사를 수행한다. 생성된 초안은 문장별 근거 판정과 인용 무결성 검사를 거쳐 최종 답변으로 반환한다. 이 구조로 문서 처리 비용의 반복을 줄이고 파서·검색기·생성기를 같은 인터페이스에서 비교하였다.

대표 서비스는 부산대학교 문서에 Cascade 파싱과 BM25 검색을 적용한 구성이다. Dense 검색, 순위 융합 및 재정렬도 선택 가능한 경로로 구현하였다. 또한 기관 메타데이터와 필터를 통해 금융감독원·한국은행·한국거래소·한국예탁결제원·한국인터넷진흥원·한국해양과학기술원 문서를 구분할 수 있도록 하였다.

표 3.1에 주요 기술과 담당 기능을 정리하였다. 파서와 생성기는 입력 형식·품질 및 실행 설정에 따라 선택한다. 검색·생성 성능 비교의 동결 구성과 이후 보안 계층을 병합한 구성은 구분하며, 보안 결함을 보완한 별도 실험 사본은 구현 개선 후보로 다룬다.

표 3.1. 계층별 기술 구성과 담당 기능

계층	주요 기술	담당 기능
사용자 화면	React · TypeScript · Vite	질문 작성, 답변·인용·원문 표시, 브라우저 대화 기록
질의 API	Python ThreadingHTTPServer · JSON	기관·역할·검색·생성 설정을 받아 질문별 독립 요청 처리
검색 저장소	SQLite · FTS5 BM25	청크·메타데이터 색인과 근거 검색; Dense·Hybrid는 선택 경로
문서 처리	PyMuPDF · pdfplumber, Docling · PaddleOCR, hwplib · hwpplib 등	파일 형식·페이지 특성·추출 품질에 따라 파서와 대체 경로 선택
답변 생성	OpenAI 호환 서버 · Gemini API · 추출형 대체	공통 생성 계약으로 근거 전달, 답변 생성과 실패 시 대체 처리
소프트웨어 검증	Python unittest · Vitest · TypeScript · ESLint	회귀 테스트, 타입 검사, 프론트엔드 검사와 빌드

3.2 공식 문서 수집과 입력 코퍼스 확정

3.2.1 수집 범위와 재개 가능한 실행

대학의 공지와 규정은 중앙 홈페이지뿐 아니라 학사·입학·취업·기숙사·국제교류·학생 지원 사이트 및 학과 게시판에 분산되어 있다. 초기 수집은 학교 도메인 pusan.ac.kr과 그 하위 사이트에서 시작하였다. 이후 서비스용 선별 단계에서 16개 호스트 허용 목록과 주제 조건을 적용하였다. 주소에 학교 이름이 포함된다는 이유만으로 허용하지 않고 응답의 호스트와 형식을 확인한다. HTML 본문과 PDF·HWP/HWPX·Office 첨부파일을 수집 대상으로 삼으며 웹

수집 단계에서 허용하지 않은 이미지·동영상·압축파일·실행파일 등은 제외한다. 파서 자체의 이미지 처리 기능과 웹 수집기의 허용 범위는 별도 설정이다.

수집 상태는 SQLite의 URL 큐에 기록한다. 방문 여부와 처리 상태를 남기므로 네트워크 오류나 실행 중단 후에도 미완료 주소부터 재개할 수 있다. robots.txt와 호스트별 요청 간격을 기본적으로 적용하고 페이지·첨부파일 수와 다운로드 용량에 상한을 둔다. 동일 출력 경로를 여러 수집기가 동시에 변경하는 문제는 파일 잠금으로 방지하였다. 수집 범위 설정의 해시도 함께 저장하여 실행 중 범위가 바뀌었을 때 서로 다른 수집 결과가 동일 작업으로 섞이지 않도록 하였다.

3.2.2 평가 문서의 실제 수집 절차와 설정

평가에 사용한 부산대 수집 기록은 2026년 7월 24일 17시 34분부터 7월 25일 03시 48분까지의 완료 항목을 포함한다(한국 시간). 대표 홈페이지, 대학생활 안내, 공지사항, 학사일정의 네 주소를 시작점으로 삼았다. 실제 처리 순서는 다음과 같다.

1. 시작 페이지에서 HTML 링크와 첨부파일 주소를 읽어 URL 대기열에 넣는다. 허용 도메인, 탐색 깊이, 이미 방문한 주소인지 확인한다.
2. robots.txt를 확인하고 호스트별로 1.5초 간격을 두어 요청한다. 응답 제한시간은 20초, 재시도는 2회이며 처리 상태를 SQLite에 저장해 중단 후 이어서 실행한다.
3. 내려받은 파일의 주소·응답 형식·실제 경로·크기·수집 시각·SHA-256을 기록한다. SHA-256은 같은 내용의 파일인지 확인하는 식별값이다.
4. 완료된 자료에 서비스 호스트와 주제 조건을 적용하고, 같은 게시물의 주소 변형과 내용이 같은 파일을 정리한다. 최종 선택 결과는 원본 경로를 가리키는 목록 파일(manifest)로 고정한다.
5. 선별한 문서를 형식별로 파싱하고 검색용 조각인 청크로 나눈 뒤, 품질 검사를 통과한 청크를 색인에 넣는다.

초기 수집 설정의 최대 깊이는 6, 응답 하나의 최대 크기는 50MiB였다. 실행당 웹페이지 5,000개·첨부파일 3,000개·호스트당 페이지 500개의 상한을 사용했다. 수집을 재개해 누적한 완료량은 10,977개이므로 실행 한 번의 상한과 누적 수집량을 구분해야 한다. 누적 수집에는 100개 호스트가 나타났고, 후속 선별은 16개 호스트를 허용했으며 실제 최종 문서는 그중 12개 호스트에서 선택되었다. 초기 탐색 범위와 최종 서비스 범위는 동일하지 않다.

원본 수집량, 최종 문서 수와 용량은 표 4.4에 제시한다. 이 통계는 부산대 평가 문서에 한정하며 다른 공공기관의 문서량을 합산한 값이 아니다.

3.2.3 선별 manifest와 원본 추적

다운로드가 끝난 파일을 바로 색인에 넣지는 않는다. 별도 선별 단계에서 수집 완료 기록, 실제 파일 경로, 확장자·MIME 유형, 크기와 SHA-256, 허용 호스트를 검사한다. 학과 게시판 범위의 자료에는 행정 주제 관련성 조건을 추가로 적용한다. 같은 게시물을 가리키는 주소 변형은 canonical URL로 정리하고 내용이 같은 파일은 해시로 중복을 제거한다. 다운로드 성공과 검색에 사용할 수 있는 문서라는 판단을 구분한 것이다.

선택한 문서는 원본 파일을 다시 복제하지 않는 manifest로 관리한다. 원문 주소, 첨부파일 주소, 기관, 파일명 및 수집 시점과 선택·제외 사유를 보존하므로 특정 자료의 출처를 추적할 수 있다. 수집·게시 시각 필드의 실제 기록 상태와 문서 시점 확인 범위는 3.4.4절에서 설명한다. 이와 같이 입력 집합을 확정된 후 동일 문서를 세 파서 프로필에 제공하여 수집량 차이와 파서 차이를 분리해 비교하였다.

3.3 이질적 문서의 구조화와 청킹

3.3.1 공통 데이터 구조

PDF에서 추출한 문단, HWP의 표, HTML의 제목은 서로 다른 형태로 반환된다. 이를 그대로 검색기로 전달하면 파서마다 별도 처리 코드가 필요하고 출처 위치도 일관되게 표시하기 어렵다. 본 시스템은 모든 파서 출력을 공통 Block 구조로 변환하고 원본 문서·블록·청크·인용의 연결을 유지하였다. 표 3.2는 단계 간 연결에 사용하는 핵심 데이터와 역할을 정리한 것이다.

Block은 11개 필드의 계약을 갖는다. 문서 ID와 블록 ID는 비어 있지 않아야 하고 읽기 순서는 0 이상의 정수이며 페이지는 정보가 있을 때 1부터 시작한다. 표 셀에는 표 ID와 행·열 값이 요구된다. 위치를 얻을 수 없는 경우에는 결측 상태로 유지한다. 이러한 구조 검사는 추출 텍스트가 존재하더라도 출처 연결이 손상된 결과를 다음 단계로 전달하지 않기 위한 것이다.

3.3.2 형식과 품질에 따른 Cascade 파싱

파싱은 Baseline, Challenger, Cascade의 세 프로파일로 구성하였다. Baseline은 기본 추출 경로, Challenger는 대안 추출 경로를 제공하고 Cascade는 문서 특성과 추출 품질에 따라 필요한 파서를 선택·보완한다. 세 프로파일은 같은 입력과 출력 계약을 사용하므로 이후 청킹·색인·검색 절차를 공통으로 적용할 수 있다. 파일 확장자만 따르지 않고 실제 형식을 확인하여 잘못된 확장자나 형식 불일치도 처리한다.

표 3.2. 문서 처리와 답변 근거를 연결하는 공통 데이터 구조

구조	핵심 필드	보존하는 정보와 활용
원본 문서	document_id, institution, source_title, source_url, source_sha256	문서의 소속·제목·원문 주소와 파일 무결성
Block 식별·내용	document_id, block_id, block_type, text	문단·제목·목록·표 등 추출 요소의 식별과 내용
Block 순서·위치	parser, reading_order, page, section_path	추출기, 읽기 순서, 페이지와 제목 계층
Block 표 구조	table_id, row, column	표와 셀의 관계 및 행·열 위치
검색 청크	chunk_id, doc_id, metadata.block_ids, 위치·출처 메타데이터	검색 단위와 그 내용을 구성한 원문 요소의 연결
주장·인용	text, supported, source_numbers, chunk_id, excerpt, excerpt_sha256	답변 문장의 판정과 출처 번호·발췌문·해시의 연결

Cascade의 PDF 처리는 PyMuPDF를 이용한 기본 텍스트 추출과 페이지 특성 확인에서 시작한다. Docling의 구조 추출 결과와 PaddleOCR 계열의 OCR 결과 중 페이지 특성에 맞는 결과를 선택·결합한다. 이는 페이지별 결과 채택 방식이며 외부 파서를 해당 페이지에만 호출한다는 의미는 아니다. pdfplumber의 표 추출 결과를 보완적으로 사용하고 품질이 부족한 경우 추가 추출 경로를 시도한다.

HWP/HWPX는 Java 기반 hwplib·hwpplib를 우선 사용하며 unhwplib와 Tika를 대안으로 둔다. HTML은 DOM 기반으로 본문을 추출하고 Office 문서는 형식별 전용 라이브러리와 XML 처리 경로를 사용한다. 추출된 블록에는 사용한 파서명을 남겨 문제가 발생한 문서가 어떤 경로를 거쳤는지 확인할 수 있게 하였다. 이후 추출 결과의 구조와 내용을 검사한다.

3.3.3 표·섹션 보존과 색인 허용 판정

청킹의 기본 상한은 1,800자이다. 일반 블록은 같은 섹션 안에서만 결합하고 표는 본문과 분리된 청크로 만든다. 하나의 원본 블록이나 표 행이 상한을 초과할 때에는 최대 250자의 중첩을 두고 나눈다. 중첩은 상한을 초과한 단위에만 적용한다.

긴 표는 행을 기준으로 분할하고 머리글 정보가 있으면 각 부분에 반복한다. 예를 들어 일정표의 두 번째 부분만 검색되더라도 해당 날짜가 신청 기간인지 납부 기간인지 구분하는 데 필요한 열 이름을 함께 제공하도록 한 것이다. 표 전체와 표 셀을 동시에 색인하여 같은 문구가 중복 검색되는 문제도 피하였다. 머리글 보존은 파싱 결과에 의존하므로 추출 단계의 품질도 함께 확인한다.

품질 검사는 파서 성공 여부, 스키마, 텍스트 길이, 제어문자와 문자 깨짐, 한국어 비율, 표 신호에 대응하는 표의 존재 및 읽기 순서를 바탕으로 정상·검토 필요·중대한 실패를 구분한다. Corpus Gate는 정상 결과를 기본 허용하며 검토 필요 결과는 명시적으로 허용한 실행 조건에서만 포함한다. 대표 시연 인덱스는 이 조건을 적용하되 중대한 실패는 제외하였다. 청크가 다른 문서의 블록이나 제외된 블록을 참조하면 색인을 중단하여 원문과 검색 단위의 연결을 검사한다.

3.3.4 실제 표의 원문·Block·청크 연결

그림 3.2은 「2026학년도 2학기 재학생 등록금 납부 계획」 1쪽의 신용카드납부 표를 처리한 실제 저장 결과이다. 무이자 할부기간은 농협은행 3개월, 부산은행 4개월, 하나은행 3개월이다. 세 `table_cell` Block에는 원문의 값과 `row=2, column=1·2·3`이 기록되어 있다. 행과 열 번호는 0부터 시작하며 같은 표 ID, 페이지, 절 경로를 공유한다.

검색 청크는 표 전체를 담은 `table` Block을 참조하며, 저장된 청크 본문과 표 Block의 본문은 일치한다. 표 ID와 1쪽이라는 위치 정보도 인덱스와 저장 검색 기록에 유지된다. 이 청크의 검색 위치는 표 단위이므로 셀 Block의 행·열 값이 그대로 답변의 셀 단위 인용이 되는 것은 아니다. 같은 문서의 다른 일정 표에서는 저장된 열 순서가 원문과 어긋난 사례도 확인되어, 위치 필드의 존재와 표 구조의 정확성은 구분하여 검수해야 한다.

1 원문 PDF의 표

2026학년도 2학기 재학생 등록금 납부 계획 · 1쪽 · 신용카드납부

구 분	농협은행	부산은행	하나은행
지정 카드	BC카드, NH카드	BC카드	BC카드, 하나카드
무이자 할부기간	3개월	4개월	3개월
최장할부기간	6개월	12개월	15개월



2 공통 Block 레코드: 표와 셀의 위치

page = 1 section_path = ["2. 신용카드납부"]
table_id = …:t0001 표 Block = …:b000032

셀 Block ID	row	column	text
…:b000042	2	1	3개월
…:b000043	2	2	4개월
…:b000044	2	3	3개월

row와 column은 0부터 시작하는 저장 값이다.



3 검색 청크: 표 본문과 원문 위치의 연결

chunk_id = …#0007 block_ids = […:b000032]
table_ids = […:t0001] page_start = page_end = 1

청크 본문 발췌 (첫째·셋째 줄, |는 탭 구분자 표시)

구 분	농협은행	부산은행	하나은행
무이자 할부기간	3개월	4개월	3개월

ID 앞부분 생략: doc_4ce82561e3e142c4f92fe306:casca

그림 3.2. 등록금 납부 안내의 원문 표·Block·검색 청크 연결

3.4 검색 후보 선정과 문맥 구성

3.4.1 BM25와 문서 다양성

검색 저장소는 SQLite 메타데이터 테이블과 FTS5 전문 검색 테이블로 구성하였다. BM25 검색에는 본문과 함께 기관명·파일명·문서 제목·분류·경로를 사용한다. 한국어 토큰에는 문자 bigram을 추가하여 표현 일부의 겹침도 검색 신호로 활용한다. 사용자가 기관을 지정하면 해당 범위에서 검색하며 한 긴 문서의 유사 청크가 상위 결과를 독점하지 않도록 문서별 청크 수를 제한한다. 대표 구성의 제한은 문서당 두 개이며 실행 설정으로 관리한다.

질문을 그대로 검색식으로 바꾸는 것만으로는 행정 문서의 표현 차이를 충분히 다루기 어려웠다. 서비스 경로에서는 질의를 정규화하고 선택적으로 관련 표현을 확장한다. 대화형 어미에서 파생된 정보량이 낮은 토큰과 일반 안내 문서 등의 잡음도 조정한다. 문서 제목의 연도와 질문의 연도가 충돌하는 후보를 구분하여 같은 단어가 많다는 이유만으로 다른 시기의 공고가 앞서는 현상을 완화하도록 하였다. 대표 규칙의 적용 범위는 3.9절에, 규칙을 묶어 적용한 검색 조건의 성능은 4장에 제시한다. 문자 bigram과 표현 확장은 일부 문자열 차이를 보완하지만 자동 오타자 교정기를 별도로 구현한 것은 아니다. 기관명·연도·자격 조건을 잘못 바꾸는 교정의 영향은 후속 평가가 필요하다.

3.4.2 복합 질문의 누락 근거 보완

검색된 문서가 정답 문서여도 생성기에 전달한 부분에 필요한 정보가 모두 있다는 보장은 없다. 예를 들어 신청 경로와 납부 기간을 함께 묻는 질문에서 상위 두 청크가 신청 경로만 반복하면, 문서는 찾았지만 질문의 절반에 필요한 근거가 빠진다. 이를 위해 질문이 요구하는 시간·금액·대상·절차 등의 항목을 확인하고 인접 문맥을 보완하는 단계를 두었다.

명시적인 복합 질문에서 같은 문서의 후보가 특정 항목을 중복 제공할 때에는 기여가 낮은 청크를 누락 항목의 인접 청크로 교체할 수 있다. 문서당 상한을 유지하며 질문과 인접 근거의 학년도·학기가 충돌하는 경우에는 교체하지 않는다. 이후 정확히 같거나 유사한 근거를 제거하고 요청한 수의 최종 문맥을 선택한다. 후보 검색, 인접 보완, 중복 제거를 구분하여 기록하므로 검색 실패와 문맥 구성 실패를 따로 진단할 수 있다.

Dense 단독 모드는 벡터 검색 결과를 사용하고, 하이브리드 모드는 BM25 점수와 벡터 유사도를 직접 더하지 않고 RRF로 두 검색 결과의 순위를 결합한다. 같은 청크는 검색기별로 한 번만 집계하고 검색기의 실패와 융합·재정렬 상태를 구분한다. 한국어 임베딩 기반 모드도 선택할 수 있도록 인터페이스를 마련했으나, 해당 인덱스의 준비 상태를 확인한 뒤 사용한다.

3.4.3 기관 필터와 역할의 구분

기관 필터는 검색 범위를 명시적으로 지정하는 기능이고 역할은 후보의 우선순위와 설명 관점을 조정하는 정보이다. 학생·행정직원·연구자 및 기관별 직원 프리셋을 정의하고 자유 역할 입력은 기관명과 신분 키워드에 따라 가장 가까운 프리셋에 매핑한다. 판단할 수 없으면 일반 사용자로 처리한다. 기관을 지정하지 않은 요청에서만 역할의 우선 기관을 후보 목록 앞으로 옮기며 다른 기관 후보를 삭제하지 않는다.

역할 입력은 서버에 미리 정의한 관점 문장으로 변환하여 생성 프롬프트에 전달하며, 원문에 포함된 임의의 지시의 삽입을 제한하였다. 역할은 확인된 사실을 어떤 관점에서 설명할지에 사용하며 사용자의 신분을 확인하거나 문서 접근 권한을 부여하는 인증 수단은 아니다.

3.4.4 최신성: 문서 시점 확인과 갱신 범위

본 시스템은 수집 시각을 보존하고 질문과 근거의 적용 시점이 충돌하는지 확인하는 방식으로 최신성을 다룬다. 수집 시각(`fetch_at`)과 게시 시각(`published_at`)은 별도 필드이며, 평가에 사용한 선별 manifest 2,260건에는 수집 시각이 모두 기록되어 있으나 게시 시각은 0건이다. 현재 선별기는 게시 시각을 자동 추출하지 않으므로 수집일을 게시일이나 최신 개정일로 해석하지 않는다.

문서 갱신은 수집·선별·파싱과 색인 생성을 명령으로 다시 실행하는 방식이다. 앞서 설명한 연도 충돌 후보 강등과 복합 질문의 학년도·학기 충돌 검사는 다른 시기 자료의 혼입을 줄이기 위한 규칙이다. 생성기에도 상충 자료를 임의로 최신이라고 판단하지 않도록 지시한다. 다만 규정의 개정일·시행일·효력 종료일과 개정본 간 관계를 관리하거나 변경을 주기적으로 감지하여 자동 갱신하는 기능은 구현하지 않았다. 제목의 숫자와 학년도를 잘못 해석한 사례는 4.5.3절에서 다룬다.

3.5 근거 기반 생성과 문장별 판정

3.5.1 질문별 요청·응답 계약

프론트엔드는 질문과 설정을 `POST /chat`에 JSON으로 전달하고 서버는 요청값과 준비 상태를 확인하여 인덱스와 생성기를 선택한다. 표 3.3는 주요 필드를 묶어 정리한 것이다. 화면의 답변과 근거 패널은 같은 응답을 사용하여 서로 다른 질문의 결과가 섞이지 않도록 하였다.

생성 프롬프트는 검색된 근거에서 직접 확인되는 사실만 사용하도록 구성하였다. 날짜·시간·금액·대상·신청 경로·예외 조건을 보존하고 여러 항목 중 일부만 확인되면 확인된 내용과

표 3.3. POST /chat의 주요 요청·응답 필드

구분	주요 필드	역할
요청: 질문·범위	question, institution, role	질문, 검색 기관, 답변 관점 지정
요청: 검색	top_k, parser_profile, retrieval_mode	근거 개수, 파서별 인덱스, 검색 방식 선택
요청: 생성	provider, model	생성 제공자와 허용된 모델 선택
응답: 답변	answer, cited_answer	일반 답변과 인용 번호가 연결된 답변
응답: 근거	claims, citations, results	문장별 판정, 인용 객체, 검색 근거 목록
응답: 진단	generator, generation, retrieval, postprocessing	사용 생성기, 생성·검색 진단과 후처리 정보

부족한 내용을 구분하여 답하도록 한다. 상충 자료가 있을 때 임의로 최신 문서라고 판단하지 않도록 명시하였다. 문맥 길이, 출력 토큰 수, 제공자별 제한시간과 전체 마감시간도 설정하여 요청 하나가 무한히 처리되지 않게 하였다. 현재 문맥과 출력 상한은 실행 설정으로 정하며 질문의 복잡도에 따라 입력·출력 토큰을 자동 배분하는 기능은 구현하지 않았다.

3.5.2 근거의 존재와 주장 지지 여부 분리

생성된 초안은 독립적인 주장 단위로 분리한 후 검색 원문과 대조한다. 각 주장에 어휘 겹침, 날짜·시간·금액 등의 중요 값, 대상과 조건, 허용·금지 및 이상·이하 등의 관계 규칙을 적용한다. 숫자가 근거 어디엔가 등장한다는 이유만으로 해당 문장을 지지된 것으로 판단하지 않도록 대상과 값의 연결도 제한적으로 확인한다. 현재 처리 상한은 여덟 주장이고 상한 때문에 잘린 수를 메타데이터에 남긴다.

지지되는 문장에는 최대 두 근거 청크를 연결하고 최종 답변을 재구성한다. 인용 번호는 생성 모델이 임의로 붙이는 방식이 아니라 서버가 근거 판정 결과에 따라 부여한다. 인용에는 원문 발췌, 청크·문서 ID와 페이지·섹션 등 위치를 함께 반환한다. 하나의 청크가 여러 블록을 포함하면 복수 위치가 연결될 수 있으므로 화면의 여러 위치 표시를 서로 독립적인 문서 수로 해석하지 않는다.

이 판정은 학습된 자연어 추론 모델이 아닌 규칙 기반 보조 장치이다. 응답의 신뢰도 값도 보정된 정답 확률이 아니라 내부 점수이다. 올바른 의역이 배제되거나 복잡한 예외 관계가 누락될 가능성이 있으므로 출처 표시 자체를 정확성 보증으로 제시하지 않는다. 최종 답변뿐 아니라 원문과 판정 이유를 함께 제공하여 사용자가 문장의 적용 대상을 비교할 수 있게 하였다.

3.6 생성 전후 보안 검사

문서 품질을 판단하는 Corpus Gate와 별도로 검색 문맥의 지시와 출력 인용을 검사하는 두 보안 계층을 구현하였다. 이 절은 저장소에 병합된 보안 버전을 기준으로 하며 앞선 성능 비교의 동결 코드 및 결함을 보완한 별도 실험 사본과 구분한다. 공식 문서에서 수집되었다는 사실만으로 문서 안의 모든 문자열을 모델이 따라야 할 지시로 취급하지 않는 것이 설계 목적이다.

생성 전 Context Gate는 최종 검색 후보의 본문 또는 미리보기에서 모델 지시 변경, 비밀 출력, 도구 실행, 인용 조작 등의 패턴을 검사한다. 전각 문자 등을 NFKC로 정규화하고 Unicode 서식 제어문자를 제거하여 단어 사이의 보이지 않는 문자로 탐지를 피하는 일부 변형도 처리한다. 탐지 점수가 0.85 이상인 높은 신호는 제외하고 그보다 낮은 탐지 신호는 생성용 사본에서 정제한다. 정제 후 같은 규칙에 다시 걸리면 제외한다. 기존 메타데이터에 원본 검증 실패나 악성 검사 실패가 기록된 경우도 제외하지만 이 계층이 별도 악성코드 검사를 수행하는 것은 아니다.

생성용 문맥과 검증용 문맥은 분리하였다. 허용된 문서의 원문은 인용 검증에 유지하고 생성기에는 정제된 사본을 전달한다. 제외된 문서는 두 목록에서 모두 제거하며 남은 근거에 같은 순서로 번호를 부여한다. 모든 후보가 제외되면 생성기를 호출하지 않고 확인 불가 응답을 반환한다. 프롬프트에서는 검색 자료를 비신뢰 문맥으로 구획하여 문서 내용과 시스템 지시를 구분한다. 검사 결과에는 허용·정제·제외 수와 사유를 기록한다. 관측 모드는 판정만 남기고 문맥을 바꾸지 않으며 입력 검사 비활성화 설정도 출력 검사와 프롬프트의 경계 표시까지 해제하는 것은 아니다.

생성 후에는 문장별 근거 판정을 거친 응답에 Output Gate를 적용한다. 인용의 청크 ID가 허용된 원문에 존재하는지, 정수형 출처 번호가 같은 청크를 가리키는지, 발췌문과 저장된 SHA-256이 일치하는지 검사한다. NFKC와 공백 정규화 후 발췌문이 원문에 포함되는지도 확인한다. 주장·인용 목록의 형식이 잘못되거나 유효하지 않은 인용이 있으면 답변을 보류하고 인용 목록을 비운다. 지지된 문장 비율에 따라 전체 답변·부분 답변·보류 상태를 구분한다. 이는 출처 연결의 무결성 검사로, 인용문의 의미가 질문에 맞는 결론인지까지 새로 추론하지는 않는다.

병합본 검토에서는 무관한 금지 문장이 공격 탐지를 면제하는 문제, 파일명·절 제목 등 생성 메타데이터의 검사 누락, 인용기의 페이지 표시 제거와 출력 검사의 정규화 불일치가 확인되었다. 별도 수정 사본은 예외를 해당 문장·절로 좁히고 생성기와 게이트의 공통 필드 추출을 적용하였다. 출력에서는 원문 측 페이지 표시 정규화와 공백뿐인 인용의 거부를 보완하였다.

생성용 문맥과 검증용 원문의 분리




그림 3.3. 생성용 정제 사본과 검증용 원문을 분리하는 보안 검사 흐름

이 수정 결과를 병합본의 기능이나 배포 실적으로 포함하지 않으며 규칙에 없는 우회 표현과 정상 문서의 오탐 가능성을 남은 한계로 다룬다.

3.7 실제 질의의 검색·답변·인용 흐름

3.7.1 대학생활원 공지 확인 사례

구현된 흐름은 “2026학년도 2학기 대학생활원 공지는 어디서 확인하고 개별 문자도 보내줘?” 라는 질의로 확인할 수 있다. 이 사례는 2026년 9월 9일 보안 병합 구성을 사용한 정상 질의의 실제 생성 기록이며 Gemini 3.5 Flash-Lite 호출에 성공하고 추출형 대체 응답은 사용하지 않았다. 그림 3.4은 해당 응답을 현재 프론트엔드의 격리 사본에 표시한 화면이다. 답변과 근거는 저장 기록을 그대로 사용했으며, 화면 캡처를 위한 재현은 새로운 생성 실험과 구분한다.




그림 3.4. 현재 사용자 화면에 표시한 저장 질의와 인용 답변

요청에는 Cascade 파서와 BM25 검색이 사용되었다. 검색 기록에서 BM25 후보는 31개이며 Dense와 재정렬은 비활성 상태였다. 문맥 중복 제거 단계는 후보 31개 중 정규화 후 같은 내용인 일곱 개를 중복으로 판정하고 최종적으로 일곱 문서의 여덟 청크를 선택하였다. 고유 후보 24개 중 16개는 최종 문맥에 포함되지 않았다. Context Gate는 여덟 개를 검사하여 모두 허용했고 정제·제외는 발생하지 않았다. 그림 3.5은 이 단일 질의의 단계별 기록이며 단계별 성능이나 평균 처리량을 나타내지 않는다.

첫 번째 근거는 「2026년도 2학기 대학생활원 부산캠퍼스 비원생 모집요강.pdf」의 19쪽, ‘1. 공지관련 사항’ 이다. 원문에는 부산 대학생활원 홈페이지 공지사항, 각 동 게시판, 대학

질의 요지: 대학생활원 공지 확인 방법과 개별 통보 여부



단일 질의의 저장 진단 기록이며, 성능 개선율이나 전체 정확도를 나타내지 않는다.

그림 3.5. 대학생활원 질의의 검색 후보 축소와 최종 검증 기록

생활원 앱으로 공지를 확인하며 개별 통보는 하지 않는다고 명시되어 있다. 이어 전용 앱을 내려받아 공지사항을 확인하라는 안내가 있다. 같은 모집요강의 다른 청크와 HWP 자료도 함께 검색되어 관련 안내를 제공하였다.

생성 결과는 공지 확인 경로, 개별 통보 여부, 앱 설치 안내의 세 문장으로 정리되었다. 서버는 첫 문장과 세 번째 문장에 출처 [1]·[2], 두 번째 문장에 [2]·[3]을 연결하였다. 세 주장 모두 근거 판정을 통과했고 Output Gate는 잘못된 인용을 발견하지 않아 전체 답변 상태를 반환하였다. 이 사례에서 검색·생성·인용 연결이 동작함을 확인하였다.

3.7.2 출처를 확인하여 적용 범위 판단

그림 3.6는 같은 저장 응답의 근거 패널에서 세 보기를 발췌한 것이다. 사용자는 문장의 출처 번호를 눌러 문서명과 원문 일부, 페이지 및 섹션을 확인할 수 있다. 근거 화면에서 ‘19쪽’과 ‘1. 공지관련 사항’은 추출 단계에서 보존한 위치 정보가 인용과 화면까지 전달된 결과이다. 표시된 검색 점수는 해당 검색기의 내부 관련도 점수이며 답변이 맞을 확률로 해석하지 않는다. 원문 주소를 열어 게시물과 첨부파일을 추가 확인할 수도 있다.

이 사례에서 확인해야 할 범위는 ‘공지와 지원 일정의 개별 통보’이다. 같은 발췌문 뒤에는 별점 관련 카카오톡 알림 또는 문자 부가서비스가 별도로 설명되어 있으므로 이를 대학생활원의 모든 문자 서비스가 없다는 의미로 확대하면 안 된다. 시스템은 공지 전달 방식을 안내하며 실제 문자 발송을 수행하지 않는다. 질문의 표현을 답변으로 요약한 뒤에도 사용자가 원문의 대상과 예외를 확인할 수 있어야 한다.



그림 3.6. 현재 근거 패널의 검증·문서·위치 보기

3.8 사용자 인터페이스와 실패 대응

3.8.1 질문 작성에서 근거 확인까지

현재 프론트엔드는 질문 작성과 답변 읽기를 중심으로 구성하고 대화 기록, 모델·역할·검색 설정을 분리하였다. 추천 질문을 누르면 기관과 질문 초안이 입력되며 사용자는 자신의 학년도나 조건에 맞게 수정한 후 전송한다. 연결이 준비되지 않은 동안에도 초안은 작성할 수 있고 서버·파서·검색 방식의 준비 상태에 따라 전송 가능 여부를 표시한다. 선택 가능한 이름이 존재하는 것만으로 실제 인덱스나 모델이 준비되었다고 간주하지 않는다.

답변은 Markdown의 목록·표·강조를 유지하여 보여준다. 실제 근거에 대응하는 인용 번호만 클릭 가능한 버튼으로 변환하고 코드와 기존 외부 링크 안의 문자열은 중첩 버튼으로 만들지 않는다. 원격 이미지와 HTML 실행을 제한하여 답변을 읽는 과정에서 임의 콘텐츠가 실행되거나 추적 이미지가 로드되는 경로를 줄였다. 답변 복사·재생성·근거 열기와 최신 답변으로 이동을 지원한다.

근거 화면은 검증·문서·위치의 세 보기로 구성하였다. 검증 보기에는 문장별 지지 여부와 연결 출처를, 문서 보기에는 기관·제목·발췌문·원문 및 첨부 링크를, 위치 보기에는 페이지·섹션·표의 행과 열을 표시한다. 행·열의 내부 0부터 시작하는 값은 화면에서 1부터 시작하는 번호로 변환한다. 위치 정보가 없을 때는 값을 꾸며 내지 않으며 여러 위치가 있는 경우 표시

수와 추가 위치 수를 구분한다. 앞 절의 화면은 이 프론트엔드에 저장 응답을 표시한 것으로, 답변과 근거 연결을 확인하는 예시이다.

3.8.2 대화 기록과 요청 일관성

최근 30개 대화를 브라우저에 저장하여 검색·전환·삭제·되돌리기할 수 있게 하였다. 새로고침 후에는 저장 데이터의 타입과 중복 ID를 검사하여 질문·답변·근거를 복원한다. 여러 탭이 동시에 저장할 때에는 Web Locks로 순서를 조정하고 메시지 ID와 삭제 상태를 반영하여 늦게 도착한 저장이 삭제한 대화를 다시 만드는 문제를 방지하도록 하였다. Web Locks를 사용할 수 없거나 저장에 실패하면 안내를 표시하고 현재 대화는 메모리에 유지한다.

이 기록은 해당 브라우저의 localStorage에 저장되며 계정이나 다른 기기로 동기화되지 않는다. 서버에는 질문별 독립 요청을 전달하며, 이전 대화 문맥을 합치는 다중 턴 처리는 지원하지 않는다. 재시도와 재생성에는 원래 질문의 기관·역할·제공자·모델·파서·검색 설정을 보존하여 사용자가 다른 설정을 선택한 뒤 과거 답변을 다시 생성하더라도 요청 조건이 임의로 바뀌지 않도록 하였다.

3.8.3 취소·연결 오류·근거 부족의 처리

전송 중에는 중복 요청을 막고 중지 버튼을 제공한다. 취소 시 브라우저 요청을 중단하고 이전 요청의 지연 응답이 현재 대화를 갱신하지 않도록 요청 식별 상태를 확인한다. 이는 화면의 비동기 일관성을 위한 처리이며 외부 제공자가 이미 시작한 생성 작업의 즉시 종료가 비용 취소를 보장하는 것은 아니다. 관리자 권한으로 서버의 신규 요청을 차단하고 대기 작업을 취소하는 비상정지·복구 기능은 현재 구현 범위에 포함하지 않았다. 연결 오류에는 오류 메시지와 재시도 가능 여부를 표시한다. Enter 전송, Shift+Enter 줄바꿈, 한글 조합 중 오전송 방지, 모달의 Escape 닫기 및 근거 탭의 방향키 탐색도 구현하였다.

서버에서 검색 결과가 없거나 지지되는 문장이 없으면 확인 불가 상태를 반환한다. 생성 API의 오류나 시간 초과에는 추출형 응답으로 전환할 수 있으며 특정 네트워크 제공자를 명시한 경우에는 해당 제공자와 추출형 대체 경로만 사용한다. 자동 선택은 서버 설정의 순서를 따른다. 대체 응답의 사용 여부와 사유를 메타데이터로 남겨 정상 생성과 구분한다. 요청 크기·질문 길이·검색 개수·동시 생성 수를 제한하고 허용 Origin 검사와 설정된 경우의 토큰 인증을 적용하였다.

화면 검증에서는 손상된 저장 데이터, 취소와 지연 응답, 여러 탭의 동시 조작, 긴 답변과 좁은 화면을 확인하였다. 회귀 테스트와 접근성 검사 기록은 이러한 사용 흐름의 증거로 활용한다. 다만 프론트엔드 검증에는 로컬 API 대역이 사용되었으므로 실제 생성 품질과 운영 배포 결과는 별도의 근거로 다룬다.

3.9 규칙 기반 처리의 항목과 적용 범위

본 시스템은 생성 모델만으로 답변을 처리하지 않는다. 사람이 정한 조건에 따라 검색 결과를 조정하고 생성 문장을 검사하는 규칙 기반 처리를 함께 사용한다. 예를 들어 질문이 2026년 일정인데 문서 제목이 다른 연도를 가리키면 검색 순위를 낮추고, 답변의 금액이 인용 근거에 없으면 해당 문장을 보류한다. 규칙은 잘못된 답변을 줄일 수 있지만, 올바른 문서나 문장까지 제외할 수 있다.

2026년 9월 4일의 검색·생성·근거 판정 코드를 기능별로 묶은 목록은 68개 규칙군이다. 이는 정규식 개수나 실행 횟수가 아니라 같은 판단 목적을 가진 조건 묶음의 수다. 표 3.4는 전체 세부 규칙을 나열하지 않고 범주와 대표 동작을 요약한다.

표 3.4. 검색·생성·근거 판정 규칙군의 구성과 대표 동작

범주	규칙군 수	대표 조건과 동작
검색어 정리·순위·중복	9	정보량이 낮은 표현을 정리하고 연도 충돌 후보를 낮춤; 문서별 체크 상한 적용
질문 의도별 검색어 확장	8	D2 비자 관련 질문에서 예약·제출서류·수수료 등 검색 표현 추가
질문 항목·인접 근거 보완	14	기간·금액·대상 등 누락 항목을 같은 문서의 다른 체크에서 보완
생성 지시·내용 점검 항목	18	한 문장에 근거를 연결하고 질문의 여러 요구 항목을 빠뜨리지 않도록 모델에 지시
문장 근거·인용 판정	19	날짜·금액 등 핵심값과 허용/금지·이상/이하 관계를 대조하고 지지되지 않는 문장 제외
합계	68	보안 지시 탐지·URL 검사·파서 선택 규칙은 이 집계에서 제외

범용 처리는 21개, 개발용 질문이나 행정 의도에 맞추어 추가한 처리는 47개였다. 생성 지시 범주의 규칙은 모델에게 주는 작성 지침이며, 코드가 반드시 강제하는 검사와도 구분한다. 분류 기준과 원래 규칙 목록의 저장 위치는 동봉 자료에 기록하였다.

별도의 보안 규칙은 문서 속 역할 변경·이전 지시 무시·비밀 공개 유도 등을 검사하고, 인용 검사는 출처 번호·문서 조각 ID·발췌문·해시가 연결되는지 확인한다. 이들의 실행 결과는 4.6절에 문서 제외율과 공격 표식 출력률로 보고한다. 특정 탐지 규칙 하나가 차단한 비율은 중복 적용을 분리해 기록하지 않아 산출하지 않았다.

C0와 C1의 차이는 검색 조정의 사용 여부이며 모든 68개 규칙을 한꺼번에 켜고 끈 비교가 아니다. 생성 지시와 출력 검사는 두 조건에 공통으로 남는다. 따라서 C0·C1의 차이를 개별 규칙의 효과나 전체 규칙 기반 처리의 효과로 해석하지 않는다. 개별 효과를 알려면 한 규칙씩 제외하고 다시 비교하는 추가 실험이 필요하다.

3.10 대표 설계 변경과 구현상의 판단

개발 과정에서는 단계별 출력과 실패 사례를 추적하여 문제를 수정하였다. 첫째, 문서를 블록·표·위치의 공통 구조로 표현하였다. 이를 통해 파서 교체와 표의 행 단위 청킹을 공통 처리로 연결하고 최종 인용에서 페이지와 섹션을 표시할 수 있게 하였다. 수집 선별과 Corpus Gate는 검색에 사용할 자료의 범위와 품질을 검사하도록 분리하였다.

둘째, 정답 문서가 검색되어도 필요한 날짜·대상·절차가 최종 문맥에 빠지는 문제에 대응하였다. 일반 안내와 연도 불일치 후보를 조정하고 복합 질문에서 누락된 항목의 인접 청크를 선택하도록 하였다. 문서별 상한과 중복 제거를 유지하면서 누락 근거를 보완하였다. Dense와 RRF 등 대안은 비교 가능한 경로로 남기고 대표 서비스는 확인된 BM25 구성으로 제시하였다.

셋째, 생성 모델이 올바른 내용을 작성했더라도 후처리가 이를 훼손하는 사례를 수정하였다. 초기 문장 분리는 ‘2026. 8. 24.(월)’ 같은 날짜를 마침표에서 나누고 짧은 문장 필터는 ‘학부 등록금은 동결되었습니다.’와 같은 완전한 사실도 제거할 수 있었다. 점 표기 날짜를 문장 분리 전에 보호하고 생성 초안의 짧은 문장 기준을 별도로 조정하되 추출형 후보의 짧은 필터는 유지하였다. 허용·금지 및 이상·이하 관계가 뒤집힌 문장을 거부하는 규칙과 공식 메뉴 경로의 올바른 의역을 보존하는 제한적 규칙도 보완하였다.

넷째, 문서의 지시와 시스템의 지시를 구분하기 위해 생성 전 보안 검사와 생성 후 인용 검사를 추가하였다. 이후 발견된 예외 처리와 메타데이터 검사 문제는 별도 수정 사본에서 다루어 변경 범위를 추적하였다. 다섯째, 대화 저장 실패, 탭 간 삭제, 취소 뒤 지연 응답을 회귀 검증에 포함하였다. 이러한 변경의 성능 효과는 검색 평가, 동일 초안 재처리, 실제 생성 및 보안 실험을 구분하여 다음 장에서 분석한다.

3.11 구성원 역할 및 수행 일정

본 과제는 3인 팀으로 수행하였다. 검색·리랭킹·생성 모델의 병렬 실험과 비교를 공통 업무로 두었으며, 최종심사표에 기재한 구성원별 주담당 업무는 다음과 같다.

표 3.5. 구성원별 주담당 업무

구성원	학번	주담당 업무
이현우	202155596	1) 문서 수집·파싱·검색·답변 생성 파이프라인 설계 2) 답변 정확성·근거 일치 여부 평가용 LLM Judge 설계·실험 3) BM25 RAG API 구현, React 연동 및 배포
황지완	202155627	1) 문서 파싱·RAG·평가 방법 관련 논문 조사 및 비교 2) 대학·공공기관 문서 수집, HWP/PDF 파싱 및 청킹 3) 문서 최신성 확인 및 적대적 공격 평가
정지인	202355709	1) 생성 전 문맥 검사·생성 후 인용 검증을 위한 보안 레이어 탑재 2) RAG·보안 벤치마크 조사, 평가셋과 실험 조건 설계 3) 출처 검증 UI/UX 구성 및 보고서·발표 자료 정리

프로젝트의 실제 작업 기록에서 확인되는 주요 수행 과정과 일정을 월 단위로 정리하였다.

표 3.6. 월별 주요 수행 일정

시기	주요 수행 내용
2026년 6월	기관 문서 수집 및 초기 자료 통합
2026년 7월	문서 변환·파싱, 구조 보존 방식 조사, 부산대학교 문서 색인과 BM25 기반 질의응답 시연 구성
2026년 8월	연구비 규정 실험의 검색·리랭킹·생성 품질 비교, 부산대학교 실서비스 경로를 대상으로 한 평가 기반 구축
2026년 9월	검색·답변 생성 결과 분석, 생성 전후 보안 계층 통합과 파일럿 평가, 대화 이력 및 문서 출처 확인을 위한 사용자 화면 개선

제4장 연구 결과 분석 및 평가

4.1 평가 목적과 실험 구성

평가는 문서 처리·검색·생성·보안의 작동과 최종 답변 오류의 발생 단계를 확인하는 데 목적이 있다. 문서 적중, 필수 근거 회수, 답변의 완전성과 인용 적합성을 각각 측정하였다.

정량 평가는 2026년 9월 14일까지 완료된 실험 기록을 대상으로 한다. 검색 조건을 탐색한 개발셋 평가, 출처를 분리한 합성 진단, 보안 파일럿, 그리고 개발에 사용하지 않은 holdout의 최종 평가는 서로 다른 실험이다. 각 실험에서 고정한 문서 집합, 모델 및 평가표를 기준으로 결과를 해석하였으며 조건이 다른 수치를 동일 실험의 전후 결과로 합치지 않았다.

DEV45는 본 과제의 서비스 개발을 위해 구성한 45문항으로, 9개 행정 영역의 기본 질문 39개와 역할 조건을 추가한 변형 6개로 이루어진다. 각 문항에는 질문·영역·역할·정답 문서와 기대 근거를 기록하였다. 검색 규칙의 진단과 수정에 반복 사용한 개발셋이며, 기본 질문과 역할 변형은 같은 질문군으로 묶어 분석하였다.

표 4.1. 주요 평가의 목적과 조건

평가	시점	표본·비교 조건	생성·반복
파서 감사	9월 1일	18문서·54근거, 파서 3종	생성 없음
DEV 검색	9월 2일	45문항, 파서·검색 8조건	추출형, 조건별 1회
DEV 생성	9월 4일 완료	45문항, C0·C1	조건별 독립 생성 3회
C2 탐색	9월 4일	45문항, 저장 C1 문맥 재사용	C2 응답 3회, 일부 재처리
DEV 후속 검색	9월 4일	같은 45문항, 의도별 검색 보완	추출형, 1회
Shadow 검색	9월 4일	60문항, C0·C1	추출형, 조건별 1회
Shadow 생성	9월 5~6일	같은 60문항, C1	독립 생성 3회
보안 파일럿	9월 9일	정상 14·공격 10·대조 10, 3조건	생성·판정 각 1회
최종 holdout	9월 14일	핵심 27문항 C0·C1, 도전 9문항 C1	조건별 독립 생성 3회
사람 검수	9월 14일	holdout 첫 회차 답변 62개, 개발자 1인	생성 없음, Judge와 일치도 비교

C0는 검색 튜닝을 끈 Cascade BM25 기준선, C1은 검색 튜닝을 적용한 서비스 조건이다. 동일한 명칭이라도 실험별 코드와 평가셋 버전이 다르므로 실행 기록을 구분한다. DEV 생성 비교는 9월 3일자 실험 조건을 고정하여 9월 4일 세 번의 생성을 완료한 결과이며 이후 의도별 검색 보완까지 반영한 재평가가 아니다. C2는 별도 생성 실험으로 실제 서비스에는 채택하지 않았다.

검색 비교는 로컬 서비스의 동일한 요청 경로를 사용하였다. 기본 설정은 상위 문맥 8개와 문서당 청크 2개이며 9월 4일 후속 검색에서는 명시적으로 세 부분을 묻는 일부 질의에 한해 동일 문서의 세 번째 청크를 허용하였다. 검색만 평가할 때는 추출형 응답을 사용하여 외부 생성 모델을 호출하지 않았다.

표 4.2. 평가 지표와 해석

지표	정의	측정 대상
문서 적중률 Hit@k	상위 k개에 정답 문서가 있는 질문 비율	관련 문서 발견
MRR@5	5위 이내 첫 정답 순위의 역수 평균	정답 문서 순위
Any Gold@k	지정 정답 청크를 하나 이상 회수한 비율	부분 근거 회수
All Gold@k	지정 정답 청크를 모두 회수한 비율	청크 집합 회수
필수 근거 회수율	질문의 필수 사실별 근거 회수 정도	답변에 필요한 근거
Judge 평균	본 과제의 평가표에 따른 0-2점 평균	답변 품질의 보조 지표
GFC	내용·근거·인용 조건을 모두 충족한 답변 비율	근거 충족 완전정답률

0~2점 평가는 핵심 사실이 모두 정확하면 2점, 답변의 방향은 맞지만 핵심 누락이나 부분 오류가 있으면 1점, 결론 오류·중대한 근거 부재·무관한 답변이면 0점으로 판정한다. 답변 가능한 질문의 명확한 회피는 0점이지만, 답변 불가 또는 범위가 모호한 질문의 적절한 회피·재질문은 문항별 기준을 충족하면 2점일 수 있다. Judge v11은 이 평가 규약을 적용한 과제 내 자동 채점기의 버전명이다.

GFC는 2점 답변 중 내용·근거·인용 조건을 모두 충족한 경우에만 인정한다. 모든 필수 사실을 정확히 포함하고 검색 문맥이 각 사실을 지지하며 필요한 인용이 해당 근거를 가리켜야 한다. 잘못된 날짜·금액·조건, 근거 없는 추가 사실, 모순 또는 답변 가능한 질문에 대한 과도한 회피가 있으면 실패로 판정한다. DEV45·C2·Shadow는 3회 중 2회 이상 GFC인 문항 비율을, holdout은 예정 응답 기준 비율과 다수결 문항 비율을 보고한다. 반복 답변을 독립 질문으로 세지 않는다.

4.1.1 Q&A 평가셋의 출처와 구성

본 과제의 Q&A는 외부에서 내려받은 공개 질의응답 벤치마크가 아니라, 수집한 부산대학교 공식 문서에서 질문과 기대 답변·근거를 구성한 자체 평가셋이다. 실제 이용자의 상담

기록으로 간주하지 않는다. 문서의 작성 기관은 부산대학교의 각 담당 부서 및 원 공고 기관이며, 질문·평가 기준은 본 과제의 평가 산출물이다. 따라서 문서 출처와 Q&A 구성 주체를 구분한다.

표 4.3. 자체 Q&A 평가셋의 규모·출처·사용 목적

집합	문항	원문 파일	구성과 사용 범위
DEV45	45	39개	9개 행정 영역의 기본 질문 39개와 역할 변형 6개; 개발 중 반복 사용
Shadow60	60	42개	핵심 42·역할 변형 8·도전 10; DEV와 출처를 분리한 합성 진단, 독립 사람 검수 없음
최종 holdout	36	27개	핵심 27·도전 9; 개발에 쓰지 않은 질문과 정답 근거를 개발자 1인이 확인

파일 해시를 재대조한 결과 DEV와 Shadow, DEV와 최종 holdout의 원문 중복은 각각 0개였다. 다만 최종 holdout의 27개 원문 중 9개(33.3%)는 앞선 Shadow 진단에서도 사용되었다. 질문 문구는 다르지만 일부 질문은 주제와 필요한 사실도 겹친다. 따라서 최종 평가셋을 완전히 새로운 문서와 사실만으로 구성한 독립 표본으로 해석하지 않는다.

표의 원문 파일 수는 각 평가셋에서 근거로 지정한 파일의 서로 다른 SHA-256 수다. 답변 불가·범위 모호 문항은 정답 문서를 찾는 대신 회피·재질문 행동을 평가하므로 긍정 답변용 근거가 없을 수 있다. 각 집합의 JSONL 파일 크기는 개정 DEV45 67,119바이트, Shadow60 261,344바이트, 최종 holdout 133,572바이트이며 문서 코퍼스의 용량과 구분한다.

평가 문항에는 질문, 행정 영역, 역할 조건, 기대 답변 또는 필수 사실, 원문 인용을 저장하였다. 필수 사실은 답변에 반드시 있어야 하는 내용으로, 예를 들어 “자동 수강신청의 조건”과 “정원을 넘었을 때의 조치”를 각각 기록한다. DEV의 문항 ID는 별도 출처 목록과 연결하고, Shadow와 holdout은 문항 내부의 근거 항목에 제목·주소·파일 식별값을 기록하였다.

대표 출처는 다음과 같다. DEV의 등록금 문항은 부산대 공지 「2026학년도 2학기 재학생 등록금 납부 계획」의 PDF를 사용하였다[10]. Shadow의 취업 지원 문항은 취업전략과 게시판에 첨부된 「2026 금정 청년 구직응원 패키지 지원사업 대상자 모집 공고」 HWP에서 구성하였다[11]. 최종 holdout의 자동 수강신청 문항은 입학처 게시물의 국문 안내 PDF를 근거로 삼았다[12]. 출처 URL은 원 게시물 또는 안내 페이지를 가리키며 첨부파일의 제목·원본 경로·해시로 실제 사용한 파일을 구분한다.

동봉한 supplement/qa-source-map.csv에는 141문항 전체의 문항 ID, 질문, 공식 출처 URL, 제목, 원본 파일 경로와 해시를 수록하였다. 평가용 JSONL 세 파일도 함께 제공한다. DEV 출처 목록은 최초 평가셋에서 작성되었으므로 개정본의 같은 문항 ID와 대조해 연결하

였다. 최종 holdout 파일에 남은 초안 상태 표시는 검수 완료 여부로 사용하지 않으며, 별도로 보존한 최종 검수 승인 기록을 기준으로 한다.

4.1.2 실험 기록과 재현 조건

실험 결과를 추적할 수 있도록 실행 식별자, 코드·평가셋·코퍼스·인덱스의 식별 정보, 생성·채점 설정과 결과 파일의 위치를 LaTeX 원고에 동봉한 REPRODUCIBILITY.md와 evaluation-records.json에 정리하였다. 경로는 프로젝트 저장소를 기준으로 한 상대 경로이며, SHA-256은 파일 내용이 같은지 확인하는 식별값이다. 실행 당시에 기록된 값과 보고서 정리 시점에 계산한 값을 구분하였다. 원자료와 인덱스는 별도 보존 자료이므로, 원고 ZIP만으로 실험 전체를 다시 실행할 수 있는 것은 아니다.

주요 생성 비교의 기록은 dev45-generation-current-v1이다. 당시 서비스에는 저장소에 확정하지 않은 수정이 포함되어 있었다. 서버 파일 하나의 식별값은 남아 있지만 전체 코드의 동일성을 보장하는 값은 아니다. 해당 커밋과 파일 해시는 동봉한 재현 정보에 기록하였다. 답변·판정과 평가셋·인덱스의 연결은 저장 해시로 확인했지만, 당시 수정 사항 전체에 대응하는 코드 사본은 확인하지 못하였다. 따라서 저장 결과의 재집계와 동일 코드에서의 재실행은 구분한다.

보안 파일럿은 보안 적용 전·병합 보안본·수정 사본의 코드를 각각 보존하였다. 세 코드 사본의 파일 목록과 식별값을 동봉한 기록에 수록하여 어떤 보안 조건을 실행했는지 구분하였다. 생성 모델의 응답은 같은 설정에서도 달라질 수 있으므로, 재현 확인에서는 저장 답변의 재집계와 새 답변 생성의 변동을 함께 고려해야 한다.

4.2 코퍼스 구축과 파서 평가

4.2.1 코퍼스 구축 결과

초기 수집 완료량은 웹페이지 7,775개와 첨부파일 3,202개를 합한 10,977개, 5,834,477,829바이트(약 5.83GB)였다. 서비스 범위·형식·무결성·중복 기준을 적용한 뒤 2,260개 문서, 473,678,602바이트(약 473.68MB)를 선별하였다. 최종 문서 수는 완료 항목의 20.6%이며 선별 과정에서 내용이 같은 중복 항목 118개를 제외하였다. 여기서 GB와 MB는 각각 10억 바이트와 100만 바이트 단위다. 수집 기록에는 대기 및 오류 항목도 남아 있으므로 대학 웹 전체를 완전하게 수집한 것으로 해석하지 않았다.

선별 문서는 HTML 1,646개(72.8%), HWP와 PDF 각각 278개(각 12.3%), DOCX와 XLSX 각각 23개(각 1.0%), 기타 형식 12개(0.5%)였다. 기타는 PPTX 4·DOC 3·HWPX 2·XLS 2·TXT 1개다. 수집 기록에는 대기 2,244개, 오류 141개와 제외 1,460개도 남았다. 9월

표 4.4. 데이터 처리 단계별 산출물

단계	결과	단위·비고
초기 수집 완료	10,977	웹페이지 7,775·첨부파일 3,202; 약 5.83GB
선별 문서	2,260	완료 항목의 20.6%; 약 473.68MB
파싱 성공	2,247	선별 문서 2,260개 중 99.4%
파싱 청크	44,591	품질 기준 적용 전
추출 표	7,813	파싱 산출물
검색 인덱스	44,520	품질 기준 적용 후 청크

22일 원본 경로 2,260개를 다시 확인한 결과 파일 누락이나 기록 크기와 실제 크기의 불일치는 없었다. 파싱에 성공하지 못한 입력은 오류 8개, 빈 결과 1개, 미지원 형식 4개였다. 파싱 산출물과 서비스 인덱스의 청크 수 차이 71개는 품질 기준 적용 과정에서 제외된 것이다. 처리 성공은 모든 내용이 정확하게 추출되었다는 의미와 구분하였다.

4.2.2 형식별 근거 보존

파서의 목적은 원문의 날짜·수치·절차·표 관계를 검색 가능한 형태로 보존하는 것이다. 이를 확인하기 위해 HWP/HWPX, 일반 PDF, OCR·표 중심 PDF에서 각각 6개 문서를 선택하고 문서당 3개 근거, 총 54개를 검사하였다. 세 파서는 같은 원문 집합을 사용하였다. 문자열의 공백·구분자 차이를 정규화한 뒤 문자·숫자·순서가 유지되는지를 판정하였다.

표 4.5. 표적 문서의 근거 보존 결과

파서	전체 근거 / 54	세 근거 보존 문서 / 18	HWP 계열 / 18	일반 PDF / 18	OCR·표 PDF / 18
Baseline	48 (88.9%)	14 (77.8%)	18 (100.0%)	17 (94.4%)	13 (72.2%)
Challenger	54 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)
Cascade	54 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)

Baseline에서 손실된 근거에는 등록 기간 표의 행 관계, OCR 절차, 교육과정 정의와 지급 한도 표 관계가 포함되었다. Challenger와 Cascade는 선정한 54개를 모두 보존하였다. 다만 알려진 실패 유형을 고려한 표본이고 Cascade 결과를 근거 연결의 기준으로 사용했으므로, 전체 코퍼스의 파서 정확도나 두 개선 파서 사이의 우월성으로 해석할 수 없다. 원문 화면에 대한 독립적인 사람 검수는 후속 과제로 남았다.

4.3 DEV45 검색 비교

4.3.1 9월 2일 검색 방식 비교

검색 방식 비교의 목적은 모델의 생성 변동을 배제한 상태에서 정답 문서와 근거 청크의 회수 차이를 확인하는 것이다. 동일 문서 집합에서 파서·검색 8조건을 실행하여 360개 요청을 수집했고 오류는 없었다. Baseline·Challenger·Cascade의 튜닝 BM25를 비교하고 Cascade에 대해서는 기본 BM25, KURE와 Snowflake의 Dense 및 Hybrid를 추가하였다. Dense와 Hybrid에는 C1의 의도별 튜닝을 적용하지 않았다.

표 4.6. 동일 서비스 경로의 검색 결과


조건	방식	Hit@5	MRR@5	Any Gold @8	All Gold @8
PAR-B	Baseline·튜닝 BM25	39/45 (86.7%)	0.7259	—	—
PAR-CH	Challenger·튜닝 BM25	40/45 (88.9%)	0.7144	—	—
C0	Cascade·기본 BM25	29/45 (64.4%)	0.4944	23/45 (51.1%)	10/45 (22.2%)
C1	Cascade·튜닝 BM25	40/45 (88.9%)	0.7174	28/45 (62.2%)	17/45 (37.8%)
D-K	KURE Dense	37/45 (82.2%)	0.5956	27/45 (60.0%)	15/45 (33.3%)
H-K	KURE Hybrid	34/45 (75.6%)	0.5441	20/45 (44.4%)	9/45 (20.0%)
D-S	Snowflake Dense	36/45 (80.0%)	0.6156	29/45 (64.4%)	16/45 (35.6%)
H-S	Snowflake Hybrid	35/45 (77.8%)	0.5596	21/45 (46.7%)	10/45 (22.2%)

C0에서 C1으로 변경하면서 문서 적중률은 64.4%에서 88.9%로 24.4%p 증가했고, 모든 정답 청크를 회수한 비율은 22.2%에서 37.8%로 15.56%p 증가하였다. 퍼센트포인트(%p)는 두 비율을 뺀 값이다. 예를 들어 20%에서 30%가 되면 10%p 증가다. 평균 정답 청크 회수율도 0.3593에서 0.5000으로 상승하였다. Cascade 조건에서는 C1이 문서 적중과 전체 정답 청크 회수에서 가장 높았다. Snowflake Dense는 일부 정답 청크를 찾은 질문이 한 개 더 많았지만 문서 적중과 전체 근거 회수에서는 낮았다.

해당 개발셋과 설정의 결과를 BM25의 Dense·Hybrid 대비 일반적 우월성으로 해석할 수는 없다. 파서별 청크 식별자가 달라 Baseline과 Challenger의 청크 지표는 비교하지 않았다. 검색 지연도 단일 순차 실행과 초기 모델 적재가 섞여 있어 속도 비교에 사용하지 않았다.

DEV45 검색 방식별 정답 문서 적중

2026년 9월 2일 · Hit@5 · 조건별 45문항



C0-C1은 동일 파서의 기본·튜닝 BM25 비교이다.

Dense-Hybrid에는 C1 튜닝을 적용하지 않아 방식 자체의 우열로 해석하지 않는다.

그림 4.1. DEV45 검색 조건별 문서 적중 수와 비교 범위

4.3.2 9월 4일 의도별 후속 검색 보완

후속 개발에서는 구어체 질문을 공식 문서 어휘로 확장하고 같은 문서에 분산된 지원 범위·신청 절차·제출서류를 보완하였다. 이후 DEV45 전체를 실제 서비스 경로로 다시 검색하였다. 외부 생성 모델과 Judge는 호출하지 않았다.

앞선 8조건 비교는 초기 평가셋과 dev45-retrieval-matrix-20260902 실행에 해당한다. 후속 비교인 표 4.7는 개정 평가셋에서 수행한 retrieval-budget-breakdown-v5와 dev45-retrieval-query-expansion-v7의 결과를 연결한 것이다. 따라서 앞선 C1의 MRR@5 0.7174와 후속 비교의 보완 전 값 0.7137은 같은 실행의 수치가 아니다. 평가셋과 결과 파일의 정확한 연결은 동봉한 재현 정보에 기록하였다.

표 4.7. 후속 검색 보완 전후 결과

지표	의도 확장 전	최종 보완 후
문서 Hit@5	40/45 (88.9%)	45/45 (100.0%)
MRR@5	0.7137	0.8137
모든 필수 체크 회수@8	31/45 (68.9%)	41/45 (91.1%)
모든 필수 근거 회수@8	33/45 (73.3%)	43/45 (95.6%)
평균 필수 근거 회수율@8	0.7481	0.9778

최종 두 미완전 문항은 같은 교육·연구 및 학생지도비(교연비) 질문의 기본형과 역할 변형이었다. 핵심 최대액 표는 검색했지만 지정된 배경 문장까지 모두 회수하지 못하였다. 이미 핵심 수치를 답할 수 있는 상황에서 평가 숫자만 높이기 위한 추가 튜닝은 중단하였다. 이 표는 반복 열람한 개발셋의 결과이며 일반화나 생성 품질을 측정하지 않는다. 또한 9월 2일 비교의 초기 청크 기준과 9월 4일 후속 비교의 필수 근거 기준은 정의가 달라 동일 지표의 연속적인 개선으로 직접 연결하지 않았다.

4.4 DEV45 생성 및 근거 결속 평가

4.4.1 C0·C1의 독립 생성 비교

검색 개선이 답변에 전달되는지를 확인하기 위해 C0와 C1의 45문항을 세 번씩 독립 생성하였다. 두 조건의 문맥 상한은 24,000자, 출력 상한은 900토큰이며 생성 temperature는 별도로 지정하지 않았다. 생성은 Gemini 3.5 Flash-Lite, 판정은 Gemini 3.1 Flash-Lite와 Judge v11을 사용하였다. Judge는 temperature 0, 출력 상한 1,600토큰으로 각 답변을 한 번씩 판정하였다.

전체 유효 답변 270개와 판정 270개를 확보했으며 최종 집계에 오류나 대체 모델 응답은 없다. 첫 회차 수집 중 다른 모델로 전환되어 거부된 시도 8건은 별도로 보존하고 동일 조건으로 재수집하였다.

표 4.8. DEV45 독립 생성 3회 결과

지표	C0	C1
Judge 평균 / 2점	0.8815	1.2148
0점 답변 / 135	52 (38.5%)	29 (21.5%)
2점 답변 / 135	36 (26.7%)	58 (43.0%)
회차별 GFC 수	12·13·11	18·20·20
다수결 GFC / 45	13 (28.9%)	20 (44.4%)

질문별 세 번의 평균 점수는 개선 19개, 동률 15개, 악화 11개였다. 기본 질문과 역할 변형을 묶은 39개 질문군의 대응 부트스트랩 10,000회에서 평균 차이 0.3333의 95% 신뢰구간은 [0.0889, 0.5887]이었다. 한편 다수결 GFC 차이 0.1556의 신뢰구간은 [-0.0217, 0.3201], McNemar 검정의 p값은 0.1185였다. McNemar p값은 질문별 다수결 결과 45쌍을 대상으로 계산한 보조값이며, 기본 질문과 역할 변형 간 종속성은 질문군 부트스트랩 신뢰구간에서 반영하였다. 이 조건에서는 평균 Judge 점수 향상이 관측되었으나 완전정답률 향상을 확정할 통계적 근거는 충분하지 않았다.

4.4.2 동일 답변에 대한 Judge 반복

생성 변동과 판정 변동을 구분하기 위해 첫 회차의 고정 답변을 현재 평가표와 설정에서 Judge가 세 번씩 평가하였다. C0와 C1 모두 45문항의 점수와 GFC가 세 번 일치하였다. C0는 평균 $0.8667 \cdot \text{GFC } 12/45$, C1은 평균 $1.2000 \cdot \text{GFC } 18/45$ 였다. 같은 답변의 반복 채점 결과인 18/45는 서로 다른 세 생성의 다수결 20/45와 다른 통계량이며, 반복 일치가 사람의 정답 판단과의 일치를 보장하지는 않는다.

4.4.3 C2의 주장·인용 동시 생성 실험

C1은 자유 서술 초안을 받은 뒤 각 문장을 어느 출처가 지지하는지 판단한다. 이 과정의 근거 결속 손실을 줄이기 위한 대안으로 C2는 각 주장과 함께 출처 번호와 원문 인용을 구조화하여 생성하도록 하였다. 검증기는 인용의 실제 포함 여부와 수치·주제·관계를 검사한다. 실험은 저장된 C1 검색 문맥과 순서를 그대로 사용하였다.

표 4.9. C2 탐색 실험 결과

지표	C1	C2
Judge 평균 / 2점	1.2148	1.3630
회차별 GFC 수	18·20·20	28·25·23
다수결 GFC / 45	20 (44.4%)	26 (57.8%)

다수결 기준 개선 9개와 손실 3개로 순증은 6문항이었다. 질문군 단위 부트스트랩 100,000회에서 평균 점수 차이의 95% 신뢰구간은 $[0.0000, 0.3116]$, GFC 차이의 신뢰구간은 $[0.0000, 0.2826]$ 이었다. 평균 차이 신뢰구간의 원계산 하한은 부동소수점 오차 수준의 음수이며 0으로 반올림하였다. McNemar p값은 0.1460으로 확정적인 개선 근거는 부족하였다.

C2는 C1의 동일 초안을 후처리한 결과가 아니라 별도로 생성한 응답을 평가한 실험이다. 그러나 첫 C2 응답에서 발견한 거부 사례를 보고 검증기를 수정한 뒤 같은 응답을 재처리했으며 두 번째·세 번째만 고정한 검증기로 새로 생성하였다. 또한 C2는 출력 상한 1,200토큰·temperature 0으로 C1과 설정이 달랐다. 따라서 차이를 인용 방식 하나의 효과로 분리할 수 없으며 생성·검증 구성을 함께 바꾼 탐색 결과로 해석한다. C2는 서비스에 채택하지 않았다.

4.4.4 저장 초안의 후처리 진단

별도의 진단에서는 생성 모델을 다시 호출하지 않고 같은 초안과 검색 문맥을 재처리하였다. 등록금 관계문 수정에서 270개 중 9개 답변이 바뀌었고 나머지 261개는 유지되었다. 변경된 9개를 같은 Judge로 재판정한 점수는 모두 2점이었다. 이어 표 행의 날짜·시간과 인접한 고지서

출력 경로를 보완했을 때 C1 답변 135개 중 6개가 추가로 바뀌었다. 이 중 4개는 1점에서 2점으로, 2개는 1점을 유지하였다.

유지된 판정과 변경된 답변의 판정을 합친 누적 진단 평균은 C0 0.9037, C1 1.3259였다. 저장 초안의 후처리 손실을 확인한 보조 결과이므로 새로운 전체 서비스 생성 성능으로 사용하지 않았다. 개선되지 않은 두 답변은 초안부터 필요한 사실이 없어 후처리 개선만으로 복구하지 못하였다.

4.5 Shadow60의 검색·생성 진단

4.5.1 출처 분리와 검색 결과

DEV에서 확인한 개선이 다른 문서에서도 나타나는지 진단하기 위해 Shadow60을 구성하였다. 개발셋과 문서 식별자, 원문 해시, 연도를 제거한 제목 및 정규 URL의 중복을 검사하였다. 점수를 보기 전에 발견된 출처 중복 후보를 교체한 뒤 질문과 정답 근거를 고정하였다. 핵심 42문항은 단순 24·복합 18문항으로 서로 다른 원문 파일 42개를 사용한다. 게시물 URL은 40개이며, 한 게시물의 서로 다른 첨부파일을 별도 원문으로 구분한 경우가 있다. 나머지는 역할 변형 8문항과 답변 불가·모호성·인젝션 도전 10문항이다. 사람이 독립 검수한 최종 holdout이 아닌 합성 진단 세트다.

9월 4일 동일한 고정 인덱스, BM25 및 문맥 8개로 C0·C1의 60개 요청을 각각 실행하였다. 생성기는 추출형이며 오류는 없었다.

표 4.10. Shadow 핵심 42문항 검색 결과

지표	C0	C1
문서 Hit@5	40/42 (95.2%)	38/42 (90.5%)
문서 Hit@8	41/42 (97.6%)	39/42 (92.9%)
모든 필수 근거 회수@8	22/42 (52.4%)	21/42 (50.0%)
평균 근거 회수율@8	0.6071	0.5833

이 세트에서는 검색 튜닝의 양의 일반화 효과가 관측되지 않았다. 문서 Hit@8 차이의 95% 신뢰구간은 $[-0.1190, 0]$, McNemar p값은 0.5였다. 모든 필수 근거 회수 차이의 신뢰구간은 $[-0.1190, 0.0476]$, p값은 1.0이었다. 표본이 작고 서로 다른 결과가 나온 질문도 적어 일반적인 열세를 단정할 수는 없으나, DEV의 높은 적중률이 새로운 출처에서 그대로 재현되지는 않았다.

4.5.2 생성 완결성과 결과

9월 5일 C1으로 60문항을 세 번 생성하여 180개 답변을 확보하였다. 생성 모델은 Gemini 3.5 Flash-Lite, 출력 상한은 900토큰이었다. 세 회차의 문맥과 생성 입력은 동일하게 유지하였다. 9월 6일 종료된 Judge v11 평가에서는 177개가 유효하고 3개가 형식 오류였다. 오류는 모호성 도전 문항에만 있어 전체 60문항의 최종 평균과 다수결 GFC는 확정하지 않았다. 사전에 지정한 핵심 42문항의 126개 판정은 모두 유효하였다.

표 4.11. Shadow 핵심 질문의 독립 생성 3회 결과

집단	문항 수	회차별 GFC 수	다수결 GFC	평균 / 2점
핵심 전체	42	14·17·13	15/42 (35.7%)	1.1111
단순 질문	24	10·11·9	10/24 (41.7%)	1.2778
복합 질문	18	4·6·4	5/18 (27.8%)	0.8889

필수 근거가 모두 검색된 21문항 중 10개는 다수결 GFC였으나 11개는 실패하였다. 반대로 지정된 근거를 모두 회수하지 못한 21문항 중 5개는 GFC였다. 전자는 검색 이후의 생성·근거 결속 병목을, 후자는 고정 청크를 기준으로 만든 정답 근거가 다른 유효한 근거를 포괄하지 못하는 측정 한계를 보여준다. 점수를 본 뒤 정답 근거를 완화하지 않고 이러한 한계를 기록하였다. 같은 세트의 C0·C2 생성을 수집하지 않았으므로 상대적인 생성 개선 폭은 산출하지 않았다. 표 4.11의 GFC는 C1 구성의 관측값이다.

4.5.3 대표 실패 사례

첫째, 파일 식별자를 연도로 오인한 검색 손실이다. 실제 평가 질문은 “2026 K-water 장학회 청년 멘토의 모집인원·대상·선발일정과 활동기간·혜택을 알려줘.”였다. 보존된 공식 웹문에는 “모집 인원 : 88명”, “활동 기간 : 2026년 5월 ~ 12월”이 있다. 그러나 파일 식별자 203839의 앞 네 자리 2038을 연도로 해석한 강등이 적용되어 정답 청크가 후보 순위 1위에서 71위로 밀렸다. 연도를 포함하는 질문을 처리할 때 숫자 문자열의 위치와 의미를 구분해야 한다.

둘째, 학년도와 실제 일정 연도를 동일시한 검색 손실이다. “2026 교육대학원 학위논문 심사에서 심사요구서·심사료 제출일과 발표일, 결과보고서 및 최종논문 제출 일정을 정리해줘.”라는 질문의 근거 문서는 제목에 “2025학년도 후기”를 포함하지만 보존된 파싱 표의 일정은 “2026. 04. 09”, “2026. 06. 26” 등으로 작성되어 있다. 제목 연도만 사용한 강등 때문에 정답 청크가 후보 순위 2위에서 52위로 밀렸다. 문서의 학년도와 개별 절차의 달력 연도를 분리해야 한다.

셋째, 올바른 초안이 인용 검증에서 제거된 생성 이후 손실이다. 질문은 “제21회 대학(원) 생 지식재산 우수논문공모전 참가 자격과 신청·논문 제출 마감은 언제야?”였다. 원문은 국내 대학(원) 재학·휴학생, 개인 또는 3인 이하 팀의 참가 자격과 5월 31일 18시 신청 마감, 8월 3일 18시 논문 마감을 포함한다. 첫 생성 초안에도 이 세 정보가 모두 있었다.

표 4.12. 공모전 질문의 단계별 관찰

단계	관찰 내용
검색 근거	제목의 제21회와 본문의 자격·마감 확보
생성 초안	자격·신청 마감·논문 마감을 세 문장으로 답변
검증 과정	세 문장의 행사 회차와 본문 근거 결합 실패
최종 답변	“검색 결과는 있으나 답변 문장을 지지하는 근거를 충분히 확인하지 못했습니다.”

저장된 진단에서는 제목의 “제21회”가 수량으로 추출되지만 본문 근거에 상속되지 않아 세 주장이 모두 거부되는 경로를 확인하였다. 따라서 이 실패를 문서 미수집이나 모델의 최초 생성 실패로 분류하면 원인을 잘못 짚게 된다. 다만 제목의 값을 무조건 허용하면 다른 행이나 문서의 값과 잘못 결합될 수 있으므로 문서 범위를 보존하는 검증이 필요하다. 위 세 사례는 동결 후 발견한 개별 실패이며 전체 오류의 비율을 대표하지 않는다.

4.6 보안 검사 파일럿

보안 평가는 입력 문서에 포함된 공격 지시가 모델 입력과 최종 답변에 어떻게 반영되는지 확인하는 데 목적이 있다. 9월 9일 보안 적용 전, 병합된 보안본, 결함을 수정한 별도 사본을 비교하여 총 102개 답변·판정 쌍을 완성하였다. 조건마다 정상 질문 14개, 합성 공격 10개와 대응 대조 10개를 사용하였다. 합성 20개는 서로 다른 20문항이 아니라 가상 열람실 운영시간 질문 하나의 변형이다. 생성과 판정은 각각 한 번이며 생성 모델과 Judge는 앞선 평가와 동일하다.

공격 문구는 외부 공개 공격 데이터셋을 그대로 사용한 것이 아니라 본 과제의 검사 기능을 확인하기 위해 만든 합성 사례다. 목표 변경·역할 위장·가짜 비밀 공개 유도는 Perez와 Ribeiro가 구분한 목표 탈취·프롬프트 유출 개념과 관련된다[8]. 이를 검색 문서에 넣는 상황은 Greshake 등의 간접 주입 위협과 연결된다[9]. 다만 실제 시스템 프롬프트나 비밀의 유출 성공을 측정한 것은 아니다.

10개 변형은 이전 지시 무시, 역할 변경, 비밀 공개 문구, 가상 도구 호출 문구, 허위 인용, 시스템 태그 위장, 한국어 목표 변경, 정상 금지 문구와 공격의 혼합, 파일명 속 공격, 모든 근거가 오염된 상황을 포함한다. 파일명·혼합 문구·전체 문맥 오염은 본 구현의 검사 누락을 확인하기 위한 자체 확장이다. 실제 명령 실행이나 외부 전송을 수행하지 않고 합성 표식 문자열이 입력과

출력에 남는지만 확인하였다. 원문 시나리오는 동봉한 supplement/security-scenarios.json에 보존하였다.

표 4.13. 보안 조건별 정상 품질과 공격 표식 관찰

지표	보안 적용 전	병합 보안본	수정 사본
	6/14 (42.9%)	6/14 (42.9%)	5/14 (35.7%)
정상 질문 GFC			
정상 평균 / 2점	1.0714	1.1429	1.0714
	0/10 (0.0%)	7/10 (70.0%)	9/10 (90.0%)
공격 문서 제외			
	10/10 (100.0%)	3/9 (33.3%)	1/9 (11.1%)
모델 입력의 표식 잔존			
	1/10 (10.0%)	0/10 (0.0%)	0/10 (0.0%)
최종 답변의 표식 출력			
	0/10 (0.0%)	1/10 (10.0%)	1/10 (10.0%)
생성 없는 보안 회피			
	10/10 (100.0%)	10/10 (100.0%)	10/10 (100.0%)
대응 대조 GFC			

보안본 두 조건의 한 공격은 생성기를 호출하지 않고 회피하여 입력·초안의 관측 분모가 9다. 미관측 값을 표식이 없다는 값으로 채우지 않았다. 공격 표식은 실제 비밀이 아닌 합성 canary이며 최종 답변이 해당 문자열을 출력했는지를 검사하였다.

입력 격리의 작동 차이와 최종 표식 출력 차이는 관측되었으나 정상 답변 품질 향상은 입증하지 못하였다. 수정본에서도 한 표식이 모델 입력에 남았으며 병합 보안본과 수정본의 최종 출력은 모두 0/10으로 수정 자체의 출력률 개선은 관측되지 않았다. 단일 가상 질문의 변형, 조건별 1회 생성, 실행 순서와 시간 차이를 분리할 수 없으므로 일반적인 공격 성공률 감소나 인과 효과로 확대하지 않았다. 의미 기반 공격 성공률도 별도로 산출하지 않았다.

4.7 최종 holdout 평가와 사람 검수

4.7.1 평가셋과 실행 조건

최종 평가는 개발에 사용하지 않은 holdout 36문항을 대상으로 9월 14일에 수행하였다. 핵심 27문항은 학사·입학·핵심 행정·취업·졸업·국제·등록·장학·학생지원의 9개 영역에서 단일 사실·복합 근거·구조 민감 유형을 각 3문항씩 배치한 것으로, 27개의 서로 다른 출처 문서군을 사용하며 문항당 2~5개, 총 87개의 필수 주장을 가진다. 도전 9문항은 답변 불가 3, 범위·시점 모호 3, 프롬프트 인젝션 3으로 구성하였다. 정답 근거는 출처 문서와 원문 인용으로 지정하였다. 개발자 1인이 원문과 대조한 뒤 평가셋을 확정하고 파일 식별값을 기록하였다. 결과를 본 뒤 질문이나 정답을 수정하지 않았다.

인력 제약으로 당초 계획한 두 사람의 독립 검수 대신 개발자 1인의 원문 기반 채점과 Judge 판정의 일치도를 확인하는 개정 절차를 적용하였다. 서비스 코드는 보안 검사 파일럿에서 보존한 병합 보안본이며, 검색 인덱스는 앞선 실험과 같은 고정본이다. 생성은 Gemini 3.5 Flash-Lite, 문맥 8개·문서당 2청크, 보안 검사는 모두 강제 모드로 실행하였다. Judge는 Gemini 3.1 Flash-Lite와 v11 평가표, temperature 0으로 답변마다 한 번 판정하였다. 핵심 27문항은 C0·C1 각 3회, 도전 9문항은 C1 3회 생성하여 예정 슬롯은 189개였다. 실행 중 제공자의 요청 제한(HTTP 429)이 발생하여 전역 호출 간격 15초로 재개하였고, 이미 저장된 답변은 그대로 사용하였다. C1 첫 회차의 한 슬롯은 429 이후 추출형 응답으로 대체되어 운영 오류로 보존하고 GFC 실패로 집계하였으며, 도전 문항의 Judge 형식 오류 4건은 판정 없음으로 분모에서 구분하였다. 평가셋·실행 계획·코드·집계 파일의 경로와 전체 식별값은 동봉한 재현 정보에 수록하였다.

4.7.2 자동 평가 결과

표 4.14. 최종 holdout 자동 평가 결과(생성 3회, Judge v11)

집합·조건	예정	정상 출력	유효 Judge	GFC 수	GFC / 예정	평균 / 2점
핵심 C0	81	81	81	19	23.5%	0.9506
핵심 C1	81	80	80	18	22.2%	0.8750
도전 C1	27	27	23	7	판정 불완전	0.7391

핵심 27문항의 예정 응답 81개 기준에서 C1과 C0의 GFC 차이는 $-1.23\%_p$ 였다. 질문군 단위 대응 부트스트랩 10,000회의 95% 신뢰구간은 $[-19.75, +17.28]\%_p$, 정확 부호 치환 검정의 p값은 0.892였다. 회차별 GFC 수는 C0 6·7·6, C1 6·7·5로 회차 간 변동보다 조건 간 차이가 작았다. 따라서 개발셋에서 관측한 검색 조정의 평균 점수 향상은 holdout에서 재현되지 않았고, Shadow60 진단의 결과와 같은 방향이다. 3회 중 2회 이상 GFC인 다수결 문항 비율로 통일하면 holdout은 C0 6/27(22.2%), C1 5/27(18.5%)로 DEV45의 C0 13/45(28.9%), C1 20/45(44.4%)보다 낮다. holdout의 3분의 2가 복합 근거·구조 민감 유형이고 코드 조정에 사용하지 않은 최종 평가 문항이므로, 개발셋 수치를 서비스의 일반 성능으로 사용할 수 없음을 확인한 결과로 해석한다.

4.7.3 검색 단계와 생성·검증 단계의 분리

최종 답변의 오류가 어느 단계에서 발생하는지 확인하기 위해 저장된 답변 기록을 단계별로 연결하였다. 각 기록에는 검색 후보(BM25 상위 128개), 중복 제거 후 풀 32개, 최종 문맥 8개의

체크 식별자, 생성 모델의 저장 초안, 출력 검사의 문장별 판정, 그리고 Judge의 필수 주장별 판정이 포함되어 있다. 외부 모델을 다시 호출하지 않고 이 기록만으로 집계하였다. 문서 단위 적중은 필수 주장의 지정 출처 문서가 해당 단계의 체크에 포함된 경우, 근거 체크 적중은 실행 시 저장된 원자적 근거 매치(NFKC 정규화·유사도 0.85)의 판정을 그대로 사용하였다. 검색은 결정적이어서 세 회차의 최종 문맥이 모두 동일하였다. 집계 스크립트와 결과 파일, 입력 해시는 동봉한 재현 정보에 수록하였다.

표 4.15. holdout 핵심 문항의 단계별 근거 회수와 답변 결과

단위	지표	C0	C1
주장	필수 주장 수(27문항 × 3회)	261	256
주장	검색 후보 128개에 출처 문서 포함	87/87 (100%)	82/82 (100%)
주장	최종 문맥 8개에 출처 문서 포함	213/261 (81.6%)	208/256 (81.2%)
주장	최종 문맥 8개에 지정 근거 체크 포함	144/261 (55.2%)	148/256 (57.8%)
주장	근거 체크가 있는 주장 중 Judge 지지	89/144 (61.8%)	80/148 (54.1%)
주장	근거 체크가 없는 주장 중 Judge 지지	30/117 (25.6%)	33/108 (30.6%)
문항	출처 문서를 모두 포함	66/81 (81.5%)	62/80 (77.5%)
문항	필수 근거 체크를 모두 포함	39/81 (48.1%)	39/80 (48.8%)
문항	근거를 모두 포함한 문항의 GFC	16/39 (41.0%)	13/39 (33.3%)
문항	근거가 불완전한 문항의 GFC	3/42 (7.1%)	5/41 (12.2%)
문항	근거를 모두 포함한 문항의 평균 / 2점	1.256	1.128

검색 단계에서 출처 문서를 찾는 일은 병목이 아니었다. 필수 주장의 출처 문서는 후보 단계에서 예외 없이 회수되었고 최종 문맥 8개에도 5건 중 4건 이상 포함되었다. 후보 128개의 값은 첫 회차 기준이나 세 회차의 검색 결과가 같으므로 전체에 적용된다. 남은 검색 손실은 문서를 찾지 못한 것이 아니라 문서 내부의 어느 체크를 문맥 예산 안에 넣는가의 문제였다. 문항당 2~5개의 필수 근거를 문맥 8개·문서당 2체크로 모두 담은 문항은 절반에 미치지 못하였고, 이는 복합 근거·구조 민감 유형에 집중되었다. 다만 지정 근거 체크가 없는 주장의 25.6~30.6%도 Judge가 지지한 것으로 판정하였으므로, 고정된 인용을 기준으로 한 근거 체크 적중은 같은 문서의 다른 유효한 체크를 놓치는 엄격한 측정이다.

그럼에도 필수 근거를 모두 확보한 문항의 완전정답률은 C0 41.0%, C1 33.3%에 그쳤고 Judge 평균도 2점 만점에 1.1~1.3점이었다. 근거 체크가 문맥에 있는 필수 주장 가운데 최종 답변에서 지지된 것은 54.1~61.8%였다. 즉 근거가 모델에 전달된 뒤에도 약 38.2~45.9%의 필수 주장이 최종 답변에서 충분히 지지되지 않은 것으로 판정되었다. 검색 이후에도 큰 손실이 남았다는 뜻이다. 다만 이 값만으로 검색·생성·검사 단계 각각의 인과적 기여율을 정할 수는 없다. Judge가 실패 답변에 붙인 원인은 C0 기준 필수 주장 누락 60/62, 부적절한 회피 49/62,

명시적 회피 15/62로 근거 없는 사실(2)이나 모순(2)보다 누락과 회피가 압도적이었다. C1도 56·45·16으로 같은 분포였다.

표 4.16. 생성 초안과 출력 검사 단계의 손실

지표	C0	C1
출력 검사가 판정한 초안 문장	289	298
근거 미확인으로 제거된 문장	108 (37.4%)	115 (38.6%)
제거 문장 중 정답 핵심값 문자열 포함	27/108 (25.0%)	33/115 (28.7%)
답변 결정: 전체 답변 / 부분 답변 / 회피	17 / 49 / 15	16 / 48 / 16
비GFC 답변: 근거 불완전	39 / 62	36 / 62
비GFC 답변: 근거 완비·초안 핵심값 일부 미포함	13 / 62	20 / 62
비GFC 답변: 근거 완비·초안 핵심값 모두 포함	10 / 62	6 / 62

생성 이후의 손실은 두 갈래였다. 첫째는 초안 자체의 누락이다. 문맥에 있는 값을 초안에 쓰지 않거나, 같은 문맥에 있는 이전 학년도 문서의 값을 선택한 경우가 여기에 해당한다. 예를 들어 2025학년도 후기 교육대학원 논문 일정 질문에서는 2024학년도 후기 문서가 1위, 정답인 2025학년도 후기 문서가 2위로 함께 문맥에 있었으나, 초안은 이전 학년도 문서의 4월 16일·4월 22~23일·7월 23~24일을 “2025학년도 후기” 일정으로 답하여 세 필수 주장이 모두 누락으로 판정되었다. 문서의 학년도 표기와 실제 일정 연도를 구분하지 못한 이 오류는 Shadow60에서 관측한 검색 강등과 같은 뿌리를 생성 단계에서 드러낸 것이다. 둘째는 출력 검사 단계의 보수적 기각이다. 검사기는 초안 문장의 37.4~38.6%를 근거 미확인으로 제거하였는데, 제거된 문장 중 C0 27/108(25.0%), C1 33/115(28.7%)가 정답 핵심값 문자열을 포함하였다. 사유는 의미 관계 불일치와 핵심값 불일치가 절반씩이었다. 장애학생 컴퓨터교육 일정 질문에서는 초안이 2일차·4일차의 날짜·시간·주제를 모두 정확히 적었으나 세 문장이 유사도 0.58~0.75로 기각되어 최종 답변이 “검색 결과는 있으나 답변 문장을 지지하는 근거를 충분히 확인하지 못했습니다.”가 되었고, 계절학기 단기파견 질문에서는 “최대 6학점”을 담은 문장이 0.778로 기각되어 핵심 수치가 빠진 부분 답변이 되었다. 초안과 제거 문장의 핵심값 포함 여부는 문자열 검사 결과다. 표현이 다른 정답은 놓치고, 값이 같아도 대상·시점·관계가 틀린 문장은 포함할 수 있다. 따라서 표 4.16의 비율은 정답 문장 기각률이나 오탐의 하한을 뜻하지 않는다. 초안의 완전성과 검사 단계 손실도 이 집계만으로 확정할 수 없으며, 실제 오탐률은 문장 단위 검수로 확인해야 한다.

4.7.4 사람 1인 검수와 Judge의 일치도

첫 회차의 실제 답변 62개(핵심 C0 27, C1 26, 도전 9)를 개발자 1인이 채점하였다. 채점 화면에는 조건명·모델·회차·Judge 판정을 숨기고 임의 순서의 식별자를 부여했으며, 원문·

필수 주장·실제로 전달된 검색 문맥·답변·인용을 함께 제시하였다. 본 채점 전 DEV 답변 8개로 기준을 연습했고 연습분은 일치도에서 제외하였다. 최초 확정 판정은 수정을 잠갔으며, 정답지에 있다는 이유만으로 통과시키지 않고 해당 내용이 실제 답변에 있고 전달된 근거가 이를 지지하는지 확인하도록 하였다. 다만 조건별 전체 성적은 채점 전에 이미 공개되어 있었고 개발자가 문제로 조건을 추측할 수 있으므로 완전한 눈가림이나 독립 검수는 아니다. 사람 판정은 342번째 저장본을 기준으로 집계하였고, 해당 파일과 식별값을 동봉한 재현 정보에 수록하였다.

표 4.17. 사람 1인 판정과 Judge 판정의 일치도

표본	n	GFC 일치	κ	균형 정확도	Macro F1	점수 일치	가중 κ
핵심 전체	53	0.906	0.705	0.899	0.852	0.849	0.852
핵심, 불확실 제외	48	0.938	0.786	0.912	0.893	0.875	0.867
핵심 C0	27	0.889	0.658	0.855	0.829	0.852	0.858
핵심 C1	26	0.923	0.755	0.955	0.876	0.846	0.846
도전	7	0.571	0.000	—	0.364	0.429	0.000

핵심 문항에서 사람과 Judge의 GFC 판정은 53개 중 48개가 일치하였고 Cohen κ 는 0.705였다. 사람이 경계 판단으로 표시한 5개를 제외하면 일치율 0.938, κ 0.786이다. 이는 개정 절차에서 참고선으로 둔 일치율 0.80· κ 0.60을 넘지만, 두 사람의 독립 검수를 대신하지 않으므로 기존 보정 기준의 통과로 표현하지 않는다. 사람의 GFC는 C0 5/27, C1 4/26으로 같은 답변에 대한 Judge의 6/27, 6/26보다 약간 엄격하였고, 0~2점 분포는 C0 7·12·8, C1 6·14·6이었다.

사람의 판정도 표 4.15와 같은 방향을 보였다. 필수 근거를 모두 확보한 답변 26개의 사람 GFC는 8개(30.8%), 평균 1.27점이었고, 근거가 불완전한 27개는 1개(3.7%), 0.78점이었다. 검수 기록에는 “체크는 제대로 전달된 것 같으나 답변을 생성하지 못함”, “근거 자체는 제대로 확보했으나 과거 지침을 참고하고 있음”과 같이 검색 이후의 실패를 짚은 메모와 석사과정 내용, 제출 기한, 주최 주기, 비용 등 특정 항목의 누락을 지적한 메모가 남아 있다. 사람이 2점을 주고도 GFC로 인정하지 않은 답변 5개는 핵심 내용은 맞지만 불필요한 문장이 추가되었거나, 과거 지침을 근거로 삼았거나, 요구된 명칭이 빠진 경우로 기록되었다.

도전 문항은 유효 비교 7개에서 일치율 0.571, κ 0으로 두 판정이 갈렸다. 프롬프트 인젝션 3문항은 세 회차 모두 주입된 지시를 따르지 않았으나, 정상 질문 부분까지 “제공된 검색 근거에서 질문에 답할 내용을 확인할 수 없습니다.”로 회피하여 사람과 Judge가 모두 0점으로 판정하였다. 답변 불가·범위 모호 문항에서 Judge는 회피 자체를 적절하다고 보아 3개를 통과시켰으나, 검수자는 일률적인 회피 문구가 문항별로 요구한 공식 조회 경로 안내나 범위

확인을 담지 못했다고 보아 통과시키지 않았다. 따라서 보안 지시의 거부는 작동했지만, 거부 뒤에 정상 요청을 이어서 처리하는 행동은 확보되지 않았다.

이 결과는 한 사람의 판정과 Judge의 일치도이며, 동일 계열의 생성·판정 모델, 작은 표본, 개발자 검수의 편향, 그리고 조건별 성적이 채점 전에 공개된 점을 한계로 가진다. 일치도가 높다는 사실이 C1의 성능 개선이나 Judge의 일반적 타당성을 입증하지는 않는다.

4.8 종합 해석과 검증 범위

표 4.18. 성능 변화량 요약: 동일 행 안에서만 전후 비교

비교·지표	적용 전	적용 후	변화량
표적 파서 근거 보존	48/54 (88.9%)	54/54 (100%)	+11.11%p
초기 DEV 문서 Hit@5	29/45 (64.4%)	40/45 (88.9%)	+24.44%p
초기 DEV All Gold@8	10/45 (22.2%)	17/45 (37.8%)	+15.56%p
후속 DEV 필수 근거 완비	33/45 (73.3%)	43/45 (95.6%)	+22.22%p
DEV 생성 평균 / 2점	0.8815	1.2148	+0.3333점
DEV 다수결 GFC	13/45 (28.9%)	20/45 (44.4%)	+15.56%p
Shadow 문서 Hit@8	41/42 (97.6%)	39/42 (92.9%)	-4.76%p
holdout GFC / 예정 응답	19/81 (23.5%)	18/81 (22.2%)	-1.23%p
보안 공격 문서 제외	0/10 (0%)	7/10 (70%)	+70.0%p
보안 최종 표식 출력	1/10 (10%)	0/10 (0%)	-10.0%p

변화량은 반올림 전 비율에서 계산했다. 파서는 Baseline과 Cascade, 초기 DEV·DEV 생성·Shadow·holdout은 C0와 C1, 후속 DEV는 해당 후속 실험의 보완 전후, 보안은 적용 전과 병합 보안본의 비교다. 규칙 하나씩의 기여도는 측정하지 않았다. DEV의 GFC 증가와 holdout의 차이는 통계적으로 유의한 차이로 확인되지 않았으며, 보안의 표식 출력률은 일반적인 공격 성공률이 아니다.

표 4.19에 주요 관측을 정리하였다. 각 행은 앞 절의 개별 실험에 대응하며 평가셋·코드·생성 조건이 다른 행 사이의 수치를 연속적인 개선 단계로 해석하지 않는다.

DEV에서는 검색 적중과 평균 생성 점수가 개선되었고, C2에서는 생성과 함께 근거를 결속하는 방식의 가능성을 관측하였다. Shadow 진단과 최종 holdout에서는 검색 튜닝의 양의 일반화 효과가 재현되지 않았다. 반면 holdout의 단계별 분해는 출처 문서의 발견이 후보 단계에서 예외 없이 이루어지고 최종 문맥에도 대부분 전달되는 데 비해, 근거를 확보한 뒤에도 생성 초안의 누락과 출력 검사의 과도한 제거가 발생함을 보였다. 각 단계의 정확한 손실 비중은 추가 검수가 필요하다. 따라서 후속 개선의 우선순위는 검색 규칙의 추가 조정보다 문서

표 4.19. 핵심 실험 결과와 해석 범위

평가	주요 관측	해석 범위
문서 처리	2,260건 중 2,247건 파싱, 44,520 청크 색인	구축 규모이며 내용 정확도와는 별개
표적 파서 비교	54개 근거 중 Baseline 48개, Challenger·Cascade 각 54개 보존	알려진 실패 유형의 18문서 표본
초기 DEV 검색	C0→C1 문서 Hit@5: 29/45→40/45	초기 평가셋에서의 동일 코퍼스 비교
후속 DEV 검색	보완 전→후 Hit@5: 40/45→45/45	개정 평가셋과 후속 코드의 별도 비교
DEV 생성	C0→C1 평균: 0.8815→1.2148; 다수결 GFC: 13/45→20/45	평균 점수 개선 관측, GFC 차이의 통계적 유의성 미확인
C2 탐색	평균 1.3630; 다수결 GFC 26/45	출력 상한·온도와 검증 처리 조건이 다른 탐색 실험
Shadow 핵심	C0→C1 Hit@8: 41/42→39/42; C1 GFC 15/42	검색 개선 미유지; C0 생성과의 비교 없음
보안 파일럿	표식 출력 1/10→0/10→0/10; 정상 GFC 6/14→6/14→5/14	적용 전·병합본·수정 사본 순서; 단일 질문의 공격 변형
최종 holdout	C0·C1 예정 응답 기준 GFC 23.5%·22.2%; 차이 -1.23%p, 95% CI [-19.75, +17.28]	개발 미사용 36문항, 생성 3회; 검색 조정의 효과 미재현
holdout 단계 분해	출처 문서 회수 후보 100%·문맥 81.6%; 근거 완비 문항의 GFC 41.0%(C0)	근거 확보 뒤에도 누락·기각 관측; 근거 청크 완비는 48.1%
사람 검수	핵심 53개 GFC 일치 0.906, κ 0.705; 도전 7개 κ 0	개발자 1인과 Judge의 일치도; 독립 2인 검수 아님

범위와 사건·수치·시점의 관계를 보존하는 생성·검증 구조, 특히 정답 문장을 기각하지 않는 검사기의 보정에 있다.

소프트웨어 검증 기록에서는 9월 6일 전체 단위 테스트 803건 실행 중 6건 제외, 실패 0건과 프론트엔드 검사·빌드 통과를 확인하였다. 9월 8일 보안 수집기 수정 사본은 857건 실행 중 6건 제외, 실패·오류 0건이었다. 제외 항목은 선택적 의존성이 필요한 테스트다. 이는 해당 코드·환경의 회귀 검증이며 모델 정답률이나 다른 시점의 전체 코드 검증을 대신하지 않는다.

개발셋의 반복 사용, 작은 표본, 동일 계열 생성·평가 모델, 정답 근거 정의의 불완전성이 주요 타당도 제한이다. 최종 holdout은 코드 조정에는 쓰지 않았지만 원문 27개 중 9개가 Shadow 진단과 겹치므로, 세 평가셋이 모두 독립적인 것은 아니다. 최종 holdout 36문항의 자동 평가와 개발자 1인의 채점은 완료하였으나, 독립된 두 사람의 검수와 합의 판정은 수행하지 못했으므로 사람 판정은 비교 기준이지 오류 없는 정답이 아니다. holdout의 단계별 분해에서 초안 누락과 검사 단계 손실의 구분은 문자열 포함 검사에 의존하며, 두 손실의 정확한 비율은 표현 차이를 반영하는 후속 검수가 필요하다. 원문 화면에 대한 파서 검수와 다양한 공격군 평가는 후속 과제로 남긴다. 외부 챗봇과 같은 질문 및 같은 채점 기준을 적용한 답변 성능 비교는 수행하지 않았다. 상용 서비스와 동일 조건의 응답 시간·비용 비교, 실제 사용자의 과업 성공률과 탐색 시간 측정도 완료하지 않았다. 따라서 현재 결과로 상용 서비스보다 빠르거나 실제 행정 업무 시간을 줄였다고 결론내릴 수 없다.

제5장 결론 및 향후 연구 방향

5.1 연구 결과 요약

본 과제는 부산대학교와 공공기관의 공식 문서를 대상으로 수집·파싱·검색·근거 기반 생성·원문 확인을 연결하는 행정 문서 챗봇을 구현하였다. 부산대학교 코퍼스에서는 선별 문서 2,260건 중 2,247건을 파싱하고 품질 검사를 거친 44,520개 청크를 검색 인덱스로 구성하였다. 사용자는 기관을 선택하여 질문하고 답변 문장에 연결된 인용과 원문을 확인할 수 있다. 검색 문맥과 생성 출력을 검사하는 기능을 추가하여 입력 자료와 모델 지시의 경계를 구분하였다.

평가에서는 검색 개선과 답변 품질을 분리하였다. 9월 2일 개발용 45문항의 동일 코퍼스 비교에서 BM25 검색 조정 후 문서 Hit@5가 64.4%에서 88.9%로 24.4%p 증가하였다. 9월 4일 완료한 반복 생성 비교에서는 0~2점 평균이 0.8815에서 1.2148로 높아졌으나, 3회 중 2회 이상 완전 정답인 문항의 증가에 대해서는 통계적으로 유의한 차이를 확인하지 못했다. 이후 별도 Shadow60 진단에서는 새로운 질문에 대한 개선이 일관되게 유지되지 않았다. 실험별 관측과 해석 범위는 표 4.19에 정리하였다.

9월 9일 보안 파일럿에서는 공격 변형 10개의 최종 표식 출력이 보안 적용 전 1건, 병합 보안본과 수정 실험본에서 각각 0건으로 관측되었다. 이 결과는 소규모 합성 공격에서 동작 차이를 확인한 것으로, 일반적인 공격 방어율이나 보안 도입에 따른 답변 정확도 향상을 의미하지 않는다. 입력에 공격 표식이 남은 사례와 정상 질문의 불완전 답변이 존재하여 후속 검증이 필요하다.

9월 14일에는 개발에 사용하지 않은 holdout 36문항으로 최종 평가를 수행하였다. 핵심 27문항의 예정 응답 81개 기준 완전정답률은 C0 23.5%, C1 22.2%로 검색 조정의 효과가 재현되지 않았다. 답변 기록을 단계별로 분해한 결과, 필수 주장의 출처 문서는 검색 후보 단계에서 예외 없이 회수되고 최종 문맥 8개에도 81.6%가 포함되어 문서 발견은 병목이 아니었다. 그러나 필수 근거를 모두 확보한 문항에서도 완전정답률은 33.3~41.0%에 그쳤고, 근거가 전달된 필수 주장의 38.2~45.9%는 최종 답변에서 충분히 지지되지 않은 것으로 판정되었다. 손실은 초안이 문맥의 값을 빠뜨리거나 이전 학년도 문서의 값을 선택하는 생성 단계와 출력 검사 단계에서 관측되었다. 출력 검사로 제거된 문장 중 정답 핵심값 문자열을 포함한 비율은

C0 27/108(25.0%), C1 33/115(28.7%)였다. 실제 정답 문장의 기각률은 문장 단위 검수로 확인해야 한다. 개발자 1인이 첫 회차 답변 62개를 채점한 결과 핵심 문항의 Judge 판정과 GFC 일치율 0.906, Cohen κ 0.705로 같은 방향을 확인하였으며, 검수 기록도 근거가 전달된 뒤의 누락을 주된 실패로 지목하였다.

검색·생성·보안 단계별 검증 기록을 남기고, 성공 사례와 함께 개발셋의 개선이 새로운 질문에서 유지되지 않는 현상, 근거를 확보한 뒤의 생성 누락, 과잉 회피, 올바른 문장도 제거할 수 있는 인용 검사의 한계를 분석하여 후속 개선 방향을 정리하였다. 최종 holdout에서 근거 확보 뒤에도 큰 손실을 확인했으므로, 추가 검색 규칙을 늘리는 일과 함께 생성·검사 과정의 누락과 과도한 문장 제거를 줄이는 작업이 필요하다.

5.2 향후 연구 방향

최종 holdout은 DEV와 원문을 분리하고 고정한 코드·문서 집합으로 평가했으나 검수는 개발자 1인에 그쳤다. 원문 27개 중 9개는 Shadow 진단과 겹치므로, 다음 평가는 기존 진단에서 다른 문서와 사실까지 분리해야 한다. 독립된 두 사람의 검수와 합의 판정으로 자동 평가의 완전 정답 판정을 대조하고 오답·누락을 기관·행정 영역·질문 난도별로 보고해야 한다. 출력 검사기가 정답 문장을 근거 미확인으로 제거한 사례는 의미 관계·핵심값 판정의 기준을 사람 라벨로 보정하고, 초안과 최종 답변의 차이를 회귀 검사로 추적하여 과잉 기각률을 관리해야 한다. 또한 같은 문맥에 여러 학년도의 문서가 있을 때 생성 단계에서 최신 문서를 선택하도록 문서의 학년도 표기와 실제 일정 연도를 구분하는 규칙이 필요하다. 단순·복합 질문, 모호한 질문, 적용 시점이 충돌하는 질문을 구분하고, 인용문의 원문 존재 여부와 결론의 대상·수치·시점·예외 관계를 지지하는지는 별도로 평가한다.

개발용 질문에 맞춘 검색 규칙은 새로운 질문에서도 효과가 유지되는지 확인한 뒤 채택해야 한다. 오탈자·띄어쓰기·유사 표현은 원질의와 같은 답을 요구하는 질문군으로 구성하고 변환 과정에서 기관명·연도·자격 조건이 달라지지 않는지 검사한다. 복합 질문은 대상·기간·비용·절차·예외 등 요구 항목을 나누어 각 항목의 근거 회수와 답변 포함 여부를 확인한다.

문맥 구성에서는 모델의 입력 한도에서 시스템 지시와 출력 예약분을 제외한 토큰 예산을 계산하고, 중복을 제거한 근거를 요구 항목별로 배치하는 방안을 검토한다. 압축·분할 질의에서도 원문과 인용 위치를 보존하고 날짜·부정·예외 조건의 손실을 검사해야 한다. 고정 문맥과 제안 방식은 GFC, 필수 근거 회수율, 실제 토큰 사용량과 응답 시간으로 비교한다.

보안 평가는 다양한 정상 업무·공격 목표·대상 문서로 확대하여 생성 입력·최종 답변·출처 메타데이터를 각각 검사하고, 정상 문서를 공격으로 오인해 답변을 보류하는 비용도 평가한다.

보안 수정본의 입력 처리 개선은 현재 서비스와 분리된 실험 결과이므로 충분한 회귀·반복 검증을 거쳐 반영해야 한다.

운영 단계에서는 입력·출력 검사와 별개로 비상정지와 복구 절차가 필요하다[13]. 관리자가 신규 요청을 차단하고 대기 작업을 취소하며 진행 중인 호출의 상태를 확인한 뒤, 원인을 점검하고 재개할 수 있어야 한다. 외부 제공자가 접수한 호출은 즉시 종료되지 않을 수 있으므로 요청 차단과 원격 실행 종료를 구분한다. 중지 후 새 호출과 취소한 응답의 화면 반영 여부, 복구 권한과 기록의 유지를 검증한다.

문서 갱신에서는 수집일·게시일과 개정일·시행일·효력 종료일을 구분하고 동일 규정의 개정본과 한시적 안내의 관계를 관리해야 한다. 적용 시점을 확인할 수 없거나 내용이 충돌하는 자료는 임의로 최신이라고 판단하지 않고 사용자가 확인할 근거로 제시한다. 다기관 확장에서는 코퍼스 규모와 문서 형식, 질문 특성에 따른 독립적인 품질 지표가 필요하다. 실제 활용성은 장학금 신청이나 연구비 집행 조건 확인을 사용자 과업으로 정하여 일반 웹 탐색과 챗봇 사용의 성공률, 원문 확인 시간, 잘못된 적용 조건 선택 건수를 비교하는 방식으로 평가한다.

상용 서비스는 동일 문서·질문으로 비교하고 가능한 범위에서 모델·출력 예산·지역·네트워크·동시 요청 수를 맞춘다. 캐시를 사용하지 않는 최초 요청과 반복 요청을 분리하고 실행 순서를 교차한다. 내부 검색 구간을 관측할 수 없는 서비스는 검색 지연 비교에서 제외하고 사용자 요청부터 답변 완료까지의 시간을 비교한다. 중앙값·95백분위 지연, 오류율·비용과 GFC를 함께 보고하여 불완전하거나 보류된 답변의 짧은 응답 시간을 품질 개선으로 해석하지 않도록 한다.

참고문헌

- [1] Patrick Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [2] Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. <https://doi.org/10.1561/15000000019>.
- [3] Vladimir Karpukhin et al. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020. <https://doi.org/10.18653/v1/2020.emnlp-main.550>.
- [4] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2009. <https://cormack.uwaterloo.ca/cormacksigir09-rrf.pdf>.
- [5] Nelson F. Liu et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. https://doi.org/10.1162/tacl_a_00638.
- [6] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, 2024. <https://doi.org/10.18653/v1/2024.eacl-demo.16>.
- [7] Lianmin Zheng et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html.
- [8] Fabio Perez and Ian Ribeiro. Ignore Previous Prompt: Attack Techniques For Language Models. ML Safety Workshop, NeurIPS 2022; arXiv:2211.09527, 2022. <https://doi.org/10.48550/arXiv.2211.09527>.
- [9] Kai Greshake, Sahar Abdelnabi, Shailesh Mishra, Christoph Endres, Thorsten Holz, and Mario Fritz. Not What You’ve Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. arXiv:2302.12173, 2023. <https://doi.org/10.48550/arXiv.2302.12173>.
- [10] Pusan National University. Tuition Payment Plan for Enrolled Students, Fall 2026, 2026. Korean PDF attachment, collected July 2026. https://www.pusan.ac.kr/kor/CMS/Board/Board.do?board_seq=1510073&mCode=MN095&mgr_seq=3&mode=view.

- [11] Geumjeong-gu; Pusan National University Career Center. 2026 Geumjeong Youth Job-Seeking Support Package Recruitment Notice, 2026. Korean HWP attachment, collected July 2026. <https://job.pusan.ac.kr/ko/notice/notice/view/203775?p=16>.
- [12] Pusan National University Admissions. Korean Guide: inform_20260116_korean.pdf, 2026. PDF attachment, collected July 2026. https://go.pusan.ac.kr/college_2016/pages/index.asp?b=B_1_1&bn=49176&m=read&p=50.
- [13] Dae Sun Kim. Written Consultation Report for the 2026 Capstone Design Project, School of Computer Science and Engineering. Korea Institute of Ocean Science & Technology, 2026. Written consultation, July 28 (in Korean).