
최신성, 정확성, 적대적공격대응을
적용한 부산대학교 및 공공기관
행정문서 챗봇



202155596 이현우 kodokugourmet@gmail.com
202155627 황지완 hjw8486@pusan.ac.kr
202355709 정지인 gini202355709@gmail.com

지도교수: 손준영

목차

1	서론	1
1.1	연구 배경	1
1.2	기존 문제점	2
1.3	연구 목표	2
2	연구 배경	4
2.1	검색 증강 생성과 문서 근거	4
2.2	어휘 검색과 의미 검색	4
2.3	문서 분할과 문맥 구성	5
2.4	답변 품질과 자동 평가	5
2.5	문서 속 공격 지시와 대응 방법	5
3	연구 내용	7
3.1	시스템의 전체 구조와 구현 범위	7
3.2	공식 문서 수집과 평가 문서 선정	8
3.2.1	수집 범위와 재개 가능한 실행	8
3.2.2	평가 문서의 실제 수집 절차와 설정	9
3.2.3	선별 문서 목록과 출처 관리	10
3.3	여러 형식의 문서 처리와 분할	10
3.3.1	공통 데이터 구조	10
3.3.2	형식과 품질에 따른 Cascade 파싱	10
3.3.3	표·절 구조 보존과 검색에 사용할 청크 선정	11
3.3.4	실제 표의 원문·Block·청크 연결	12
3.4	검색 후보 선정과 문맥 구성	14
3.4.1	BM25와 문서 다양성	14
3.4.2	복합 질문의 누락 근거 보완	14
3.4.3	기관 필터와 역할의 구분	15
3.4.4	최신성: 문서 시점 확인과 갱신 범위	15
3.5	근거 기반 생성과 문장별 판정	15
3.5.1	질문 요청과 답변 데이터의 형식	15
3.5.2	답변 문장과 근거의 일치 여부 확인	16
3.6	생성 전후 보안 검사	17
3.7	실제 질의의 검색·답변·인용 흐름	19
3.7.1	대학생활원 공지 확인 사례	19
3.7.2	출처를 확인하여 적용 범위 판단	20
3.8	사용자 인터페이스와 실패 대응	21
3.8.1	질문 작성에서 근거 확인까지	21
3.8.2	대화 기록과 요청 일관성	22

3.8.3	취소·연결 오류·근거 부족의 처리	22
3.9	규칙 기반 처리의 항목과 적용 범위	23
3.10	대표 설계 변경과 구현상의 판단	24
3.11	구성원 역할 및 수행 일정	25
4	연구 결과 분석 및 평가	26
4.1	평가 목적과 실험 구성	26
4.1.1	Q&A 평가셋의 출처와 구성	28
4.1.2	실험 기록과 재현 조건	29
4.2	문서 수집 결과와 파서 평가	29
4.2.1	수집·선별·파싱 결과	29
4.2.2	형식별 근거 보존	30
4.3	DEV45 검색 비교	31
4.3.1	9월 2일 검색 방식 비교	31
4.3.2	9월 4일 의도별 후속 검색 보완	32
4.4	DEV45 답변 생성과 출처 연결 평가	33
4.4.1	C0·C1의 독립 생성 비교	33
4.4.2	동일 답변에 대한 Judge 반복	34
4.4.3	C2의 주장·인용 동시 생성 실험	34
4.4.4	저장 초안의 후처리 진단	35
4.5	Shadow60의 검색·생성 진단	35
4.5.1	출처 분리와 검색 결과	35
4.5.2	생성 완결성과 결과	36
4.5.3	대표 실패 사례	36
4.6	보안 검사 파일럿	37
4.7	최종 holdout 평가와 사람 검수	39
4.7.1	평가셋과 실행 조건	39
4.7.2	자동 평가 결과	39
4.7.3	검색 단계와 생성·검증 단계의 분리	40
4.7.4	사람 1인 검수와 Judge의 일치도	42
4.8	종합 해석과 검증 범위	43
5	결론 및 향후 연구 방향	46
5.1	연구 결과 요약	46
5.2	향후 연구 방향	47
	참고문헌	49

제1장 서론

1.1 연구 배경

대학과 공공기관의 행정 업무에서는 답변의 자연스러움만큼 적용 대상, 시행 시점, 예외 조건을 정확하게 전달하는 일이 중요하다. 학생이 장학금 신청 자격을 확인하거나 연구자가 연구비 집행 절차를 찾을 때, 필요한 정보가 하나의 안내문에 모두 담겨 있지 않을 수 있다. 공지 본문에는 개요만 있고 신청 기간은 첨부 표에, 예외 조항은 별도의 규정이나 자주 묻는 질문에 제시된다. 사용자는 부서별 홈페이지를 이동하고 서로 다른 형식의 파일을 열어 관련 내용을 직접 연결해야 한다.

기관의 규정이 개정되거나 한시적 행정 지침이 함께 적용되면 문서를 찾은 뒤에도 어느 조건이 현재 업무에 해당하는지 확인해야 한다. 게시일이 최근이라는 이유만으로 모든 질문에 우선 적용할 수는 없으며 규정의 시행 시점과 안내문의 대상이 다를 수 있다. 따라서 본 과제는 문서 탐색과 함께 신청 대상·기간·예외를 확인하는 과정을 연구 대상으로 삼았다.

본 과제는 이러한 탐색 과정을 줄이기 위해 부산대학교 및 공공기관의 공식 문서를 검색하고 검색 근거에 연결된 답변을 제공하는 행정 문서 질의응답 시스템을 구현하였다. 과제팀의 명칭은 ‘무엇이든 물어보세’이며 구현 화면은 ‘PNU Docs’로 표시하였다. 사용자가 질문에 대한 답변과 함께 문장별 출처, 원문 발췌, 원문 링크를 확인할 수 있도록 구성하였다. 외부 문서를 찾아 생성 모델의 입력에 제공하는 검색 증강 생성(Retrieval-Augmented Generation, RAG)을 적용하였다[1]. 기관 문서의 수집·검색, 근거 기반 생성과 인용 검사를 연결한 RAG 응용 시스템이다.

시스템의 대상은 부산대학교에 한정되지 않는다. 금융감독원, 한국거래소, 한국예탁결제원, 한국은행, 한국인터넷진흥원, 한국해양과학기술원의 문서도 기관별로 구분하여 다룬다. 주요 정량 평가는 부산대학교 행정 문서로 구성된 개발용 질문과 개발에 사용하지 않은 별도 평가 질문을 대상으로 수행하였다.

1.2 기존 문제점

첫 번째 문제는 문서마다 형식과 구조가 다르다는 점이다. HTML, 텍스트 PDF, 스캔 PDF, HWP와 HWPX, Office 문서는 글과 표를 추출하는 방법이 서로 다르다. 같은 PDF에서도 문단 순서나 표의 행·열이 잘못 추출될 수 있다. 글자를 읽어 냈더라도 금액과 대상, 날짜와 절차가 잘못 연결될 수 있으므로 추출한 내용과 원문 위치를 함께 검사해야 한다.

두 번째 문제는 정답 문서를 찾아도 답변이 틀릴 수 있다는 점이다. 필요한 표의 행이나 예외 조항이 생성 모델에 전달되지 않으면 답변에서 해당 내용이 빠진다. 반대로 문서를 너무 많이 전달하면 중요한 정보를 놓치거나 다른 연도의 조건을 섞을 수 있다. 따라서 질문의 핵심 표현, 문서 제목과 연도를 확인하면서 필요한 내용을 골라야 한다.

세 번째 문제는 답변의 근거를 확인하기 어렵다는 점이다. 출처 목록만 붙이면 각 문장이 어느 자료를 바탕으로 작성되었는지 알기 어렵다. 문서 안에 “이전 지시를 무시하라”와 같은 공격 문구가 있으면 모델이 질문과 무관한 답을 할 수도 있다. 따라서 문서 내용과 모델이 따라야 할 지시를 구분하고, 답변에 붙인 인용이 원문과 맞는지 검사해야 한다.

네 번째 문제는 검색 성능과 답변 정확도를 구분해서 평가해야 한다는 점이다. 정답 문서가 검색 결과에 포함되어도 최종 답변이 정확하다는 뜻은 아니다. 개발 중 반복해서 사용한 질문에서 성능이 좋아졌더라도 새로운 질문에서는 그렇지 않을 수 있다. 본 과제는 검색, 답변 생성, 인용 연결, 보안 기능을 나누어 평가하고 각 실험의 질문 수와 조건을 함께 제시하였다.

1.3 연구 목표

본 과제의 목표는 기관의 행정 문서를 검색하고, 사용자가 답변의 근거를 직접 확인할 수 있게 하는 것이다. 이를 위해 여러 형식의 문서를 수집하고 필요한 문서를 골라 글과 표를 추출하였다. 문서 구조를 유지하며 검색용 조각으로 나눈 뒤 검색 인덱스를 만들고, 질문과 역할에 맞게 근거를 찾도록 하였다. 답변 생성 전후의 보안 검사와 원문 확인 화면도 구현하였다.

본 과제에서 확인하려는 질문은 다음과 같다. 첫째, 형식이 다른 한국어 행정 문서를 검색하고 원문 위치까지 보여 줄 수 있는가. 둘째, 질문 표현과 문서 특성에 맞춘 검색 규칙이 검색과 답변 품질을 높이는가. 셋째, 문서 속 공격 지시와 잘못된 인용을 검사하는 기능이 실제 답변 생성 과정에서 작동하는가. 넷째, 개발 중 확인한 개선이 다른 문서에서 만든 질문에도 나타나는가.

본 보고서는 실제로 구현한 기능과 저장된 실험 결과를 설명한다. 개발에 사용하지 않은 최종 평가 질문 36개에 대한 자동 평가와 개발자 1인의 채점 결과를 포함한다. 다만 독립된 두

표 1.1. 연구 목표

구분	구현 목표	확인 방법
문서 처리	여러 형식의 문서를 공통 구조로 변환하고 위치 정보를 보존	수집·파싱 산출물과 파서 비교
근거 검색	관련 문서와 필요한 내용이 검색되도록 후보를 구성	문서 적중률·순위·지정 근거 회수율
답변 제공	문장별 인용과 원문 확인 수단을 제공	실제 생성 기록·서비스 화면
입력과 출력 검사	문서 속 공격 지시 및 잘못된 인용을 검사	합성 기능 시험·생성 포함 소규모 보안 실험
평가 재현성	질문·코드·응답·판정과 실행 조건을 연결	실험별 산출물·해시·집계 기록

사람의 검수는 수행하지 못하였다. 문서의 수집 시점과 원문을 보여 주지만, 모든 규정의 최신 개정 내용을 자동으로 반영하거나 행정 판단을 대신하는 기능은 구현하지 않았다.

본 보고서에서 사용하는 주요 용어는 다음과 같다. **파싱**은 문서에서 글과 표를 추출하는 처리이며, **체크**는 검색을 위해 나눈 문서 조각이다. **문맥**은 답변 모델에 전달하는 근거 묶음을 뜻한다. **DEV**는 개발 중 반복해서 사용한 질문, **holdout**은 개발에 사용하지 않은 최종 평가 질문이다. **Judge**는 정해진 기준으로 답변을 채점하는 모델이다. **GFC**는 필요한 내용을 빠짐없이 정확하게 답하고 근거와 인용 조건도 충족한 답변의 비율이다.

제2장 연구 배경

2.1 검색 증강 생성과 문서 근거

RAG는 질문과 관련된 자료를 검색한 뒤, 그 자료를 생성 모델에 제공하여 답변하게 하는 방식이다[1]. 본 과제에서는 기관 문서에서 필요한 부분을 찾아 모델에 전달하고, 답변에 해당 출처를 연결하였다. 문서가 바뀌면 검색 인덱스를 다시 만들 수 있으며 사용자는 답변의 근거가 된 원문을 확인할 수 있다.

검색기는 모델에 보여 줄 자료를 고르고, 생성 모델은 그 자료를 바탕으로 답변을 작성한다. 잘못된 자료를 찾거나 필요한 조건을 빠뜨리면 모델이 글을 자연스럽게 써도 정확한 답을 하기 어렵다. 따라서 문서 수집과 추출, 근거 선택, 답변 확인을 함께 개선해야 한다. 본 시스템은 근거가 부족하면 확인된 부분만 답하거나 답변을 보류한다. 생성 호출에 실패하면 검색 원문의 내용을 추려서 보여 주는 대체 응답을 제공한다.

2.2 어휘 검색과 의미 검색

BM25는 질문에 쓰인 단어가 문서에 얼마나 자주 나오는지, 다른 문서에서는 얼마나 드문지, 문서가 얼마나 긴지를 고려해 순위를 매기는 검색 방식이다[2]. 사업명·기관명·규정명·연도처럼 정확히 일치해야 하는 표현을 찾을 때 비교 기준으로 삼을 수 있다. 본 시스템의 기본 검색은 SQLite FTS5의 BM25를 사용한다.

Dense 검색은 질문과 문서를 숫자 벡터로 바꾼 뒤 의미가 가까운 문서를 찾는 방식이다. 단어가 달라도 뜻이 비슷한 표현을 찾는 데 목적이 있다. DPR은 질문과 문서를 각각 벡터로 변환하는 두 인코더를 사용하였다[3]. 본 과제에서는 한국어 임베딩 모델로 의미 검색 기능을 구현하고, 같은 문서 집합에서 BM25와 비교하였다.

BM25 점수와 벡터 유사도는 값의 범위가 달라 그대로 더하면 한쪽 검색 결과의 영향이 지나치게 커질 수 있다. RRF(Reciprocal Rank Fusion)는 점수 대신 각 검색 결과의 순위를 합치는 방법이다[4]. 후보 문서 d 의 점수는 각 검색기의 순위 r 을 이용한 $1/(c+r)$ 을 더해 계산한다. c

는 상위 순위의 영향을 조절하는 양의 상수로, Hit@k에서 검색 개수를 뜻하는 k와 다르다. 본 과제는 이 방법으로 단어가 일치하는 결과와 의미가 비슷한 결과를 함께 사용하였다.

기본 서비스와 별도 실험의 조건은 구분하였다. 주요 성능 비교에서는 Cascade 파서와 BM25 검색을 그대로 두고 검색 규칙 적용 전후를 비교하였다. Dense·Hybrid 검색과 연구비 규정의 검색 순서 조정은 별도 조건에서 실험했으며 기본 서비스에 모두 적용한 것은 아니다.

2.3 문서 분할과 문맥 구성

긴 문서는 검색 단위인 청크로 분할한다. 청크를 지나치게 짧게 나누면 조건과 예외가 떨어지고 지나치게 길게 나누면 핵심 정보의 비중이 작아질 수 있다. 본 과제에서는 문서 제목, 절의 경로, 표 여부, 페이지나 청크 위치를 보존하여 검색 결과를 원문에 다시 연결할 수 있도록 하였다.

긴 입력에서는 관련 정보의 위치에 따라 모델의 활용 능력이 달라질 수 있다[5]. 본 시스템은 문서별 청크 수를 제한하여 특정 문서가 문맥을 독점하지 않도록 하고 필요한 경우 같은 문서의 인접 구간을 이용하여 질문이 요구한 서로 다른 항목을 보완한다. 문맥은 질문에 필요한 근거를 중심으로 구성한다.

2.4 답변 품질과 자동 평가

RAG의 평가는 검색과 생성을 나누어야 한다. RAGAS는 검색된 문맥의 적절성, 응답의 근거성, 질문과의 관련성 등 구성 요소별 평가의 필요성을 제시하였다[6]. 본 과제는 검색에 문서 적중률과 순위 지표를 적용하고, 답변에는 자체 평가표의 0~2점 점수와 근거 충족 완전정답률(GFC)을 사용한다. GFC(Grounded Full-Correct Rate)는 본 과제에서 정의한 지표로, 필요한 내용을 빠짐없이 정확하게 답하고 근거와 인용 조건을 충족한 답변의 비율이다.

LLM을 사용하면 여러 답변을 같은 평가표로 채점할 수 있다. 다만 답변의 순서·길이·모델 계열에 따라 판정이 달라지는 편향이 보고되었다[7]. 본 과제는 답변 생성과 채점에 같은 Gemini 계열을 사용했으므로 자동 점수를 사람의 정답 판단과 같다고 보지 않았다. 같은 질문을 여러 번 생성한 것은 답변이 얼마나 달라지는지 보기 위한 것이며, 반복 응답을 서로 다른 질문으로 세지는 않았다.

2.5 문서 속 공격 지시와 대응 방법

프롬프트 주입은 입력에 섞인 명령으로 모델이 원래 지시와 다른 행동을 하도록 유도하는 공격이다. Perez와 Ribeiro의 *Ignore Previous Prompt*는 목표와 다른 출력을 유도하는 목표

탈취(goal hijacking)와 원래 프롬프트를 노출시키는 프롬프트 유출(prompt leaking)을 구분하고 PromptInject 실험 틀을 제시하였다[8]. 예를 들어 “앞의 지시를 무시하고 지정한 문구만 출력하라”는 문장은 답변의 목표를 바꾸려는 지시이다. 이 논문은 악성 지시문을 설명하는 근거 문헌이며, 본 과제의 평가 문항을 그대로 가져온 데이터셋 출처는 아니다.

검색 시스템에서는 사용자가 직접 쓴 질문뿐 아니라 검색된 문서도 공격 경로가 될 수 있다. Greshake 등의 연구는 외부 콘텐츠를 통해 모델 동작을 바꾸는 간접 프롬프트 주입을 다루었다[9]. 본 과제의 문서 내부 공격 실험은 이 위협 상황에 해당한다. 문서 본문과 파일명은 답변 자료이지 모델의 역할을 바꾸는 명령이 아니다. 따라서 생성 전에 문서 속 공격 지시를 검사하고, 생성 후에는 답변 형식과 인용이 원문에 연결되는지 검사한다.

인용문이 원문에 있고 파일 식별값이 맞더라도 답변이 정답이라는 뜻은 아니다. 해당 문장이 질문의 대상·연도·조건을 실제로 뒷받침하는지 따로 확인해야 한다. 본 과제에서는 공격 지시 차단, 인용 연결 검사, 의미적 정답 평가를 구분하였다.

제3장 연구 내용

3.1 시스템의 전체 구조와 구현 범위

웹 기반 질의응답 시스템은 기관 문서를 검색하여 한국어 답변과 근거를 제공한다. 사용자가 원문과 적용 범위를 확인할 수 있도록 문서 수집부터 답변의 출처 표시까지 문서 식별자와 원문 위치를 유지하였다.



그림 3.1. 문서 준비와 질의응답을 분리한 시스템 구성

그림 3.1과 같이 시스템은 문서를 미리 준비하는 단계와 질문을 받아 답하는 단계로 나뉜다. 먼저 공식 웹페이지와 첨부파일을 수집하고, 수집 범위와 파일 상태를 확인하며 중복을 제거

한다. 문서에서 글과 표를 추출한 뒤 검색용 청크로 나누고 품질 검사를 통과한 결과로 검색 인덱스를 만든다.

질문이 들어오면 기관·역할 설정에 맞게 자료를 검색하고 부족한 근거를 보완한다. 생성 전에 문서 속 공격 지시를 검사하고, 생성 후에는 답변 문장과 인용이 원문에 맞는지 확인한다. 미리 만든 인덱스를 사용하므로 질문할 때마다 문서를 다시 처리할 필요가 없다. 파서·검색기·생성기의 입출력 형식도 맞추어 같은 조건에서 비교할 수 있게 하였다.

대표 서비스는 부산대학교 문서에 Cascade 파싱과 BM25 검색을 적용한 구성이다. Dense 검색, 순위 융합 및 재정렬도 선택 가능한 경로로 구현하였다. 또한 기관 메타데이터와 필터를 통해 금융감독원·한국은행·한국거래소·한국예탁결제원·한국인터넷진흥원·한국해양과학기술원 문서를 구분할 수 있도록 하였다.

표 3.1에 주요 기술과 기능을 정리하였다. 파서와 생성기는 문서 형식·추출 품질·실행 설정에 따라 선택한다. 성능 비교에 사용한 코드, 이후 보안 기능을 합친 코드, 보안 결함을 고친 실험용 코드는 서로 구분하였다. 실험용 수정 사항을 현재 서비스에 반영한 기능으로 설명하지 않는다.

표 3.1. 계층별 기술 구성과 담당 기능

계층	주요 기술	담당 기능
사용자 화면	React · TypeScript · Vite	질문 작성, 답변·인용·원문 표시, 브라우저 대화 기록
질의 API	Python ThreadingHTTPServer · JSON	기관·역할·검색·생성 설정을 받아 질문별 독립 요청 처리
검색 저장소	SQLite · FTS5 BM25	청크·메타데이터 색인과 근거 검색; Dense·Hybrid는 선택 경로
문서 처리	PyMuPDF · pdfplumber, Docling · PaddleOCR, hwpplib · hwpplib 등	파일 형식·페이지 특성·추출 품질에 따라 파서와 대체 경로 선택
답변 생성	OpenAI 호환 서버 · Gemini API · 추출형 대체	공통 입출력 형식으로 근거 전달, 답변 생성과 실패 시 대체 처리
소프트웨어 검증	Python unittest · Vitest · TypeScript · ESLint	회귀 테스트, 타입 검사, 프론트엔드 검사와 빌드

3.2 공식 문서 수집과 평가 문서 선정

3.2.1 수집 범위와 재개 가능한 실행

대학의 공지와 규정은 중앙 홈페이지 외에도 학사·입학·취업·기숙사·국제교류·학생지원 사이트와 학과 게시판에 흩어져 있다. 처음에는 pusan.ac.kr과 하위 사이트에서 수집하였다.

이후 서비스에 사용할 문서를 고를 때 허용한 웹사이트 주소 16개와 주제 조건을 적용하였다. 주소에 학교 이름이 들어 있다는 이유만으로 허용하지 않고 실제 응답 주소와 파일 형식을 확인한다. HTML 본문과 PDF·HWP/HWPX·Office 첨부파일을 수집하며, 허용하지 않은 이미지·동영상·압축파일·실행파일은 제외한다. 파서가 이미지에서 글을 읽을 수 있더라도 웹 수집기가 이미지를 수집하도록 설정한 것은 아니다.

수집 상태는 SQLite의 URL 큐에 기록한다. 방문 여부와 처리 상태를 남기므로 네트워크 오류나 실행 중단 후에도 미완료 주소부터 재개할 수 있다. robots.txt와 호스트별 요청 간격을 기본적으로 적용하고 페이지·첨부파일 수와 다운로드 용량에 상한을 둔다. 동일 출력 경로를 여러 수집기가 동시에 변경하는 문제는 파일 잠금으로 방지하였다. 수집 범위 설정의 해시도 함께 저장하여 실행 중 범위가 바뀌었을 때 서로 다른 수집 결과가 동일 작업으로 섞이지 않도록 하였다.

3.2.2 평가 문서의 실제 수집 절차와 설정

평가에 사용한 부산대 수집 기록은 2026년 7월 24일 17시 34분부터 7월 25일 03시 48분까지의 완료 항목을 포함한다(한국 시간). 대표 홈페이지, 대학생활 안내, 공지사항, 학사일정의 네 주소를 시작점으로 삼았다. 실제 처리 순서는 다음과 같다.

1. 시작 페이지에서 HTML 링크와 첨부파일 주소를 읽어 URL 대기열에 넣는다. 허용 도메인, 탐색 깊이, 이미 방문한 주소인지 확인한다.
2. robots.txt를 확인하고 호스트별로 1.5초 간격을 두어 요청한다. 응답 제한시간은 20초, 재시도는 2회이며 처리 상태를 SQLite에 저장해 중단 후 이어서 실행한다.
3. 내려받은 파일의 주소·응답 형식·실제 경로·크기·수집 시각·SHA-256을 기록한다. SHA-256은 같은 내용의 파일인지 확인하는 식별값이다.
4. 완료된 자료에 서비스 호스트와 주제 조건을 적용하고, 같은 게시물의 주소 변형과 내용이 같은 파일을 정리한다. 최종 선택 결과는 원본 경로를 가리키는 목록 파일(manifest)로 고정한다.
5. 선별한 문서를 형식별로 파싱하고 검색용 조각인 청크로 나눈 뒤, 품질 검사를 통과한 청크를 색인에 넣는다.

초기 수집 설정의 최대 깊이는 6, 응답 하나의 최대 크기는 50MiB였다. 실행당 웹페이지 5,000개·첨부파일 3,000개·호스트당 페이지 500개의 상한을 사용했다. 수집을 재개해 누적한 완료량은 10,977개이므로 실행 한 번의 상한과 누적 수집량을 구분해야 한다. 누적 수집에는

100개 호스트가 나타났고, 후속 선별은 16개 호스트를 허용했으며 실제 최종 문서는 그중 12개 호스트에서 선택되었다. 초기 탐색 범위와 최종 서비스 범위는 동일하지 않다.

원본 수집량, 최종 문서 수와 용량은 표 4.4에 제시한다. 이 통계는 부산대 평가 문서에 한정하며 다른 공공기관의 문서량을 합산한 값이 아니다.

3.2.3 선별 문서 목록과 출처 관리

내려받은 파일을 모두 검색에 사용하는 것은 아니다. 수집 완료 여부, 실제 파일 위치, 확장자와 응답 형식(MIME), 크기, SHA-256, 허용한 사이트인지를 확인한다. 학과 게시판 자료는 행정 주제에 해당하는지도 확인한다. 같은 게시물로 이어지는 여러 주소는 대표 주소로 묶고, 내용이 같은 파일은 해시를 비교해 중복을 제거한다.

선별한 문서는 원본 파일의 위치를 가리키는 목록 파일(manifest)로 관리한다. 원본을 다시 복사하지 않고, 원문·첨부파일 주소, 기관, 파일명, 수집 시점, 선택·제외 사유를 목록에 남긴다. 수집 시각과 게시 시각의 실제 기록 상태는 3.4.4절에서 설명한다. 파서 비교에서는 이 목록에 있는 같은 문서를 세 파서에 제공하여 문서 수 차이가 결과에 영향을 주지 않게 하였다.

3.3 여러 형식의 문서 처리와 분할

3.3.1 공통 데이터 구조

PDF에서 추출한 문단, HWP의 표, HTML의 제목은 서로 다른 형태로 반환된다. 이를 그대로 검색기로 전달하면 파서마다 별도 처리 코드가 필요하고 출처 위치도 일관되게 표시하기 어렵다. 본 시스템은 모든 파서 출력을 공통 Block 구조로 변환하고 원본 문서·블록·청크·인용의 연결을 유지하였다. 표 3.2는 단계 간 연결에 사용하는 핵심 데이터와 역할을 정리한 것이다.

Block에는 11개 항목을 저장한다. 문서 ID와 블록 ID는 반드시 있어야 하고, 읽기 순서는 0 이상의 정수여야 한다. 페이지를 알 수 있으면 1부터 시작하는 번호를 기록한다. 표 셀에는 표 ID와 행·열 번호도 기록한다. 원문에서 위치를 얻지 못한 경우에는 빈 값으로 남긴다. 이 형식을 검사하여 글은 추출되었지만 출처를 찾을 수 없는 결과가 다음 단계로 넘어가지 않게 하였다.

3.3.2 형식과 품질에 따른 Cascade 파싱

파싱은 Baseline, Challenger, Cascade의 세 가지 구성으로 나누었다. Baseline은 기본 추출 방식, Challenger는 대안 추출 방식이다. Cascade는 문서 특성과 추출 품질을 보고 필요한 파서를 선택하거나 결과를 보완한다. 세 구성의 입출력 형식을 맞추어 이후의 문서 분할·

표 3.2. 문서 처리와 답변 근거를 연결하는 공통 데이터 구조

구조	핵심 필드	보존하는 정보와 활용
원본 문서	document_id, institution, source_title, source_url, source_sha256	문서의 소속·제목·원문 주소와 파일 무결성
Block 식별·내용	document_id, block_id, block_type, text	문단·제목·목록·표 등 추출 요소의 식별과 내용
Block 순서·위치	parser, reading_order, page, section_path	추출기, 읽기 순서, 페이지와 제목 계층
Block 표 구조	table_id, row, column	표와 셀의 관계 및 행·열 위치
검색 청크	chunk_id, doc_id, metadata.block_ids, 위치·출처 메타데이터	검색 단위와 그 내용을 구성한 원문 요소의 연결
주장·인용	text, supported, source_numbers, chunk_id, excerpt, excerpt_sha256	답변 문장의 판정과 출처 번호·발췌문·해시의 연결

인덱스 생성·검색은 같은 절차로 처리한다. 확장자가 잘못 붙은 파일도 확인할 수 있도록 실제 파일 형식도 검사한다.

Cascade의 PDF 처리는 PyMuPDF를 이용한 기본 텍스트 추출과 페이지 특성 확인에서 시작한다. Docling의 구조 추출 결과와 PaddleOCR 계열의 OCR 결과 중 페이지 특성에 맞는 결과를 선택·결합한다. 이는 페이지별 결과 채택 방식이며 외부 파서를 해당 페이지에만 호출한다는 의미는 아니다. pdfplumber의 표 추출 결과를 보완적으로 사용하고 품질이 부족한 경우 추가 추출 경로를 시도한다.

HWP/HWPX는 Java 기반 hwplib·hwpplib를 우선 사용하며 unhwplib와 Tika를 대안으로 둔다. HTML은 DOM 기반으로 본문을 추출하고 Office 문서는 형식별 전용 라이브러리와 XML 처리 경로를 사용한다. 추출된 블록에는 사용한 파서명을 남겨 문제가 발생한 문서가 어떤 경로를 거쳤는지 확인할 수 있게 하였다. 이후 추출 결과의 구조와 내용을 검사한다.

3.3.3 표·절 구조 보존과 검색에 사용할 청크 선정

청크 하나의 기본 길이 제한은 1,800자다. 일반 문단은 같은 절 안에서만 합치고 표는 본문과 따로 청크를 만든다. 하나의 블록이나 표의 행이 길이 제한을 넘으면 나누되, 앞뒤 내용이 끊기지 않도록 최대 250자를 겹쳐 넣는다. 이 겹침은 길이 제한을 넘는 부분에만 적용한다.

긴 표는 행을 기준으로 분할하고 머리글 정보가 있으면 각 부분에 반복한다. 예를 들어 일정표의 두 번째 부분만 검색되더라도 해당 날짜가 신청 기간인지 납부 기간인지 구분하는 데 필요한 열 이름을 함께 제공하도록 한 것이다. 표 전체와 표 셀을 동시에 색인하여 같은 문구가

중복 검색되는 문제도 피하였다. 머릿글 보존은 파싱 결과에 의존하므로 추출 단계의 품질도 함께 확인한다.

품질 검사에서는 추출 성공 여부, 데이터 형식, 글의 길이, 문자 깨짐, 한국어 비율, 표의 추출 여부, 읽기 순서를 확인한다. 결과는 정상·검토 필요·중대한 실패로 나눈다. Corpus Gate는 이 결과를 바탕으로 검색에 사용할 청크를 고르는 기능이다. 정상 결과는 사용하고, 검토 필요 결과는 이를 허용한 실행에서만 사용한다. 대표 시연 인덱스에도 이 조건을 적용했으며 중대한 실패는 제외하였다. 청크가 다른 문서의 블록이나 제외된 블록을 가리키면 인덱스 생성을 중단한다.

3.3.4 실제 표의 원문·Block·청크 연결

그림 3.2는 「2026학년도 2학기 재학생 등록금 납부 계획」 1쪽의 신용카드납부 표를 처리한 실제 저장 결과이다. 무이자 할부기간은 농협은행 3개월, 부산은행 4개월, 하나은행 3개월이다. 세 `table_cell` Block에는 원문의 값과 `row=2`, `column=1·2·3`이 기록되어 있다. 행과 열 번호는 0부터 시작하며 같은 표 ID, 페이지, 절 경로를 공유한다.

검색 청크는 표 전체를 담은 `table` Block을 참조하며, 저장된 청크 본문과 표 Block의 본문은 일치한다. 표 ID와 1쪽이라는 위치 정보도 인덱스와 저장 검색 기록에 유지된다. 이 청크의 검색 위치는 표 단위이므로 셀 Block의 행·열 값이 그대로 답변의 셀 단위 인용이 되는 것은 아니다. 같은 문서의 다른 일정 표에서는 저장된 열 순서가 원문과 어긋난 사례도 확인되어, 위치 필드의 존재와 표 구조의 정확성은 구분하여 검수해야 한다.

1 원문 PDF의 표

2026학년도 2학기 재학생 등록금 납부 계획 · 1쪽 · 신용카드납부

구 분	농협은행	부산은행	하나은행
지정 카드	BC카드, NH카드	BC카드	BC카드, 하나카드
무이자 할부기간	3개월	4개월	3개월
최장할부기간	6개월	12개월	15개월



2 공통 Block 레코드: 표와 셀의 위치

page = 1 section_path = ["2. 신용카드납부"]
table_id = …:t0001 표 Block = …:b000032

셀 Block ID	row	column	text
…:b000042	2	1	3개월
…:b000043	2	2	4개월
…:b000044	2	3	3개월

row와 column은 0부터 시작하는 저장 값이다.



3 검색 청크: 표 본문과 원문 위치의 연결

chunk_id = …#0007 block_ids = […:b000032]
table_ids = […:t0001] page_start = page_end = 1

청크 본문 발췌 (첫째·셋째 줄, |는 탭 구분자 표시)

구 분	농협은행	부산은행	하나은행
무이자 할부기간	3개월	4개월	3개월

ID 앞부분 생략: doc_4ce82561e3e142c4f92fe306:casca

그림 3.2. 등록금 납부 안내의 원문 표·Block·검색 청크 연결

3.4 검색 후보 선정과 문맥 구성

3.4.1 BM25와 문서 다양성

검색 데이터는 SQLite에 저장하고 FTS5의 BM25로 찾는다. 본문뿐 아니라 기관명·파일명·문서 제목·분류·경로도 검색에 사용한다. 한국어는 연속된 두 글자 단위(bigram)도 함께 비교하여 표현이 일부만 겹쳐도 찾을 수 있게 하였다. 기관을 선택하면 그 기관의 문서에서 검색한다. 한 문서의 비슷한 내용이 상위 결과를 채우지 않도록 문서별 청크 수를 제한하며, 대표 구성에서는 문서당 두 개를 사용한다.

질문을 그대로 검색하면 일상 표현과 행정 문서의 표현 차이 때문에 필요한 자료를 놓칠 수 있었다. 이를 줄이기 위해 질문 표현을 정리하고 필요하면 관련 검색어를 추가하였다. “알려줘”와 같은 어미에서 생긴 검색어와 관련성이 낮은 일반 안내 문서의 영향도 줄였다. 질문의 연도와 문서 제목의 연도가 다르면 순위를 낮추는 규칙을 적용하였다. 대표 규칙은 3.9절에, 규칙 적용 전후의 성능은 4장에 제시한다.

두 글자 단위 검색과 검색어 추가는 표현 차이를 일부 보완하지만 자동 오타자 교정 기능은 아니다. 자동 교정을 도입하려면 기관명·연도·자격 조건까지 잘못 바꾸는지 별도로 확인해야 한다.

3.4.2 복합 질문의 누락 근거 보완

검색된 문서가 정답 문서여도 생성기에 전달한 부분에 필요한 정보가 모두 있다는 보장은 없다. 예를 들어 신청 경로와 납부 기간을 함께 묻는 질문에서 상위 두 청크가 신청 경로만 반복하면, 문서는 찾았지만 질문의 절반에 필요한 근거가 빠진다. 이를 위해 질문이 요구하는 시간·금액·대상·절차 등의 항목을 확인하고 인접 문맥을 보완하는 단계를 두었다.

명시적인 복합 질문에서 같은 문서의 후보가 특정 항목을 중복 제공할 때에는 기여가 낮은 청크를 누락 항목의 인접 청크로 교체할 수 있다. 문서당 상한을 유지하며 질문과 인접 근거의 학년도·학기가 충돌하는 경우에는 교체하지 않는다. 이후 정확히 같거나 유사한 근거를 제거하고 요청한 수의 최종 문맥을 선택한다. 후보 검색, 인접 보완, 중복 제거를 구분하여 기록하므로 검색 실패와 문맥 구성 실패를 따로 진단할 수 있다.

Dense 단독 모드는 벡터 검색 결과를 사용하고, 하이브리드 모드는 BM25 점수와 벡터 유사도를 직접 더하지 않고 RRF로 두 검색 결과의 순위를 결합한다. 같은 청크는 검색기별로 한 번만 집계하고 검색기의 실패와 융합·재정렬 상태를 구분한다. 한국어 임베딩 기반 모드도 선택할 수 있도록 인터페이스를 마련했으나, 해당 인덱스의 준비 상태를 확인한 뒤 사용한다.

3.4.3 기관 필터와 역할의 구분

기관 필터는 검색할 기관을 정하는 기능이고, 역할은 검색 순서와 설명 방식을 조정하는 설정이다. 학생·행정직원·연구자와 기관별 직원 역할을 미리 정의하였다. 사용자가 직접 입력한 역할은 기관명과 신분 관련 단어를 보고 가장 가까운 역할로 바꾸며, 판단하기 어려우면 일반 사용자로 처리한다. 기관을 따로 선택하지 않은 경우에만 역할과 관련된 기관의 문서를 앞에 배치한다. 이때 다른 기관의 문서를 삭제하지는 않는다.

역할은 서버에 미리 작성한 설명 문장으로 바꾸어 생성 모델에 전달한다. 이를 통해 역할 입력란에 임의의 지시를 넣는 것을 제한하였다. 역할 설정은 답변의 설명 관점을 정할 뿐, 사용자의 실제 신분을 확인하거나 문서 접근 권한을 부여하는 기능은 아니다.

3.4.4 최신성: 문서 시점 확인과 갱신 범위

본 시스템은 수집 시각을 보존하고 질문과 근거의 적용 시점이 충돌하는지 확인하는 방식으로 최신성을 다룬다. 수집 시각(`fetch_at`)과 게시 시각(`published_at`)은 별도 필드이며, 평가에 사용한 선별 문서 목록 2,260건에는 수집 시각이 모두 기록되어 있으나 게시 시각은 0건이다. 현재 선별기는 게시 시각을 자동 추출하지 않으므로 수집일을 게시일이나 최신 개정일로 해석하지 않는다.

문서 갱신은 수집·선별·파싱과 색인 생성을 명령으로 다시 실행하는 방식이다. 앞서 설명한 연도 충돌 후보 강등과 복합 질문의 학년도·학기 충돌 검사는 다른 시기 자료의 혼입을 줄이기 위한 규칙이다. 생성기에도 상충 자료를 임의로 최신이라고 판단하지 않도록 지시한다. 다만 규정의 개정일·시행일·효력 종료일과 개정본 간 관계를 관리하거나 변경을 주기적으로 감지하여 자동 갱신하는 기능은 구현하지 않았다. 제목의 숫자와 학년도를 잘못 해석한 사례는 4.5.3절에서 다룬다.

3.5 근거 기반 생성과 문장별 판정

3.5.1 질문 요청과 답변 데이터의 형식

프론트엔드는 질문과 설정을 `POST /chat`에 JSON으로 전달하고 서버는 요청값과 준비 상태를 확인하여 인덱스와 생성기를 선택한다. 표 3.3은 주요 필드를 묶어 정리한 것이다. 화면의 답변과 근거 패널은 같은 응답을 사용하여 서로 다른 질문의 결과가 섞이지 않도록 하였다.

생성 프롬프트는 검색된 근거에서 직접 확인되는 사실만 사용하도록 구성하였다. 날짜·시간·금액·대상·신청 경로·예외 조건을 보존하고 여러 항목 중 일부만 확인되면 확인된 내용과

표 3.3. POST /chat의 주요 요청·응답 필드

구분	주요 필드	역할
요청: 질문·범위	question, institution, role	질문, 검색 기관, 답변 관점 지정
요청: 검색	top_k, parser_profile, retrieval_mode	근거 개수, 파서별 인덱스, 검색 방식 선택
요청: 생성	provider, model	생성 제공자와 허용된 모델 선택
응답: 답변	answer, cited_answer	일반 답변과 인용 번호가 연결된 답변
응답: 근거	claims, citations, results	문장별 판정, 인용 객체, 검색 근거 목록
응답: 진단	generator, generation, retrieval, postprocessing	사용 생성기, 생성·검색 진단과 후처리 정보

부족한 내용을 구분하여 답하도록 한다. 상충 자료가 있을 때 임의로 최신 문서라고 판단하지 않도록 명시하였다. 문맥 길이, 출력 토큰 수, 제공자별 제한시간과 전체 마감시간도 설정하여 요청 하나가 무한히 처리되지 않게 하였다. 현재 문맥과 출력 상한은 실행 설정으로 정하며 질문의 복잡도에 따라 입력·출력 토큰을 자동 배분하는 기능은 구현하지 않았다.

3.5.2 답변 문장과 근거의 일치 여부 확인

생성 모델이 작성한 초안을 각각 확인할 수 있는 문장으로 나누고 검색 원문과 비교한다. 답변 문장이 전달하는 사실을 이하에서는 ‘주장’이라고 부른다. 단어의 겹침, 날짜·시간·금액, 대상과 조건, 허용·금지 및 이상·이하 관계를 규칙으로 검사한다. 같은 숫자가 원문 어딘가에 있다는 이유만으로 통과시키지 않도록, 그 숫자가 어떤 대상에 해당하는지도 제한적으로 확인한다. 현재는 최대 여덟 주장을 처리하며 상한 때문에 빠진 수를 처리 기록에 남긴다.

근거가 확인된 문장에는 최대 두 개의 청크를 연결하고 최종 답변을 다시 구성한다. 출처 번호는 모델이 임의로 붙이지 않고 서버가 검사 결과에 따라 부여한다. 원문 발췌, 청크·문서 ID, 페이지·절 위치도 함께 전달한다. 한 청크에 여러 블록이 들어 있으면 위치도 여러 개 표시될 수 있으므로, 화면의 위치 개수가 문서 개수를 뜻하지는 않는다.

이 검사는 사람이 정한 규칙으로 문장과 근거를 비교하는 보조 기능이다. 문장의 의미를 판단하도록 학습한 별도 모델은 사용하지 않았다. 화면에 쓰는 신뢰도 값도 정답일 확률이 아니라 내부 계산 점수다. 맞는 말을 다르게 표현한 문장이 제거되거나 복잡한 예외 조건을 놓칠 수 있다. 따라서 인용이 붙었다는 사실만으로 정확성을 보장하지 않으며, 사용자가 원문과 검사 이유를 함께 확인할 수 있게 하였다.

3.6 생성 전후 보안 검사

문서 품질 검사(Corpus Gate)와 별도로 생성 전후의 보안 검사 두 가지를 구현하였다. 생성 전에는 검색 자료에 모델의 행동을 바꾸려는 지시가 있는지 검사하고, 생성 후에는 인용이 원문에 올바르게 연결되는지 검사한다. 공식 사이트에서 가져온 문서라도 그 안의 명령을 모델이 따라서는 안 되기 때문이다. 이 절은 서비스 코드에 합친 보안 버전을 설명하며, 앞선 성능 비교 코드와 별도 수정 실험 코드는 구분한다.

생성 전 검사(Context Gate)는 검색된 본문과 미리보기에서 지시 변경, 비밀 출력, 도구 실행, 인용 조작 등의 문구를 찾는다. 전각 문자와 같은 표기 차이를 통일하는 NFKC 처리를 하고, 보이지 않는 서식 문자를 제거한 뒤 검사한다. 탐지 점수가 0.85 이상이면 해당 자료를 제외한다. 그보다 낮은 점수의 공격 의심 문구는 생성용 사본에서 정리하고, 다시 검사해도 탐지되면 제외한다. 기존 처리 기록에 원본 검증 실패나 악성 검사 실패가 있으면 제외하지만, 이 기능이 직접 악성코드 검사를 수행하지는 않는다.

생성 모델에 보여 줄 사본과 인용을 검사할 원문은 따로 관리한다. 허용된 문서의 원문은 그대로 두고 모델에는 정리한 사본을 전달한다. 제외한 문서는 양쪽에서 모두 지우고, 남은 근거의 번호와 순서는 같게 맞춘다. 근거가 하나도 남지 않으면 모델을 호출하지 않고 확인할 수 없다고 답한다. 프롬프트에도 검색 자료는 참고할 내용이며 따라야 할 지시가 아님을 표시한다.

처리 기록에는 허용·정리·제외한 자료의 수와 이유를 남긴다. 관측 모드는 검사 결과만 기록하고 입력 자료는 바꾸지 않는다. 입력 검사를 꺼도 출력 검사와 프롬프트의 지시 구분까지 함께 꺼지는 것은 아니다.

생성 후 검사(Output Gate)는 문장별 근거 확인이 끝난 답변의 인용을 검사한다. 청크 ID가 허용된 원문에 있는지, 출처 번호가 정수이며 같은 청크를 가리키는 지, 발췌문의 SHA-256이 저장된 값과 같은지 확인한다. 문자 표기와 공백을 통일한 뒤 발췌문이 실제 원문에 포함되는지도 확인한다. 답변·인용 데이터의 형식이 잘못되었거나 유효하지 않은 인용이 있으면 답변을 보류하고 인용 목록을 비운다. 근거가 확인된 문장 비율에 따라 전체 답변·부분 답변·보류로 표시한다. 이 검사는 출처 연결을 확인하는 것이므로, 내용이 질문에 대한 정답인지 새로 판단하는 기능은 아니다.

서비스에 합친 보안 코드에서는 세 가지 문제가 확인되었다. 공격과 무관한 금지 문장이 있으면 공격 탐지를 건너뛸 수 있었고, 파일명·절 제목의 공격 문구를 검사하지 못했다. 인용 처리와 출력 검사에서 페이지 표시를 지우는 방식도 달랐다. 별도 실험용 코드에서는 예외를 적용할 범위를 좁히고 두 기능이 같은 필드를 검사하도록 맞추었다. 출력 검사에서는 페이지 표시 처리와 공백뿐인 인용의 거부도 보완하였다. 이 수정 사항은 현재 서비스에 반영한 기

생성용 문맥과 검증용 원문의 분리




그림 3.3. 생성용 정제 사본과 검증용 원문을 분리하는 보안 검사 흐름

능으로 포함하지 않는다. 규칙에 없는 공격 표현과 정상 문서를 잘못 차단하는 문제도 추가 검증이 필요하다.

3.7 실제 질의의 검색·답변·인용 흐름

3.7.1 대학생활원 공지 확인 사례

“2026학년도 2학기 대학생활원 공지는 어디서 확인하고 개별 문자도 보내줘?”라는 질문으로 실제 처리 과정을 확인하였다. 2026년 9월 9일 보안 기능을 합친 코드에서 Gemini 3.5 Flash-Lite가 생성한 응답이며, 원문 추출형 대체 응답은 사용하지 않았다. 그림 3.4는 이때 저장한 답변과 근거를 현재 화면의 별도 사본에 표시한 것이다. 화면을 촬영하기 위해 답변을 새로 생성하지는 않았다.




그림 3.4. 현재 사용자 화면에 표시한 저장 질의와 인용 답변

요청에는 Cascade 파서와 BM25 검색이 사용되었다. 검색 기록에서 BM25 후보는 31개이며 Dense와 재정렬은 비활성 상태였다. 문맥 중복 제거 단계는 후보 31개 중 정규화 후 같은 내용인 일곱 개를 중복으로 판정하고 최종적으로 일곱 문서의 여덟 청크를 선택하였다. 고유 후보 24개 중 16개는 최종 문맥에 포함되지 않았다. Context Gate는 여덟 개를 검사하여 모두 허용했고 정제·제외는 발생하지 않았다. 그림 3.5는 이 단일 질의의 단계별 기록이며 단계별 성능이나 평균 처리량을 나타내지 않는다.

첫 번째 근거는 「2026년도 2학기 대학생활원 부산캠퍼스 비원생 모집요강.pdf」의 19쪽, ‘1. 공지관련 사항’이다. 원문에는 부산 대학생활원 홈페이지 공지사항, 각 동 게시판, 대학생활원 앱으로 공지를 확인하며 개별 통보는 하지 않는다고 명시되어 있다. 이어 전용 앱을

질의 요지: 대학생활원 공지 확인 방법과 개별 통보 여부



단일 질의의 저장 진단 기록이며, 성능 개선율이나 전체 정확도를 나타내지 않는다.

그림 3.5. 대학생활원 질의의 검색 후보 축소와 최종 검증 기록

내려받아 공지사항을 확인하라는 안내가 있다. 같은 모집요강의 다른 청크와 HWP 자료도 함께 검색되어 관련 안내를 제공하였다.

생성 결과는 공지 확인 경로, 개별 통보 여부, 앱 설치 안내의 세 문장으로 정리되었다. 서버는 첫 문장과 세 번째 문장에 출처 [1]·[2], 두 번째 문장에 [2]·[3]을 연결하였다. 세 주장 모두 근거 판정을 통과했고 Output Gate는 잘못된 인용을 발견하지 않아 전체 답변 상태를 반환하였다. 이 사례에서 검색·생성·인용 연결이 동작함을 확인하였다.

3.7.2 출처를 확인하여 적용 범위 판단

그림 3.6은 같은 저장 응답의 근거 패널에서 세 보기를 발췌한 것이다. 사용자는 문장의 출처 번호를 눌러 문서명과 원문 일부, 페이지 및 섹션을 확인할 수 있다. 근거 화면에서 ‘19쪽’과 ‘1. 공지관련 사항’은 추출 단계에서 보존한 위치 정보가 인용과 화면까지 전달된 결과이다. 표시된 검색 점수는 해당 검색기의 내부 관련도 점수이며 답변이 맞을 확률로 해석하지 않는다. 원문 주소를 열어 게시물과 첨부파일을 추가 확인할 수도 있다.

이 사례에서 확인해야 할 범위는 ‘공지와 지원 일정의 개별 통보’이다. 같은 발췌문 뒤에는 별점 관련 카카오톡 알림 또는 문자 부가서비스가 별도로 설명되어 있으므로 이를 대학생활원의 모든 문자 서비스가 없다는 의미로 확대하면 안 된다. 시스템은 공지 전달 방식을 안내하며 실제 문자 발송을 수행하지 않는다. 질문의 표현을 답변으로 요약한 뒤에도 사용자가 원문의 대상과 예외를 확인할 수 있어야 한다.



그림 3.6. 현재 근거 패널의 검증·문서·위치 보기

3.8 사용자 인터페이스와 실패 대응

3.8.1 질문 작성에서 근거 확인까지

현재 프론트엔드는 질문 작성과 답변 읽기를 중심으로 구성하고 대화 기록, 모델·역할·검색 설정을 분리하였다. 추천 질문을 누르면 기관과 질문 초안이 입력되며 사용자는 자신의 학년도나 조건에 맞게 수정한 후 전송한다. 연결이 준비되지 않은 동안에도 초안은 작성할 수 있고 서버·파서·검색 방식의 준비 상태에 따라 전송 가능 여부를 표시한다. 선택 가능한 이름이 존재하는 것만으로 실제 인덱스나 모델이 준비되었다고 간주하지 않는다.

답변은 Markdown의 목록·표·강조를 유지하여 보여준다. 실제 근거에 대응하는 인용 번호만 클릭 가능한 버튼으로 변환하고 코드와 기존 외부 링크 안의 문자열은 중첩 버튼으로 만들지 않는다. 원격 이미지와 HTML 실행을 제한하여 답변을 읽는 과정에서 임의 콘텐츠가 실행되거나 추적 이미지가 로드되는 경로를 줄였다. 답변 복사·재생성·근거 열기와 최신 답변으로 이동을 지원한다.

근거 화면은 검증·문서·위치의 세 보기로 구성하였다. 검증 보기에는 문장별 지지 여부와 연결 출처를, 문서 보기에는 기관·제목·발췌문·원문 및 첨부 링크를, 위치 보기에는 페이지·섹션·표의 행과 열을 표시한다. 행·열의 내부 0부터 시작하는 값은 화면에서 1부터 시작하는 번호로 변환한다. 위치 정보가 없을 때는 값을 꾸며 내지 않으며 여러 위치가 있는 경우 표시

수와 추가 위치 수를 구분한다. 앞 절의 화면은 이 프론트엔드에 저장 응답을 표시한 것으로, 답변과 근거 연결을 확인하는 예시이다.

3.8.2 대화 기록과 요청 일관성

최근 30개 대화를 브라우저에 저장하여 검색·전환·삭제·되돌리기할 수 있게 하였다. 새로고침 후에는 저장 데이터의 타입과 중복 ID를 검사하여 질문·답변·근거를 복원한다. 여러 탭이 동시에 저장할 때에는 Web Locks로 순서를 조정하고 메시지 ID와 삭제 상태를 반영하여 늦게 도착한 저장이 삭제한 대화를 다시 만드는 문제를 방지하도록 하였다. Web Locks를 사용할 수 없거나 저장에 실패하면 안내를 표시하고 현재 대화는 메모리에 유지한다.

이 기록은 해당 브라우저의 localStorage에 저장되며 계정이나 다른 기기로 동기화되지 않는다. 서버에는 질문별 독립 요청을 전달하며, 이전 대화 문맥을 합치는 다중 턴 처리는 지원하지 않는다. 재시도와 재생성에는 원래 질문의 기관·역할·제공자·모델·파서·검색 설정을 보존하여 사용자가 다른 설정을 선택한 뒤 과거 답변을 다시 생성하더라도 요청 조건이 임의로 바뀌지 않도록 하였다.

3.8.3 취소·연결 오류·근거 부족의 처리

전송 중에는 같은 요청을 중복으로 보내지 못하게 하고 중지 버튼을 제공한다. 중지하면 브라우저 요청을 취소하고, 나중에 도착한 이전 답변이 현재 대화에 표시되지 않게 한다. 다만 외부 제공자가 이미 시작한 생성까지 즉시 멈추거나 비용을 취소하는 기능은 아니다. 관리자가 서버 전체의 새 요청과 대기 작업을 중지하고 복구하는 기능도 아직 구현하지 않았다.

연결에 실패하면 오류 내용과 재시도 가능 여부를 표시한다. Enter로 전송하고 Shift+Enter로 줄을 바꿀 수 있으며, 한글을 조합하는 도중 잘못 전송되는 것을 방지하였다. Escape로 팝업을 닫고 방향키로 근거 탭을 이동하는 기능도 구현하였다.

서버에서 검색 결과가 없거나 지지되는 문장이 없으면 확인 불가 상태를 반환한다. 생성 API의 오류나 시간 초과에는 추출형 응답으로 전환할 수 있으며 특정 네트워크 제공자를 명시한 경우에는 해당 제공자와 추출형 대체 경로만 사용한다. 자동 선택은 서버 설정의 순서를 따른다. 대체 응답의 사용 여부와 사유를 메타데이터로 남겨 정상 생성과 구분한다. 요청 크기·질문 길이·검색 개수·동시 생성 수를 제한하고 허용 Origin 검사와 설정된 경우의 토큰 인증을 적용하였다.

화면은 저장 데이터가 손상된 경우, 요청 취소 후 답변이 늦게 도착하는 경우, 여러 탭을 동시에 조작하는 경우, 긴 답변과 짧은 화면을 확인하였다. 수정 후 기존 기능이 깨지는지 확인하는 회귀 테스트와 접근성 검사도 수행하였다. 다만 이 화면 검사에서는 미리 정한 응답

을 주는 로컬 테스트 API를 사용했다. 실제 모델의 답변 품질과 배포 환경의 동작은 별도로 확인해야 한다.

3.9 규칙 기반 처리의 항목과 적용 범위

본 시스템은 생성 모델만으로 답변을 처리하지 않는다. 사람이 정한 조건에 따라 검색 결과를 조정하고 생성 문장을 검사하는 규칙 기반 처리를 함께 사용한다. 예를 들어 질문이 2026년 일정인데 문서 제목이 다른 연도를 가리키면 검색 순위를 낮추고, 답변의 금액이 인용 근거에 없으면 해당 문장을 보류한다. 규칙은 잘못된 답변을 줄일 수 있지만, 올바른 문서나 문장까지 제외할 수 있다.

2026년 9월 4일의 검색·생성·근거 판정 코드를 기능별로 묶은 목록은 68개 규칙군이다. 이는 정규식 개수나 실행 횟수가 아니라 같은 판단 목적을 가진 조건 묶음의 수다. 표 3.4는 전체 세부 규칙을 나열하지 않고 범주와 대표 동작을 요약한다.

표 3.4. 검색·생성·근거 판정 규칙군의 구성과 대표 동작

범주	규칙군 수	대표 조건과 동작
검색어 정리·순위·중복	9	정보량이 낮은 표현을 정리하고 연도 충돌 후보를 낮춤; 문서별 체크 상한 적용
질문 의도별 검색어 확장	8	D2 비자 관련 질문에서 예약·제출서류·수수료 등 검색 표현 추가
질문 항목·인접 근거 보완	14	기간·금액·대상 등 누락 항목을 같은 문서의 다른 체크에서 보완
생성 지시·내용 점검 항목	18	한 문장에 근거를 연결하고 질문의 여러 요구 항목을 빠뜨리지 않도록 모델에 지시
문장 근거·인용 판정	19	날짜·금액 등 핵심값과 허용/금지·이상/이하 관계를 대조하고 지지되지 않는 문장 제외
합계	68	보안 지시 탐지·URL 검사·파서 선택 규칙은 이 집계에서 제외

범용 처리는 21개, 개발용 질문이나 행정 의도에 맞추어 추가한 처리는 47개였다. 생성 지시 범주의 규칙은 모델에게 주는 작성 지침이며, 코드가 반드시 강제하는 검사와도 구분한다. 분류 기준과 원래 규칙 목록의 저장 위치는 동봉 자료에 기록하였다.

별도의 보안 규칙은 문서 속 역할 변경·이전 지시 무시·비밀 공개 유도 등을 검사하고, 인용 검사는 출처 번호·문서 조각 ID·발췌문·해시가 연결되는지 확인한다. 이들의 실행 결과는 4.6절에 문서 제외율과 공격 표식 출력률로 보고한다. 특정 탐지 규칙 하나가 차단한 비율은 중복 적용을 분리해 기록하지 않아 산출하지 않았다.

C0와 C1의 차이는 검색 조정의 사용 여부이며 모든 68개 규칙을 한꺼번에 켜고 끈 비교가 아니다. 생성 지시와 출력 검사는 두 조건에 공통으로 남는다. 따라서 C0·C1의 차이를 개별 규칙의 효과나 전체 규칙 기반 처리의 효과로 해석하지 않는다. 개별 효과를 알려면 한 규칙씩 제외하고 다시 비교하는 추가 실험이 필요하다.

3.10 대표 설계 변경과 구현상의 판단

개발 과정에서는 단계별 출력과 실패 사례를 추적하여 문제를 수정하였다. 첫째, 문서를 블록·표·위치의 공통 구조로 표현하였다. 이를 통해 파서 교체와 표의 행 단위 청킹을 공통 처리로 연결하고 최종 인용에서 페이지와 섹션을 표시할 수 있게 하였다. 수집 선별과 Corpus Gate는 검색에 사용할 자료의 범위와 품질을 검사하도록 분리하였다.

둘째, 정답 문서가 검색되어도 필요한 날짜·대상·절차가 최종 문맥에 빠지는 문제에 대응하였다. 일반 안내와 연도 불일치 후보를 조정하고 복합 질문에서 누락된 항목의 인접 청크를 선택하도록 하였다. 문서별 상한과 중복 제거를 유지하면서 누락 근거를 보완하였다. Dense와 RRF 등 대안은 비교 가능한 경로로 남기고 대표 서비스는 확인된 BM25 구성으로 제시하였다.

셋째, 생성 모델이 올바른 내용을 작성했더라도 후처리가 이를 훼손하는 사례를 수정하였다. 초기 문장 분리는 ‘2026. 8. 24.(월)’ 같은 날짜를 마침표에서 나누고 짧은 문장 필터는 ‘학부 등록금은 동결되었습니다.’와 같은 완전한 사실도 제거할 수 있었다. 점 표기 날짜를 문장 분리 전에 보호하고 생성 초안의 짧은 문장 기준을 별도로 조정하되 추출형 후보의 짧은 필터는 유지하였다. 허용·금지 및 이상·이하 관계가 뒤집힌 문장을 거부하는 규칙과 공식 메뉴 경로의 올바른 의역을 보존하는 제한적 규칙도 보완하였다.

넷째, 문서의 지시와 시스템의 지시를 구분하기 위해 생성 전 보안 검사와 생성 후 인용 검사를 추가하였다. 이후 발견된 예외 처리와 메타데이터 검사 문제는 별도 수정 사본에서 다루어 변경 범위를 추적하였다. 다섯째, 대화 저장 실패, 탭 간 삭제, 취소 뒤 지연 응답을 회귀 검증에 포함하였다. 이러한 변경의 성능 효과는 검색 평가, 동일 초안 재처리, 실제 생성 및 보안 실험을 구분하여 다음 장에서 분석한다.

3.11 구성원 역할 및 수행 일정

본 과제는 3인 팀으로 수행하였다. 검색·리랭킹·생성 모델의 병렬 실험과 비교를 공통 업무로 두었으며, 최종심사표에 기재한 구성원별 주담당 업무는 다음과 같다.

표 3.5. 구성원별 주담당 업무

구성원	학번	주담당 업무
이현우	202155596	1) 문서 수집·파싱·검색·답변 생성 파이프라인 설계 2) 답변 정확성·근거 일치 여부 평가용 LLM Judge 설계·실험 3) BM25 RAG API 구현, React 연동 및 배포
황지완	202155627	1) 문서 파싱·RAG·평가 방법 관련 논문 조사 및 비교 2) 대학·공공기관 문서 수집, HWP/PDF 파싱 및 청킹 3) 문서 최신성 확인 및 적대적 공격 평가
정지인	202355709	1) 생성 전 문맥 검사·생성 후 인용 검증을 위한 보안 레이어 탑재 2) RAG·보안 벤치마크 조사, 평가셋과 실험 조건 설계 3) 출처 검증 UI/UX 구성 및 보고서·발표 자료 정리

프로젝트의 실제 작업 기록에서 확인되는 주요 수행 과정과 일정을 월 단위로 정리하였다.

표 3.6. 월별 주요 수행 일정

시기	주요 수행 내용
2026년 6월	기관 문서 수집 및 초기 자료 통합
2026년 7월	문서 변환·파싱, 구조 보존 방식 조사, 부산대학교 문서 색인과 BM25 기반 질의응답 시연 구성
2026년 8월	연구비 규정 실험의 검색·리랭킹·생성 품질 비교, 부산대학교 실서비스 경로를 대상으로 한 평가 기반 구축
2026년 9월	검색·답변 생성 결과 분석, 생성 전후 보안 계층 통합과 파일럿 평가, 대화 이력 및 문서 출처 확인을 위한 사용자 화면 개선

제4장 연구 결과 분석 및 평가

4.1 평가 목적과 실험 구성

평가에서는 문서 처리·검색·답변 생성·보안 기능이 어떻게 작동하고, 어느 단계에서 오류가 생기는지 확인하였다. 정답 문서를 찾았는지, 필요한 근거를 모두 찾았는지, 답변이 정확하고 빠진 내용이 없는지, 인용이 올바른지를 나누어 측정하였다.

정량 평가에는 2026년 9월 14일까지 완료한 실험 기록을 사용하였다. 개발용 질문 평가(DEV), 다른 문서로 만든 진단 질문 평가(Shadow), 소규모 보안 실험, 최종 평가(holdout)는 각각 별도 실험이다. 각 실험의 문서·모델·평가표를 확인하며 결과를 해석하였다. 조건이 다른 실험의 수치를 하나의 연속된 개선 결과로 합치지는 않았다.

DEV45는 본 과제의 서비스 개발을 위해 구성한 45문항으로, 9개 행정 영역의 기본 질문 39개와 역할 조건을 추가한 변형 6개로 이루어진다. 각 문항에는 질문·영역·역할·정답 문서와 기대 근거를 기록하였다. 검색 규칙의 진단과 수정에 반복 사용한 개발셋이며, 기본 질문과 역할 변형은 같은 질문군으로 묶어 분석하였다.

표 4.1. 주요 평가의 목적과 조건

평가	시점	표본·비교 조건	생성·반복
파서 검사	9월 1일	18문서·54근거, 파서 3종	생성 없음
DEV 검색	9월 2일	45문항, 파서·검색 8조건	추출형, 조건별 1회
DEV 생성	9월 4일 완료	45문항, C0·C1	조건별 독립 생성 3회
C2 탐색	9월 4일	45문항, 저장 C1 문맥 재사용	C2 응답 3회, 일부 재처리
DEV 후속 검색	9월 4일	같은 45문항, 의도별 검색 보완	추출형, 1회
Shadow 검색	9월 4일	60문항, C0·C1	추출형, 조건별 1회
Shadow 생성	9월 5~6일	같은 60문항, C1	독립 생성 3회
소규모 보안 실험	9월 9일	정상 14·공격 10·대조 10, 3조건	생성·판정 각 1회
최종 holdout	9월 14일	핵심 27문항 C0·C1, 도전 9문항 C1	조건별 독립 생성 3회
사람 검수	9월 14일	holdout 첫 회차 답변 62개, 개발자 1인	생성 없음, Judge와 일치도 비교

C0는 Cascade 파서와 BM25를 사용하되 검색 조정 규칙을 끈 조건이고, C1은 그 규칙을 적용한 조건이다. 같은 C0·C1이라는 이름을 써도 실험에 따라 코드와 평가 질문의 버전이 다르므로 각 절의 조건을 함께 확인해야 한다. DEV의 답변 생성 비교는 9월 3일의 조건을 고정하고 9월 4일 세 번의 생성을 마친 결과다. 이후 추가한 질문 의도별 검색 보완은 이 결과에 포함되지 않는다. C2는 답변 생성 방식을 바꾼 별도 실험이며 실제 서비스에는 적용하지 않았다.

검색 비교는 로컬 서비스의 동일한 요청 경로를 사용하였다. 기본 설정은 상위 문맥 8개와 문서당 청크 2개이며 9월 4일 후속 검색에서는 명시적으로 세 부분을 묻는 일부 질문에 한해 동일 문서의 세 번째 청크를 허용하였다. 검색만 평가할 때는 추출형 응답을 사용하여 외부 생성 모델을 호출하지 않았다.

표 4.2. 평가 지표와 해석

지표	정의	측정 대상
문서 적중률 Hit@k	상위 k개에 정답 문서가 있는 질문 비율	관련 문서 발견
MRR@5	5위 이내 첫 정답 순위의 역수 평균	정답 문서 순위
Any Gold@k	지정 정답 청크를 하나 이상 회수한 비율	부분 근거 회수
All Gold@k	지정 정답 청크를 모두 회수한 비율	청크 집합 회수
필수 근거 회수율	질문의 필수 사실별 근거 회수 정도	답변에 필요한 근거
Judge 평균	본 과제의 평가표에 따른 0-2점 평균	답변 품질의 보조 지표
GFC	내용·근거·인용 조건을 모두 충족한 답변 비율	근거 충족 완전정답률

답변 점수는 0~2점으로 매긴다. 핵심 사실이 모두 정확하면 2점, 방향은 맞지만 중요한 내용이 빠지거나 일부 틀리면 1점, 결론이 틀리거나 근거가 크게 부족하거나 질문과 무관하면 0점이다. 답할 수 있는 질문에 답하지 않으면 0점이다. 반면 원문에 답이 없거나 질문 범위가 모호하면, 문항별 기준에 맞게 답변을 보류하거나 되물었을 때 2점을 줄 수 있다. Judge v11은 이 평가표를 적용한 자동 채점기의 버전명이다.

GFC는 2점 답변에 추가 조건을 적용한 완전정답률이다. 필요한 사실을 모두 정확히 담고, 제공된 근거가 그 내용을 뒷받침하며, 인용도 해당 근거를 가리켜야 한다. 날짜·금액·조건이 틀리거나, 근거 없는 내용을 덧붙이거나, 앞뒤가 모순되거나, 답할 수 있는데도 지나치게 답변을 피하면 실패로 판정한다.

DEV45·C2·Shadow에서는 같은 질문에 세 번 답한 뒤, 그중 2회 이상 GFC를 충족한 문항의 비율을 보고한다. holdout에서는 생성 예정 답변 수를 기준으로 한 비율과 이 다수결 문항 비율을 모두 제시한다. 같은 질문의 반복 답변을 서로 다른 질문으로 세지는 않는다.

4.1.1 Q&A 평가셋의 출처와 구성

Q&A 평가셋은 수집한 부산대학교 공식 문서를 바탕으로 직접 만들었다. 외부의 공개 질의응답 데이터셋을 내려받거나 실제 상담 기록을 사용한 것은 아니다. 문서는 부산대학교 담당 부서나 원 공고 기관이 작성했고, 질문·기대 답변·채점 기준은 본 과제에서 작성하였다.

표 4.3. 자체 Q&A 평가셋의 규모·출처·사용 목적

집합	문항	원문 파일	구성과 사용 범위
DEV45	45	39개	9개 행정 영역의 기본 질문 39개와 역할 변형 6개; 개발 중 반복 사용
Shadow60	60	42개	핵심 42·역할 변형 8·도전 10; DEV와 출처를 분리한 합성 진단, 독립 사람 검수 없음
최종 holdout	36	27개	핵심 27·도전 9; 개발에 쓰지 않은 질문과 정답 근거를 개발자 1인이 확인

원문 파일의 내용이 같은지 해시로 비교한 결과, DEV와 Shadow, DEV와 최종 holdout 사이에 겹치는 원문은 각각 0개였다. 다만 최종 holdout의 원문 27개 중 9개(33.3%)는 앞선 Shadow 진단에서도 사용하였다. 질문 문구는 다르지만 일부 주제와 답변에 필요한 사실도 겹친다. 따라서 최종 평가의 모든 문서와 사실이 앞선 평가와 완전히 독립적이라고 볼 수는 없다.

표의 원문 파일 수는 내용이 다른 파일의 수이며 SHA-256으로 구분하였다. 원문에 답이 없거나 질문 범위가 모호한 문항은 답변 보류나 되물기를 평가하므로 정답 근거 파일이 없을 수 있다. 평가 질문을 저장한 JSONL 파일의 크기는 개정 DEV45 67,119바이트, Shadow60 261,344바이트, 최종 holdout 133,572바이트다. 이는 수집 문서 전체의 용량과 다르다.

평가 문항에는 질문, 행정 영역, 역할 조건, 기대 답변 또는 필수 사실, 원문 인용을 저장하였다. 필수 사실은 답변에 반드시 있어야 하는 내용으로, 예를 들어 “자동 수강신청의 조건”과 “정원을 넘었을 때의 조치”를 각각 기록한다. DEV의 문항 ID는 별도 출처 목록과 연결하고, Shadow와 holdout은 문항 내부의 근거 항목에 제목·주소·파일 식별값을 기록하였다.

대표 출처는 다음과 같다. DEV의 등록금 문항은 부산대 공지 「2026학년도 2학기 재학생 등록금 납부 계획」의 PDF를 사용하였다[10]. Shadow의 취업 지원 문항은 취업전략과 게시판에 첨부된 「2026 금정 청년 구직응원 패키지 지원사업 대상자 모집 공고」 HWP에서 구성하였다[11]. 최종 holdout의 자동 수강신청 문항은 입학처 게시물의 국문 안내 PDF를 근거로 삼았다[12]. 출처 URL은 원 게시물 또는 안내 페이지를 가리키며 첨부파일의 제목·원본 경로·해시로 실제 사용한 파일을 구분한다.

첨부한 supplement/qa-source-map.csv에는 141문항 전체의 질문, 문항 ID, 공식 출처 URL, 문서 제목, 원본 파일 경로와 해시를 정리하였다. 평가 질문이 담긴 JSONL 파일 세

개도 함께 제공한다. DEV의 초기 출처 목록은 개정본의 같은 문항 ID와 연결하였다. 최종 평가셋의 질문과 정답 근거는 개발자 1인이 원문과 대조하여 확인하고 확정하였다.

4.1.2 실험 기록과 재현 조건

실험에 사용한 코드·평가 질문·문서·검색 인덱스, 생성·채점 설정, 결과 파일의 위치는 첨부한 REPRODUCIBILITY.md와 evaluation-records.json에 정리하였다. 경로는 프로젝트 폴더를 기준으로 표시하고, 파일 내용이 같은지 확인할 수 있도록 SHA-256도 기록하였다. 실험 당시 남긴 값과 보고서를 정리하며 계산한 값은 구분하였다. 원자료와 인덱스는 별도로 보존하므로 보고서 ZIP만으로 모든 실험을 다시 실행할 수는 없다.

주요 DEV 답변 생성 실험 당시에는 Git에 저장하지 않은 코드 수정이 포함되어 있었다. 서버 파일 하나의 해시는 남아 있지만, 이를 당시 코드 전체가 보존되었다는 증거로 사용할 수는 없다. 저장된 답변·채점 결과와 평가 질문·인덱스의 연결은 해시로 확인하였다. 다만 당시 수정 사항을 모두 포함한 코드 사본은 확인하지 못했다. 따라서 저장 결과를 다시 집계할 수는 있어도 같은 코드로 실험 전체를 재실행할 수 있다고 보장하지는 않는다. 세부 식별 정보는 첨부 자료에 남겼다.

소규모 보안 실험은 보안 적용 전·병합 보안본·수정 사본의 코드를 각각 보존하였다. 세 코드 사본의 파일 목록과 식별값을 동봉한 기록에 수록하여 어떤 보안 조건을 실행했는지 구분하였다. 생성 모델의 응답은 같은 설정에서도 달라질 수 있으므로, 재현 확인에서는 저장 답변의 재집계와 새 답변 생성의 변동을 함께 고려해야 한다.

4.2 문서 수집 결과와 파서 평가

4.2.1 수집·선별·파싱 결과

초기 수집 완료량은 웹페이지 7,775개와 첨부파일 3,202개를 합한 10,977개, 5,834,477,829바이트(약 5.83GB)였다. 서비스 범위·형식·무결성·중복 기준을 적용한 뒤 2,260개 문서, 473,678,602바이트(약 473.68MB)를 선별하였다. 최종 문서 수는 완료 항목의 20.6%이며 선별 과정에서 내용이 같은 중복 항목 118개를 제외하였다. 여기서 GB와 MB는 각각 10억 바이트와 100만 바이트 단위다. 수집 기록에는 대기 및 오류 항목도 남아 있으므로 대학 웹 전체를 완전하게 수집한 것으로 해석하지 않았다.

선별 문서는 HTML 1,646개(72.8%), HWP와 PDF 각각 278개(각 12.3%), DOCX와 XLSX 각각 23개(각 1.0%), 기타 형식 12개(0.5%)였다. 기타 형식은 PPTX 4·DOC 3·HWPX 2·XLS 2·TXT 1개다. 수집 기록에는 대기 2,244개, 오류 141개, 제외 1,460개도

표 4.4. 데이터 처리 단계별 산출물

단계	결과	단위·비고
초기 수집 완료	10,977	웹페이지 7,775·첨부파일 3,202; 약 5.83GB
선별 문서	2,260	완료 항목의 20.6%; 약 473.68MB
파싱 성공	2,247	선별 문서 2,260개 중 99.4%
파싱 청크	44,591	품질 기준 적용 전
추출 표	7,813	파싱 산출물
검색 인덱스	44,520	품질 기준 적용 후 청크

남아 있다. 9월 22일 선별한 2,260개의 실제 파일을 다시 확인했으며, 누락된 파일이나 기록과 크기가 다른 파일은 없었다.

파싱하지 못한 문서는 처리 오류 8개, 빈 결과 1개, 미지원 형식 4개였다. 파싱 후 품질 검사에서 청크 71개가 제외되어 파싱 결과와 서비스 인덱스의 청크 수가 다르다. 파싱 성공은 처리가 끝났다는 뜻이며, 모든 내용이 정확히 추출되었다는 뜻은 아니다.

4.2.2 형식별 근거 보존

파서의 목적은 원문의 날짜·수치·절차·표 관계를 검색 가능한 형태로 보존하는 것이다. 이를 확인하기 위해 HWP/HWPX, 일반 PDF, OCR·표 중심 PDF에서 각각 6개 문서를 선택하고 문서당 3개 근거, 총 54개를 검사하였다. 세 파서는 같은 원문 집합을 사용하였다. 문자열의 공백·구분자 차이를 정규화한 뒤 문자·숫자·순서가 유지되는지를 판정하였다.

표 4.5. 표적 문서의 근거 보존 결과

파서	전체 근거 / 54	세 근거 보존 문서 / 18	HWP 계열 / 18	일반 PDF / 18	OCR·표 PDF / 18
Baseline	48 (88.9%)	14 (77.8%)	18 (100.0%)	17 (94.4%)	13 (72.2%)
Challenger	54 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)
Cascade	54 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)	18 (100.0%)

Baseline이 제대로 보존하지 못한 근거에는 등록 기간 표의 행 관계, OCR로 읽은 철자, 교육과정 정의, 지급한도 표의 관계가 있었다. Challenger와 Cascade는 검사한 근거 54개를 모두 보존하였다. 다만 이미 알려진 실패 유형을 고려해 고른 문서이고, 근거 연결의 기준도 Cascade 결과를 사용하였다. 따라서 이 결과를 전체 문서의 파싱 정확도로 보거나 두 개선 파서 중 하나가 더 낫다는 근거로 사용할 수는 없다. 원문 화면과 추출 결과를 독립적으로 대조하는 사람 검수는 추가로 필요하다.

4.3 DEV45 검색 비교

4.3.1 9월 2일 검색 방식 비교

검색 방식 비교에서는 생성 모델을 호출하지 않고 정답 문서와 근거 청크를 얼마나 잘 찾는지 확인하였다. 같은 문서 집합에 파서·검색 조합 8가지를 적용해 360개 요청을 실행했으며 오류는 없었다. Baseline·Challenger·Cascade에는 검색 규칙을 적용한 BM25를 사용하였다. Cascade에는 기본 BM25, KURE와 Snowflake의 Dense 및 Hybrid도 추가로 비교하였다. Dense와 Hybrid에는 C1의 질문 의도별 검색 규칙을 적용하지 않았다.

표 4.6. 동일 서비스 경로의 검색 결과


조건	방식	Hit@5	MRR@5	Any Gold @8	All Gold @8
PAR-B	Baseline·튜닝 BM25	39/45 (86.7%)	0.7259	—	—
PAR-CH	Challenger·튜닝 BM25	40/45 (88.9%)	0.7144	—	—
C0	Cascade·기본 BM25	29/45 (64.4%)	0.4944	23/45 (51.1%)	10/45 (22.2%)
C1	Cascade·튜닝 BM25	40/45 (88.9%)	0.7174	28/45 (62.2%)	17/45 (37.8%)
D-K	KURE Dense	37/45 (82.2%)	0.5956	27/45 (60.0%)	15/45 (33.3%)
H-K	KURE Hybrid	34/45 (75.6%)	0.5441	20/45 (44.4%)	9/45 (20.0%)
D-S	Snowflake Dense	36/45 (80.0%)	0.6156	29/45 (64.4%)	16/45 (35.6%)
H-S	Snowflake Hybrid	35/45 (77.8%)	0.5596	21/45 (46.7%)	10/45 (22.2%)

C0에서 C1으로 변경하면서 문서 적중률은 64.4%에서 88.9%로 24.44%p 증가했고, 모든 정답 청크를 회수한 비율은 22.2%에서 37.8%로 15.56%p 증가하였다. 퍼센트포인트(%p)는 두 비율을 뺀 값이다. 예를 들어 20%에서 30%가 되면 10%p 증가다. 평균 정답 청크 회수율도 0.3593에서 0.5000으로 상승하였다. Cascade 조건에서는 C1이 문서 적중과 전체 정답 청크 회수에서 가장 높았다. Snowflake Dense는 일부 정답 청크를 찾은 질문이 한 개 더 많았지만 문서 적중과 전체 근거 회수에서는 낮았다.

해당 개발셋과 설정의 결과를 BM25의 Dense·Hybrid 대비 일반적 우월성으로 해석할 수는 없다. 파서별 청크 식별자가 달라 Baseline과 Challenger의 청크 지표는 비교하지 않았다. 검색 지연도 단일 순차 실행과 초기 모델 적재가 섞여 있어 속도 비교에 사용하지 않았다.

DEV45 검색 방식별 정답 문서 적중

2026년 9월 2일 · Hit@5 · 조건별 45문항



C0-C1은 동일 파서의 기본·튜닝 BM25 비교이다.

Dense-Hybrid에는 C1 튜닝을 적용하지 않아 방식 자체의 우열로 해석하지 않는다.

그림 4.1. DEV45 검색 조건별 문서 적중 수와 비교 범위

4.3.2 9월 4일 의도별 후속 검색 보완

후속 개발에서는 구어체 질문을 공식 문서 어휘로 확장하고 같은 문서에 분산된 지원 범위·신청 절차·제출서류를 보완하였다. 이후 DEV45 전체를 실제 서비스 경로로 다시 검색하였다. 외부 생성 모델과 Judge는 호출하지 않았다.

앞선 8조건 비교는 초기 평가셋으로 수행했고, 표 4.7의 후속 비교는 개정 평가셋으로 수행하였다. 따라서 앞선 C1의 MRR@5 0.7174와 후속 비교의 보완 전 값 0.7137은 같은 실행에서 나온 수치가 아니다. 각 결과에 사용한 평가셋과 실험 기록은 첨부한 재현 정보에서 확인할 수 있다.

표 4.7. 후속 검색 보완 전후 결과

지표	의도 확장 전	최종 보완 후
문서 Hit@5	40/45 (88.9%)	45/45 (100.0%)
MRR@5	0.7137	0.8137
모든 필수 체크 회수@8	31/45 (68.9%)	41/45 (91.1%)
모든 필수 근거 회수@8	33/45 (73.3%)	43/45 (95.6%)
평균 필수 근거 회수율@8	0.7481	0.9778

필수 근거를 모두 찾지 못한 두 문항은 같은 교육·연구 및 학생지도비(교연비) 질문의 기본형과 역할 변형이었다. 답변에 필요한 최대 금액 표는 찾았지만 정답 근거로 지정한 배경

문장까지 모두 찾지는 못하였다. 핵심 수치에는 답할 수 있어 평가 점수만 높이기 위한 추가 조정은 중단하였다.

이 결과는 개발 중 반복해서 본 질문의 검색 성능이며, 새로운 질문이나 생성 답변의 품질을 평가한 것은 아니다. 또한 9월 2일은 초기 정답 체크, 9월 4일은 개정된 필수 근거를 기준으로 삼았으므로 두 결과를 같은 지표의 연속된 개선으로 직접 비교하지 않았다.

4.4 DEV45 답변 생성과 출처 연결 평가

4.4.1 C0·C1의 독립 생성 비교

검색 개선이 답변에 전달되는지를 확인하기 위해 C0와 C1의 45문항을 세 번씩 독립 생성하였다. 두 조건의 문맥 상한은 24,000자, 출력 상한은 900토큰이며 생성 temperature는 별도로 지정하지 않았다. 생성은 Gemini 3.5 Flash-Lite, 판정은 Gemini 3.1 Flash-Lite와 Judge v11을 사용하였다. Judge는 temperature 0, 출력 상한 1,600토큰으로 각 답변을 한 번씩 판정하였다.

전체 유효 답변 270개와 판정 270개를 확보했으며 최종 집계에 오류나 대체 모델 응답은 없다. 첫 회차 수집 중 다른 모델로 전환되어 거부된 시도 8건은 별도로 보존하고 동일 조건으로 재수집하였다.

표 4.8. DEV45 독립 생성 3회 결과

지표	C0	C1
Judge 평균 / 2점	0.8815	1.2148
0점 답변 / 135	52 (38.5%)	29 (21.5%)
2점 답변 / 135	36 (26.7%)	58 (43.0%)
회차별 GFC 수	12·13·11	18·20·20
다수결 GFC / 45	13 (28.9%)	20 (44.4%)

질문별 세 번의 평균 점수는 19문항에서 높아졌고, 15문항은 같았으며, 11문항은 낮아졌다. 기본 질문과 역할 변형을 같은 묶음으로 보아 총 39개 질문군을 분석하였다. 질문군을 반복해서 다시 뽑아 차이의 불확실성을 계산하는 대응 부트스트랩을 10,000회 수행하였다. 평균 점수 차이 0.3333의 95% 신뢰구간은 [0.0889, 0.5887]로 0을 포함하지 않았다. 이 조건에서는 평균 점수 향상이 통계적으로 확인되었다.

반면 다수결 GFC 차이 0.1556의 신뢰구간은 [-0.0217, 0.3201]로 0을 포함하였다. 두 조건에서 성공·실패가 바뀐 문항을 비교하는 McNemar 검정의 p값도 0.1185였다. 이 검정은 45문항의 결과 쌍을 대상으로 한 보조 분석이며, 기본 질문과 역할 변형의 유사성은 앞선 질문군

부트스트랩에 반영하였다. 따라서 평균 점수는 높아졌지만 완전정답률도 확실히 높아졌다고 결론 내릴 근거는 부족하였다.

4.4.2 동일 답변에 대한 Judge 반복

답변이 달라져 점수가 바뀐 것인지, 채점 모델의 판정이 달라진 것인지 구분하기 위해 첫 회차 답변을 그대로 두고 Judge로 세 번씩 채점하였다. 두 조건 모두 45문항의 점수와 GFC 판정이 세 번 같았다. C0는 평균 $0.8667 \cdot \text{GFC } 12/45$, C1은 평균 $1.2000 \cdot \text{GFC } 18/45$ 였다. 여기서 18/45는 같은 답변을 반복 채점한 결과다. 서로 다른 세 답변의 다수결 결과인 20/45와는 계산 대상이 다르다. 반복 채점이 일치해도 사람의 판단과 일치한다는 뜻은 아니다.

4.4.3 C2의 주장·인용 동시 생성 실험

C1은 먼저 답변 초안을 만든 뒤 각 문장에 맞는 출처를 찾는다. 이 과정에서 올바른 문장도 출처를 연결하지 못해 빠질 수 있다. C2는 이를 줄이기 위해 처음부터 각 주장·출처 번호·원문 인용을 함께 생성하게 하였다. 검사기는 인용문이 실제 원문에 있는지와 수치·대상·관계가 맞는지를 확인한다. 검색 결과의 영향은 같게 맞추기 위해 저장된 C1의 근거와 순서를 그대로 사용하였다.

표 4.9. C2 탐색 실험 결과

지표	C1	C2
Judge 평균 / 2점	1.2148	1.3630
회차별 GFC 수	18 · 20 · 20	28 · 25 · 23
다수결 GFC / 45	20 (44.4%)	26 (57.8%)

다수결 GFC가 실패에서 성공으로 바뀐 문항은 9개, 성공에서 실패로 바뀐 문항은 3개로 총 6문항 늘었다. 질문군 단위 부트스트랩을 100,000회 수행한 결과, 평균 점수 차이의 95% 신뢰구간은 $[0.0000, 0.3116]$, GFC 차이의 신뢰구간은 $[0.0000, 0.2826]$ 이었다. 평균 차이의 하한은 컴퓨터 계산 오차 수준의 음수여서 0으로 반올림하였다. McNemar 검정의 p값은 0.1460이었다. 개선을 확정할 통계적 근거는 부족하였다.

C2는 C1의 초안을 다시 검사한 것이 아니라 답변을 새로 생성한 실험이다. 다만 첫 C2 답변에서 문장이 잘못 제거되는 사례를 본 뒤 검사기를 수정하고 같은 답변을 다시 처리하였다. 두 번째와 세 번째 생성만 수정한 검사기를 고정하여 실행했다. 출력 상한도 1,200토큰, temperature도 0으로 C1과 달랐다. 따라서 결과 차이가 인용 방식 하나 때문이라고 볼 수는 없다. 답변 생성과 검사 설정을 함께 바꿔 본 탐색 실험이며, C2는 서비스에 적용하지 않았다.

4.4.4 저장 초안의 후처리 진단

별도의 진단에서는 생성 모델을 다시 호출하지 않고 같은 초안과 검색 문맥을 재처리하였다. 등록금 관계문 수정에서 270개 중 9개 답변이 바뀌었고 나머지 261개는 유지되었다. 변경된 9개를 같은 Judge로 재판정한 점수는 모두 2점이었다. 이어 표 행의 날짜·시간과 인접한 고지서 출력 경로를 보완했을 때 C1 답변 135개 중 6개가 추가로 바뀌었다. 이 중 4개는 1점에서 2점으로, 2개는 1점을 유지하였다.

유지된 판정과 변경된 답변의 판정을 합친 누적 진단 평균은 C0 0.9037, C1 1.3259였다. 저장 초안의 후처리 손실을 확인한 보조 결과이므로 새로운 전체 서비스 생성 성능으로 사용하지 않았다. 개선되지 않은 두 답변은 초안부터 필요한 사실이 없어 후처리 개선만으로 복구하지 못하였다.

4.5 Shadow60의 검색·생성 진단

4.5.1 출처 분리와 검색 결과

DEV에서 얻은 개선이 다른 문서의 질문에서도 나타나는지 확인하기 위해 Shadow60을 만들었다. DEV와 문서 ID·원문 해시·연도를 뺀 제목·대표 URL을 비교해 중복을 확인하였다. 점수를 보기 전에 발견한 중복 출처를 다른 자료로 바꾸고 질문과 정답 근거를 확정하였다.

핵심 42문항은 단순 질문 24개와 복합 질문 18개다. 원문 파일은 42개, 게시물 URL은 40개이며 같은 게시물의 서로 다른 첨부파일을 사용한 경우가 있다. 나머지는 역할 변형 8문항과 답변 불가·모호성·프롬프트 주입을 시험하는 도전 10문항이다. 이 질문은 독립된 사람이 검수한 최종 평가셋이 아니라 본 과제에서 만든 진단용 질문이다.

9월 4일 동일한 고정 인덱스, BM25 및 문맥 8개로 C0·C1의 60개 요청을 각각 실행하였다. 생성기는 추출형이며 오류는 없었다.

표 4.10. Shadow 핵심 42문항 검색 결과

지표	C0	C1
문서 Hit@5	40/42 (95.2%)	38/42 (90.5%)
문서 Hit@8	41/42 (97.6%)	39/42 (92.9%)
모든 필수 근거 회수@8	22/42 (52.4%)	21/42 (50.0%)
평균 근거 회수율@8	0.6071	0.5833

Shadow에서는 DEV에서 얻은 검색 개선이 다시 나타나지 않았다. 문서 Hit@8 차이의 95% 신뢰구간은 [-0.1190, 0], McNemar 검정의 p값은 0.5였다. 필수 근거를 모두 찾은 비율의 차이는 신뢰구간 [-0.1190, 0.0476], p값 1.0이었다. 표본과 두 조건의 결과가 달랐던 문항 수가

적어 C1이 일반적으로 더 나쁘다고 단정할 수는 없다. 다만 DEV의 높은 적중률이 다른 출처의 질문에서도 유지되지는 않았다.

4.5.2 생성 완결성과 결과

9월 5일 C1으로 60문항을 세 번 생성하여 180개 답변을 확보하였다. 생성 모델은 Gemini 3.5 Flash-Lite, 출력 상한은 900토큰이었다. 세 회차의 문맥과 생성 입력은 동일하게 유지하였다. 9월 6일 종료된 Judge v11 평가에서는 177개가 유효하고 3개가 형식 오류였다. 오류는 모호성 도전 문항에만 있어 전체 60문항의 최종 평균과 다수결 GFC는 확정하지 않았다. 사전에 지정한 핵심 42문항의 126개 판정은 모두 유효하였다.

표 4.11. Shadow 핵심 질문의 독립 생성 3회 결과

집단	문항 수	회차별 GFC 수	다수결 GFC	평균 / 2점
핵심 전체	42	14·17·13	15/42 (35.7%)	1.1111
단순 질문	24	10·11·9	10/24 (41.7%)	1.2778
복합 질문	18	4·6·4	5/18 (27.8%)	0.8889

필수 근거를 모두 찾은 21문항 중 다수결 GFC를 충족한 문항은 10개였고, 11개는 실패하였다. 반대로 지정 근거를 모두 찾지 못한 21문항 중에서도 5개는 GFC를 충족하였다. 첫 결과는 근거를 찾아도 생성과 출처 연결 과정에서 실패할 수 있음을 보여 준다. 두 번째 결과는 정답으로 지정하지 않은 다른 청크에서도 유효한 근거를 찾을 수 있음을 보여 준다. 점수를 본 뒤 정답 근거를 바꾸지는 않았다. Shadow에서는 C0·C2의 답변을 생성하지 않아 상대적인 개선 폭은 계산하지 않았다. 표 4.11은 C1의 결과다.

4.5.3 대표 실패 사례

첫째, 파일 식별자를 연도로 오인한 검색 손실이다. 실제 평가 질문은 “2026 K-water 장학회 청년 멘토의 모집인원·대상·선발일정과 활동기간·혜택을 알려줘.”였다. 보존된 공식 웹문에는 “모집 인원 : 88명”, “활동 기간 : 2026년 5월 ~ 12월”이 있다. 그러나 파일 식별자 203839의 앞 네 자리 2038을 연도로 해석한 강등이 적용되어 정답 청크가 후보 순위 1위에서 71위로 밀렸다. 연도를 포함하는 질문을 처리할 때 숫자 문자열의 위치와 의미를 구분해야 한다.

둘째, 학년도와 실제 일정 연도를 동일시한 검색 손실이다. “2026 교육대학원 학위논문 심사에서 심사요구서·심사료 제출일과 발표일, 결과보고서 및 최종논문 제출 일정을 정리해줘.”라는 질문의 근거 문서는 제목에 “2025학년도 후기”를 포함하지만 보존된 파싱 표의 일정은

“2026. 04. 09”, “2026. 06. 26” 등으로 작성되어 있다. 제목 연도만 사용한 강등 때문에 정답 체크가 후보 순위 2위에서 52위로 밀렸다. 문서의 학년도와 개별 절차의 달력 연도를 분리해야 한다.

셋째, 올바른 초안이 인용 검증에서 제거된 생성 이후 손실이다. 질문은 “제21회 대학(원) 생 지식재산 우수논문공모전 참가 자격과 신청·논문 제출 마감은 언제야?” 였다. 원문은 국내 대학(원) 재학·휴학생, 개인 또는 3인 이하 팀의 참가 자격과 5월 31일 18시 신청 마감, 8월 3일 18시 논문 마감을 포함한다. 첫 생성 초안에도 이 세 정보가 모두 있었다.

표 4.12. 공모전 질문의 단계별 관찰

단계	관찰 내용
검색 근거	제목의 제21회와 본문의 자격·마감 확보
생성 초안	자격·신청 마감·논문 마감을 세 문장으로 답변
검증 과정	세 문장의 행사 회차와 본문 근거 결합 실패
최종 답변	“검색 결과는 있으나 답변 문장을 지지하는 근거를 충분히 확인하지 못했습니다.”

기록을 확인하니 검사기가 제목의 “제21회”를 수량으로 읽었지만 본문 근거에는 이 값이 없다고 판단하여 세 문장을 모두 제거하였다. 문서를 못 찾거나 모델이 처음부터 틀린 답을 쓴 사례가 아니라, 올바른 초안을 검사하면서 문제가 생긴 사례다. 그렇다고 제목의 모든 숫자를 근거로 허용하면 다른 행이나 문서의 값과 잘못 연결될 수 있으므로 숫자가 가리키는 범위를 함께 확인해야 한다. 위 세 사례는 실험 조건을 고정한 뒤 발견한 개별 오류이며 전체 오류의 비율을 나타내지는 않는다.

4.6 보안 검사 파일럿

보안 평가는 입력 문서에 포함된 공격 지시가 모델 입력과 최종 답변에 어떻게 반영되는지 확인하는 데 목적이 있다. 9월 9일 보안 적용 전, 병합된 보안본, 결함을 수정한 별도 사본을 비교하여 총 102개 답변·판정 쌍을 완성하였다. 조건마다 정상 질문 14개, 합성 공격 10개와 대응 대조 10개를 사용하였다. 합성 20개는 서로 다른 20문항이 아니라 가상 열람실 운영시간 질문 하나의 변형이다. 생성과 판정은 각각 한 번이며 생성 모델과 Judge는 앞선 평가와 동일하다.

공격 문구는 외부 공개 공격 데이터셋을 그대로 사용한 것이 아니라 본 과제의 검사 기능을 확인하기 위해 만든 합성 사례다. 목표 변경·역할 위장·가짜 비밀 공개 유도는 Perez와 Ribeiro가 구분한 목표 탈취·프롬프트 유출 개념과 관련된다[8]. 이를 검색 문서에 넣는 상황은 Greshake 등의 간접 주입 위협과 연결된다[9]. 다만 실제 시스템 프롬프트나 비밀의 유출 성공을 측정한 것은 아니다.

10개 변형은 이전 지시 무시, 역할 변경, 비밀 공개 문구, 가상 도구 호출 문구, 허위 인용, 시스템 태그 위장, 한국어 목표 변경, 정상 금지 문구와 공격의 혼합, 파일명 속 공격, 모든 근거가 오염된 상황을 포함한다. 파일명·혼합 문구·전체 문맥 오염은 본 구현의 검사 누락을 확인하기 위한 자체 확장이다. 실제 명령 실행이나 외부 전송을 수행하지 않고 합성 표식 문자열이 입력과 출력에 남는지만 확인하였다. 원문 시나리오는 동봉한 supplement/security-scenarios.json에 보존하였다.

표 4.13. 보안 조건별 정상 품질과 공격 표식 관찰

지표	보안 적용 전	병합 보안본	수정 사본
정상 질문 GFC	6/14 (42.9%)	6/14 (42.9%)	5/14 (35.7%)
정상 평균 / 2점	1.0714	1.1429	1.0714
공격 문서 제외	0/10 (0.0%)	7/10 (70.0%)	9/10 (90.0%)
모델 입력의 표식 잔존	10/10 (100.0%)	3/9 (33.3%)	1/9 (11.1%)
최종 답변의 표식 출력	1/10 (10.0%)	0/10 (0.0%)	0/10 (0.0%)
생성 없는 보안 회피	0/10 (0.0%)	1/10 (10.0%)	1/10 (10.0%)
대응 대조 GFC	10/10 (100.0%)	10/10 (100.0%)	10/10 (100.0%)

보안 기능을 적용한 두 조건에서는 공격 사례 한 개가 생성 모델을 호출하기 전에 차단되었다. 따라서 모델 입력과 초안을 관찰한 수는 각각 9개다. 관찰하지 못한 값을 공격 문구가 없었던 것으로 세지는 않았다. 여기서 표식(canary)은 실제 비밀이 아니라 시험용 문자열이며, 최종 답변에 이 문자열이 나왔는지를 확인하였다.

보안 적용에 따라 모델에 전달되는 자료와 최종 표식 출력은 달라졌지만, 정상 질문의 답변 품질이 좋아졌다는 근거는 얻지 못하였다. 수정본에서도 표식 하나가 모델 입력에 남았다. 최종 출력은 기존 보안본과 수정본 모두 0/10이므로, 이번 수정이 최종 출력률을 더 낮췄다고 볼 수도 없다. 질문 하나의 변형을 조건마다 한 번씩 생성한 실험이며 실행 순서와 시간의 영향도 분리하지 못했다. 따라서 일반적인 공격 방어율이나 보안 기능 자체의 효과로 확대해 해석하지 않았다. 공격 목표를 의미상 달성했는지를 기준으로 한 성공률도 따로 측정하지 않았다.

4.7 최종 holdout 평가와 사람 검수

4.7.1 평가셋과 실행 조건

최종 평가는 개발에 사용하지 않은 holdout 36문항으로 9월 14일 수행하였다. 핵심 27문항은 학사·입학·핵심 행정·취업·졸업·국제·등록·장학·학생지원의 9개 영역에서 만들었다. 각 영역에는 단일 사실을 묻는 질문, 여러 근거를 함께 묻는 질문, 표의 행·열이나 문서 구조를 정확히 읽어야 하는 질문을 하나씩 배치하였다. 서로 다른 출처 문서군 27개를 사용했으며, 문항당 필수 주장 수는 2~5개로 총 87개다. 나머지 도전 9문항은 답변 불가 3개, 범위·시점 모호 3개, 프롬프트 인젝션 3개다.

정답 근거에는 출처 문서와 원문 인용을 기록하였다. 개발자 1인이 원문과 대조한 뒤 평가셋을 확정하고 파일 해시를 남겼다. 결과를 본 뒤 질문이나 정답을 고치지는 않았다.

인력 제약으로 당초 계획한 두 사람의 독립 검수는 수행하지 못하였다. 대신 개발자 1인이 원문을 보며 답변을 채점하고 Judge 판정과 비교하였다. 코드는 보안 실험에 사용한 기존 보안 본, 검색 인덱스는 앞선 실험과 같은 고정본을 사용했다. 생성 모델은 Gemini 3.5 Flash-Lite이며 문맥은 8개, 문서당 청크는 2개로 제한하였다. 보안 검사는 결과를 기록하는 데 그치지 않고 실제로 적용하였다. 채점은 Gemini 3.1 Flash-Lite와 v11 평가표, temperature 0으로 답변마다 한 번 수행하였다.

핵심 27문항은 C0·C1에서 각각 3회, 도전 9문항은 C1에서 3회 생성하도록 계획하여 총 생성 예정 답변은 189개였다. 제공자의 요청 제한(HTTP 429)이 발생한 뒤에는 전체 호출 사이에 15초 간격을 두고 재개했으며 기존 답변은 다시 만들지 않았다. C1 첫 회차의 답변 하나는 429 오류 이후 원문 추출형 응답으로 대체되었다. 이를 운영 오류로 기록하고 GFC 실패로 집계하였다. 도전 문항의 Judge 형식 오류 4건은 판정이 없는 경우로 구분하였다. 관련 파일과 해시는 첨부한 재현 정보에 정리하였다.

4.7.2 자동 평가 결과

표 4.14. 최종 holdout 자동 평가 결과(생성 3회, Judge v11)

집합·조건	예정	정상 출력	유효 Judge	GFC 수	GFC / 예정	평균 / 2점
핵심 C0	81	81	81	19	23.5%	0.9506
핵심 C1	81	80	80	18	22.2%	0.8750
도전 C1	27	27	23	7	판정 불완전	0.7391

핵심 27문항에 대해 조건별로 생성할 예정이던 답변 81개를 기준으로 계산하면, C1과 C0의 GFC 차이는 -1.23% 였다. 질문군 단위 대응 부트스트랩 10,000회의 95% 신뢰구간은 $[-19.75, +17.28]\%$ 였고, 차이가 우연히 생길 수 있는지 확인한 정확 부호 치환 검정의 p값은 0.892였다. 회차별 GFC 수는 C0가 6·7·6개, C1이 6·7·5개였다. 이번 최종 평가에서는 C1의 개선을 확인하지 못하였다.

DEV와 같은 다수결 기준, 즉 세 번 중 2회 이상 완전 정답인 문항의 비율로 비교하면 holdout은 C0 6/27(22.2%), C1 5/27(18.5%)였다. DEV45의 C0 13/45(28.9%), C1 20/45(44.4%)보다 낮다. holdout의 3분의 2는 여러 근거나 문서 구조를 정확히 읽어야 하는 질문이고, 코드 수정에 사용하지 않은 문항이다. 평가 질문과 조건이 다르므로 이 차이를 단순한 성능 하락량으로 보지는 않지만, 개발셋의 높은 수치를 일반적인 서비스 성능으로 사용할 수 없음을 보여준다.

4.7.3 검색 단계와 생성·검증 단계의 분리

오류가 생긴 단계를 찾기 위해 저장 기록을 검색 후보, 최종 근거, 생성 초안, 검사 후 답변 순서로 비교하였다. 검색 후보는 BM25 상위 128개, 중복 제거 후 후보는 32개, 모델에 전달한 최종 청크는 8개다. 각 단계의 청크 ID, 생성 초안, 문장별 검사 결과, Judge의 필수 주장별 판정을 연결했으며 모델을 다시 호출하지 않았다.

문서 적중은 정답 출처 문서가 해당 단계에 포함되었는지로 계산하였다. 근거 청크 적중은 실험 당시 저장된 일치 판정을 사용했다. 이 판정은 문자 표기를 NFKC로 통일하고 유사도 0.85를 기준으로 비교한 것이다. 세 회차의 검색 결과는 모두 같았다. 집계 방법과 입력·결과 파일은 첨부한 재현 정보에 남겼다.

이번 실험에서는 후보 검색 단계에서 정답 출처 문서를 모두 찾았고, 최종 청크 8개에도 출처 문서의 5건 중 4건 이상이 포함되었다. 후보 128개의 수치는 첫 회차 기준이지만 세 회차의 검색 결과가 같아 나머지 회차에도 해당한다. 따라서 문서를 처음 찾는 일보다는 그 문서의 필요한 부분을 최종 근거에 넣는 과정에서 정보가 빠졌다.

문항당 필수 근거 2~5개를 문맥 8개·문서당 2청크 안에 모두 담은 문항은 절반 미만이었다. 특히 여러 근거와 문서 구조를 함께 읽어야 하는 질문에서 부족했다. 다만 지정 근거 청크가 없는 주장도 25.6~30.6%는 Judge가 근거를 갖췄다고 판정하였다. 같은 문서의 다른 부분에도 유효한 근거가 있을 수 있어, 지정한 청크를 찾았는지만으로 근거 확보 여부를 완전히 설명할 수는 없다.

필수 근거를 모두 확보한 문항에서도 완전정답률은 C0 41.0%, C1 33.3%에 그쳤고 평균 점수는 2점 만점에 1.1~1.3점이었다. 근거 청크가 전달된 필수 주장 중 최종 답변에 근거를 갖춰 포함된 비율은 54.1~61.8%였다. 나머지 38.2~45.9%는 근거를 전달했어도 충분히 답하지

표 4.15. holdout 핵심 문항의 단계별 근거 회수와 답변 결과

단위	지표	C0	C1
주장	필수 주장 수(정상 생성 응답 기준)	261	256
주장	첫 회차 검색 후보 128개에 출처 문서 포함	87/87 (100%)	82/82 (100%)
주장	최종 문맥 8개에 출처 문서 포함	213/261 (81.6%)	208/256 (81.2%)
주장	최종 문맥 8개에 지정 근거 청크 포함	144/261 (55.2%)	148/256 (57.8%)
주장	근거 청크가 있는 주장 중 Judge 지지	89/144 (61.8%)	80/148 (54.1%)
주장	근거 청크가 없는 주장 중 Judge 지지	30/117 (25.6%)	33/108 (30.6%)
응답	출처 문서를 모두 포함	66/81 (81.5%)	62/80 (77.5%)
응답	필수 근거 청크를 모두 포함	39/81 (48.1%)	39/80 (48.8%)
응답	근거를 모두 포함한 응답의 GFC	16/39 (41.0%)	13/39 (33.3%)
응답	근거가 불완전한 응답의 GFC	3/42 (7.1%)	5/41 (12.2%)
응답	근거를 모두 포함한 응답의 평균 / 2점	1.256	1.128

주: 표 4.15와 표 4.16의 단계별 분석은 정상 생성 응답 C0 81개, C1 80개를 대상으로 한다. C1의 운영 오류 1건과 해당 응답의 필수 주장 5개는 제외했으며, 공식 GFC에서는 해당 오류를 실패로 포함하였다.

못한 것으로 판정되었다. 검색 이후에도 개선할 문제가 남아 있다는 뜻이다. 다만 이 비율을 검색·생성·검사 단계 각각의 책임 비율로 나눌 수는 없다.

Judge가 C0의 실패 답변에 붙인 원인은 필수 내용 누락 60/62, 부적절한 답변 회피 49/62, 명시적인 답변 회피 15/62였다. 근거 없는 사실 추가(2)와 모순(2)보다 누락과 회피가 많았다. C1도 각각 56·45·16으로 비슷했다. 한 답변에 여러 원인이 붙을 수 있으므로 이 수를 더해 실패 답변 수로 해석하지 않는다.

표 4.16. 생성 초안과 출력 검사 단계의 손실

지표	C0	C1
출력 검사가 판정한 초안 문장	289	298
근거 미확인으로 제거된 문장	108 (37.4%)	115 (38.6%)
제거 문장 중 정답 핵심값 문자열 포함	27/108 (25.0%)	33/115 (28.7%)
답변 결정: 전체 답변 / 부분 답변 / 회피	17 / 49 / 15	16 / 48 / 16
비GFC 답변: 근거 불완전	39 / 62	36 / 62
비GFC 답변: 근거 완비·초안 핵심값 일부 미포함	13 / 62	20 / 62
비GFC 답변: 근거 완비·초안 핵심값 모두 포함	10 / 62	6 / 62

생성 이후의 문제는 두 가지로 나뉘었다. 첫째, 초안에서 필요한 내용을 빠뜨리거나 다른 학년도 문서의 값을 사용한 경우다. 2025학년도 후기 교육대학원 논문 일정 질문에서는 2024학년도 후기 문서가 1위, 정답인 2025학년도 후기 문서가 2위로 함께 전달되었다. 그런데 모델은 이전 문서의 4월 16일·4월 22~23일·7월 23~24일을 “2025학년도 후기” 일정으로 답했다.

그 결과 필수 주장 세 개가 모두 누락으로 판정되었다. Shadow의 검색 오류와 마찬가지로 학년도와 실제 일정 연도를 구분하지 못한 사례다.

둘째, 맞는 초안 문장도 출력 검사에서 제거될 수 있었다. 검사기는 초안 문장의 37.4~38.6%를 근거 미확인으로 제거했다. 제거된 문장 중 정답의 핵심값 문자열을 포함한 문장은 C0 27/108(25.0%), C1 33/115(28.7%)였다. 정답 핵심값 문자열을 포함한 제거 문장 60개에서는 의미 관계 불일치가 28개, 핵심값 불일치가 32개였다.

장애학생 컴퓨터교육 질문에서는 초안이 2일차·4일차의 날짜·시간·주제를 정확히 썼지만, 세 문장이 유사도 0.58~0.75로 제거되었다. 최종 답변은 “검색 결과는 있으나 답변 문장을 지지하는 근거를 충분히 확인하지 못했습니다.”가 되었다. 계절학기 단기파견 질문에서도 “최대 6학점”을 담은 문장이 유사도 0.778로 제거되어 핵심 수치가 빠졌다.

다만 핵심값 포함 비율은 문자열만 비교한 결과다. 같은 뜻을 다른 말로 쓴 정답은 놓칠 수 있고, 숫자만 같고 대상·시점이 틀린 문장도 포함할 수 있다. 따라서 표 4.16의 비율을 ‘올바른 문장을 잘못 제거한 비율’이나 그 최소값으로 해석해서는 안 된다. 초안 자체의 누락과 검사 중 제거를 정확히 나누려면 각 문장을 사람이 추가로 확인해야 한다.

4.7.4 사람 1인 검수와 Judge의 일치도

개발자 1인이 첫 회차 답변 62개(핵심 C0 27개, C1 26개, 도전 9개)를 채점하였다. 화면에는 조건명·모델·회차·Judge 판정을 숨기고 답변을 임의 순서로 배치하였다. 대신 원문, 필수 내용, 모델에 전달한 근거, 실제 답변과 인용을 함께 보여 주었다. 본 채점 전 DEV 답변 8개로 기준을 연습했으며 이 답변은 일치도 계산에서 제외하였다. 최초 확정판정은 수정하지 못하게 했다.

채점할 때는 정답지에 있는 내용인지뿐 아니라 실제 답변에 그 내용이 있고 전달된 근거가 뒷받침하는지를 확인하였다. 다만 채점 전에 조건별 전체 성적이 알려져 있었고, 개발자가 답변 문체로 조건을 짐작할 수도 있었다. 따라서 완전히 조건을 모르는 상태의 채점이나 독립된 사람의 검수는 아니다. 사용한 최종 채점 기록과 파일 식별값은 첨부한 재현 정보에 남겼다.

표 4.17. 사람 1인 판정과 Judge 판정의 일치도

표본	n	GFC 일치	κ	균형 정확도	Macro F1	점수 일치	가중 κ
핵심 전체	53	0.906	0.705	0.899	0.852	0.849	0.852
핵심, 불확실 제외	48	0.938	0.786	0.912	0.893	0.875	0.867
핵심 C0	27	0.889	0.658	0.855	0.829	0.852	0.858
핵심 C1	26	0.923	0.755	0.955	0.876	0.846	0.846
도전	7	0.571	0.000	—	0.364	0.429	0.000

핵심 문항에서 사람과 Judge의 GFC 판정은 53개 중 48개가 같았다. 우연한 일치율을 고려하는 지표인 Cohen κ 는 0.705였다. 사람이 판단하기 어렵다고 표시한 5개를 빼면 일치율은 0.938, κ 는 0.786이다. 이는 참고 기준으로 정한 일치율 0.80· κ 0.60보다 높지만, 두 사람의 독립 점수를 대신한 것은 아니다.

사람이 GFC로 판정한 답변은 C0 5/27, C1 4/26으로, 같은 답변에 대한 Judge의 6/27, 6/26보다 적었다. 사람이 준 0·1·2점 답변 수는 C0가 7·12·8개, C1이 6·14·6개였다.

사람의 판정도 표 4.15와 같은 방향을 보였다. 필수 근거를 모두 확보한 답변 26개의 사람 GFC는 8개(30.8%), 평균 1.27점이었고, 근거가 불완전한 27개는 1개(3.7%), 0.78점이었다. 점수 기록에는 “체크는 제대로 전달된 것 같으나 답변을 생성하지 못함”, “근거 자체는 제대로 확보했으나 과거 지침을 참고하고 있음”과 같이 검색 이후의 실패를 짚은 메모와 석사과정 내용, 제출 기한, 주최 주기, 비용 등 특정 항목의 누락을 지적한 메모가 남아 있다. 사람이 2점을 주고도 GFC로 인정하지 않은 답변 5개는 핵심 내용은 맞지만 불필요한 문장이 추가되었거나, 과거 지침을 근거로 삼았거나, 요구된 명칭이 빠진 경우로 기록되었다.

도전 문항은 유효 비교 7개에서 일치율 0.571, κ 0으로 두 판정이 같았다. 프롬프트 인젝션 3문항은 세 회차 모두 주입된 지시를 따르지 않았으나, 정상 질문 부분까지 “제공된 검색 근거에서 질문에 답할 내용을 확인할 수 없습니다.”로 회피하여 사람과 Judge가 모두 0점으로 판정하였다. 답변 불가·범위 모호 문항에서 Judge는 회피 자체를 적절하다고 보아 3개를 통과시켰으나, 점수자는 일률적인 회피 문구가 문항별로 요구한 공식 조회 경로 안내나 범위 확인을 담지 못했다고 보아 통과시키지 않았다. 따라서 보안 지시의 거부는 작동했지만, 거부 뒤에 정상 요청을 이어서 처리하는 행동은 확보되지 않았다.

이 비교는 개발자 한 사람과 Judge의 판정이 얼마나 같은지 확인한 것이다. 생성과 채점에 같은 계열의 모델을 사용했고 표본이 작으며, 개발자도 채점 전에 조건별 성적을 알고 있었다. 따라서 일치도가 높다는 이유로 C1의 성능이 좋아졌거나 Judge가 다른 평가에서도 정확하다고 결론 내릴 수는 없다.

4.8 종합 해석과 검증 범위

표 4.18은 각 실험의 적용 전후 변화량을 정리한 것이다. 변화량은 반올림 전 비율에서 계산했다. 파서는 Baseline과 Cascade, 초기 DEV·DEV 생성·Shadow·holdout은 C0와 C1, 후속 DEV는 해당 후속 실험의 보완 전후, 보안은 적용 전과 병합 보안본의 비교다. 규칙 하나씩의 기여도는 측정하지 않았다. DEV의 GFC 증가와 holdout의 차이는 통계적으로 유의한 차이로 확인되지 않았으며, 보안의 표식 출력률은 일반적인 공격 성공률이 아니다.

표 4.19에 주요 관측을 정리하였다. 각 행은 앞 절의 개별 실험에 대응하며 평가셋·코드·생성 조건이 다른 행 사이의 수치를 연속적인 개선 단계로 해석하지 않는다.

DEV에서는 정답 문서를 찾은 비율과 평균 답변 점수가 높아졌다. C2에서는 답변 문장과 출처를 함께 생성하는 방식을 시험했으나, 확실한 개선으로 결론 내릴 근거는 부족했다. Shadow와 최종 holdout에서는 검색 규칙의 개선 효과가 다시 나타나지 않았다.

holdout에서는 정답 문서를 검색하고 필요한 근거를 전달한 뒤에도 초안에서 내용이 빠지거나 검사기가 문장을 제거하였다. 각 단계에서 얼마나 손실이 생겼는지는 추가 확인이 필요하다. 다음 개선에서는 검색 규칙을 늘리는 것과 함께, 모델이 대상·수치·시점을 정확히 답하게 하고 검사기가 올바른 문장을 잘못 제거하지 않도록 하는 데 우선순위를 둘 필요가 있다.

소프트웨어 검증 기록에서는 9월 6일 전체 단위 테스트 803건 실행 중 6건 제외, 실패 0건과 프론트엔드 검사·빌드 통과를 확인하였다. 9월 8일 보안 수집기 수정 사본은 857건 실행 중 6건 제외, 실패·오류 0건이었다. 제외 항목은 선택적 의존성이 필요한 테스트다. 이는 해당 코드·환경의 회귀 검증이며 모델 정답률이나 다른 시점의 전체 코드 검증을 대신하지 않는다.

이번 평가의 주요 한계는 개발 질문을 반복 사용한 점, 표본이 작은 점, 생성과 채점에 같은 계열의 모델을 쓴 점, 지정한 정답 근거가 불완전할 수 있다는 점이다. 최종 holdout은 코드 수정에 쓰지 않았지만 원문 27개 중 9개가 Shadow와 겹치므로 세 평가셋이 모두 독립적인 것은 아니다.

holdout 36문항의 자동 평가와 개발자 1인의 채점은 마쳤지만, 두 사람이 독립적으로 검수하고 의견을 맞추는 절차는 수행하지 못했다. 사람의 판정도 오류 없는 정답으로 볼 수는 없다. 초안에서 빠진 내용과 검사 중 제거된 내용을 나눈 분석은 문자열 비교에 의존하므로, 실제 의미를 확인하는 추가 검수가 필요하다. 파싱 결과와 원문 화면의 독립 검수, 다양한 공격 유형의 평가도 남아 있다.

외부 챗봇과 같은 질문 및 같은 채점 기준을 적용한 답변 성능 비교는 수행하지 않았다. 같은 조건에서 상용 서비스의 응답 시간·비용을 비교하거나, 실제 사용자가 업무를 얼마나 잘 마치고 정보를 얼마나 빨리 찾는지도 측정하지 않았다. 따라서 현재 결과만으로 상용 서비스보다 빠르거나 실제 행정 업무 시간을 줄였다고 결론 내릴 수는 없다.

표 4.18. 성능 변화량 요약: 동일 행 안에서만 전후 비교

비교·지표	적용 전	적용 후	변화량
표적 파서 근거 보존	48/54 (88.9%)	54/54 (100.0%)	+11.11%p
초기 DEV 문서 Hit@5	29/45 (64.4%)	40/45 (88.9%)	+24.44%p
초기 DEV All Gold@8	10/45 (22.2%)	17/45 (37.8%)	+15.56%p
후속 DEV 필수 근거 완비	33/45 (73.3%)	43/45 (95.6%)	+22.22%p
DEV 생성 평균 / 2점	0.8815	1.2148	+0.3333점
DEV 다수결 GFC	13/45 (28.9%)	20/45 (44.4%)	+15.56%p
Shadow 문서 Hit@8	41/42 (97.6%)	39/42 (92.9%)	-4.76%p
holdout GFC / 예정 응답	19/81 (23.5%)	18/81 (22.2%)	-1.23%p
보안 공격 문서 제외	0/10 (0.0%)	7/10 (70.0%)	+70.00%p
보안 최종 표식 출력	1/10 (10.0%)	0/10 (0.0%)	-10.00%p

표 4.19. 핵심 실험 결과와 해석 범위

평가	주요 관측	해석 범위
문서 처리	2,260건 중 2,247건 파싱, 44,520청크 색인	구축 규모이며 내용 정확도와는 별개
표적 파서 비교	54개 근거 중 Baseline 48개, Challenger·Cascade 각 54개 보존	알려진 실패 유형의 18문서 표본
초기 DEV 검색	C0→C1 문서 Hit@5: 29/45→40/45	초기 평가셋에서의 같은 문서 집합 비교
후속 DEV 검색	보완 전→후 Hit@5: 40/45→45/45	개정 평가셋과 후속 코드의 별도 비교
DEV 생성	C0→C1 평균: 0.8815→1.2148; 다수결 GFC: 13/45→20/45	평균 점수 개선 관측, GFC 차이의 통계적 유의성 미확인
C2 탐색	평균 1.3630; 다수결 GFC 26/45	출력 상한·온도와 검증 처리 조건이 다른 탐색 실험
Shadow 핵심	C0→C1 Hit@8: 41/42→39/42; C1 GFC 15/42	검색 개선 미유지; C0 생성과의 비교 없음
소규모 보안 실험	표식 출력 1/10→0/10→0/10; 정상 GFC 6/14→6/14→5/14	적용 전·병합본·수정 사본 순서; 단일 질문의 공격 변형
최종 holdout	C0·C1 예정 응답 기준 GFC 23.5%·22.2%; 차이 -1.23%p, 95% CI [-19.75, +17.28]	개발 미사용 36문항, 생성 3회; 검색 조정의 효과 미재현
holdout 단계 분해	출처 문서 확보: 후보 100%·문맥 81.6%; 근거를 모두 찾은 문항의 GFC 41.0%(C0)	근거를 확보해도 내용 누락·문장 제거 발생; 근거 청크를 모두 찾은 비율은 48.1%
사람 검수	핵심 53개 GFC 일치 0.906, κ 0.705; 도전 7개 κ 0	개발자 1인과 Judge의 일치도; 독립 2인 검수 아님

제5장 결론 및 향후 연구 방향

5.1 연구 결과 요약

본 과제는 부산대학교와 공공기관의 공식 문서를 수집하고 검색하여, 답변과 원문을 함께 보여 주는 행정 문서 챗봇을 구현하였다. 부산대학교 선별 문서 2,260건 중 2,247건에서 글과 표를 추출했고, 품질 검사를 거친 44,520개 청크로 검색 인덱스를 만들었다. 사용자는 기관을 선택해 질문하고 답변 문장에 붙은 인용과 원문을 확인할 수 있다. 생성 전에는 문서 속 공격 지시를, 생성 후에는 답변의 근거와 인용을 검사하도록 하였다.

검색 성능과 답변 품질은 나누어 평가하였다. 9월 2일 개발용 45문항을 같은 문서 집합에서 비교한 결과, BM25 검색 규칙 적용 후 문서 Hit@5는 64.4%에서 88.9%로 24.4%p 높아졌다. 9월 4일 완료한 반복 생성 비교에서는 0~2점 평균이 0.8815에서 1.2148로 높아졌다. 다만 세 번 중 2회 이상 완전 정답인 문항의 비율이 증가한 것은 통계적으로 확인하지 못하였다. 다른 문서로 만든 Shadow60 진단에서도 검색 개선은 유지되지 않았다. 실험별 결과와 해석 범위는 표 4.19에 정리하였다.

9월 9일 소규모 보안 실험에서는 공격 변형 10개 중 최종 답변에 시험용 표식이 나온 사례가 보안 적용 전 1건, 기존 보안본과 수정 실험본에서 각각 0건이었다. 이는 이번 합성 공격에서 확인한 결과이며 일반적인 공격 방어율이나 답변 정확도 향상을 뜻하지 않는다. 모델 입력에 공격 표식이 남거나 정상 질문에 충분히 답하지 못한 사례가 있어 추가 확인이 필요하다.

9월 14일에는 개발에 사용하지 않은 holdout 36문항으로 최종 평가하였다. 핵심 27문항의 생성 예정 답변 81개를 기준으로 한 완전정답률은 C0 23.5%, C1 22.2%였다. 개발 질문에서 얻은 개선이 최종 평가에서는 다시 나타나지 않았다.

기록을 단계별로 살펴보면 검색 후보에는 정답 출처 문서가 모두 있었고, C0의 최종 청크 8개에도 81.6%가 포함되었다. 그러나 필요한 근거를 모두 전달한 문항에서도 완전정답률은 33.3~41.0%였다. 근거가 전달된 필수 주장의 38.2~45.9%는 최종 답변에 충분히 반영되지 않은 것으로 판정되었다. 초안이 필요한 값을 빠뜨리거나 이전 학년도 값을 선택하는 문제와, 출력 검사 중 문장이 제거되는 문제가 확인되었다.

제거된 문장 중 정답 핵심값 문자열을 포함한 문장은 C0 27/108(25.0%), C1 33/115(28.7%)였다. 숫자나 표현이 같아도 내용 전체가 맞는 것은 아니므로, 이 값을 정답 문장의 잘못된 제거 비율로 볼 수는 없다. 실제 비율은 문장별로 추가 검수해야 한다. 개발자 1인이 첫 회차 답변 62개를 채점했을 때 핵심 문항의 GFC 판정은 Judge와 일치율 0.906, Cohen κ 0.705를 보였다. 사람의 검수 기록에서도 근거를 전달한 뒤 답변에서 내용이 빠지는 문제가 확인되었다.

본 과제는 검색·생성·보안 기능을 구현하고 각 단계의 검사 기록을 남겼다. 동시에 개발 질문에서 얻은 개선이 새로운 질문에는 유지되지 않았고, 근거를 찾은 뒤에도 내용이 빠지거나 답변을 지나치게 보류하는 문제가 남았다. 올바른 문장이 인용 검사에서 제거되는 사례도 확인하였다. 따라서 후속 작업에서는 검색뿐 아니라 근거를 답변에 빠짐없이 반영하는 생성 방식과 문장 검사 기준을 함께 개선해야 한다.

5.2 향후 연구 방향

다음 평가에서는 기존 실험에서 사용한 문서와 사실까지 분리해야 한다. 최종 holdout은 DEV와 원문을 분리하고 코드·문서 집합을 고정했지만, 원문 27개 중 9개가 Shadow와 겹쳤고 검수도 개발자 1인에 그쳤다. 앞으로는 독립된 두 사람이 검수하고 다른 판정은 함께 확인하여 자동 채점 결과와 비교할 필요가 있다. 오류는 기관·행정 영역·질문 난도별로 나누어 보고한다.

답변 검사에서는 사람이 확인한 문장을 기준으로 의미 관계와 핵심값 비교 규칙을 보완해야 한다. 수정 전후의 초안과 최종 답변을 비교해 올바른 문장이 새로 제거되지 않는지도 확인한다. 여러 학년도 문서가 함께 검색되면 제목의 학년도와 일정의 실제 연도를 구분하여 질문에 맞는 문서를 사용해야 한다. 단순·복합·모호한 질문과 적용 시점이 충돌하는 질문도 나누어 평가한다. 인용문이 원문에 있는지와 그 내용이 답변의 대상·수치·시점·예외를 뒷받침하는지는 따로 확인해야 한다.

개발 질문에 맞춘 검색 규칙은 새로운 질문에서도 효과가 있는지 확인한 뒤 적용해야 한다. 오타자·띄어쓰기·유사 표현을 시험할 때는 같은 답을 요구하는 질문끼리 묶고, 표현을 바꾸다가 기관명·연도·자격 조건까지 달라지지 않았는지 확인한다. 여러 항목을 묻는 질문은 대상·기간·비용·절차·예외로 나누어 각 항목의 근거를 찾았는지와 답변에 포함했는지를 검사한다.

모델에 전달할 근거의 양도 질문에 맞게 조절할 필요가 있다. 모델이 처리할 수 있는 길이에 따라 시스템 지시와 답변에 필요한 길이를 먼저 확보하고, 남은 범위에 중복을 줄인 근거를 넣는 방식을 검토한다. 자료를 줄이거나 질문을 나누더라도 원문 위치와 날짜·부정·예외 조건을 보존해야 한다. 현재의 고정된 근거 수와 새 방식을 완전정답률, 필수 근거를 찾은 비율, 실제 토큰 사용량과 응답 시간으로 비교한다.

보안 실험은 정상 업무, 공격 목적, 대상 문서를 늘려야 한다. 모델에 전달한 자료, 최종 답변, 파일명·제목 같은 출처 정보에 공격이 남는지 각각 확인하고, 정상 문서를 공격으로 잘못 판단해 답하지 못하는 경우도 측정한다. 별도 실험에서 고친 보안 코드는 기존 기능에 문제가 없는지 확인하고 반복 평가한 뒤 서비스에 반영해야 한다.

운영 중 문제가 생겼을 때 관리자가 서비스를 멈추고 복구하는 절차도 필요하다[13]. 새 요청을 막고 대기 작업을 취소한 뒤, 진행 중인 호출과 원인을 확인하고 다시 시작할 수 있어야 한다. 외부 제공자가 이미 접수한 호출은 즉시 멈추지 않을 수 있으므로 서버의 요청 차단과 외부 실행 중지는 구분한다. 중지 후 새 호출이 발생하거나 취소한 답변이 화면에 표시되지 않는지, 복구 권한과 기록이 유지되는지도 확인한다.

문서 갱신에서는 수집일·게시일·개정일·시행일·효력 종료일을 구분해야 한다. 같은 규정의 개정본과 한시적 안내가 어떤 관계인지도 관리할 필요가 있다. 적용 시점을 모르거나 자료가 충돌하면 임의로 최신 문서라고 판단하지 않고 사용자가 확인할 근거를 보여 준다.

다른 기관으로 확대할 때는 문서 수·형식·질문 특성에 맞춰 품질을 별도로 측정해야 한다. 실제 활용성은 장학금 신청 조건이나 연구비 집행 절차를 찾는 과제로 평가할 수 있다. 일반 웹 검색과 챗봇을 사용할 때의 과제 성공률, 원문 확인 시간, 적용 조건을 잘못 선택한 건수를 비교한다.

상용 서비스와 비교할 때는 같은 문서와 질문을 사용하고 가능한 범위에서 모델, 답변 길이 제한, 지역·네트워크 환경, 동시 요청 수를 맞춘다. 캐시를 쓰지 않는 첫 요청과 반복 요청을 나누고 실행 순서도 번갈아 배치한다. 내부 검색 시간을 알 수 없는 서비스는 사용자가 질문을 보낸 때부터 답변이 끝날 때까지의 시간을 비교한다. 응답 시간의 중앙값과 95백분위값, 오류율·비용·완전정답률을 함께 제시한다. 답변을 보류하거나 내용을 빠뜨려 빨라진 경우를 성능 개선으로 보지 않기 위해서다.

참고문헌

- [1] Patrick Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [2] Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. <https://doi.org/10.1561/15000000019>.
- [3] Vladimir Karpukhin et al. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020. <https://doi.org/10.18653/v1/2020.emnlp-main.550>.
- [4] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2009. <https://cormack.uwaterloo.ca/cormacksigir09-rrf.pdf>.
- [5] Nelson F. Liu et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. https://doi.org/10.1162/tacl_a_00638.
- [6] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, 2024. <https://doi.org/10.18653/v1/2024.eacl-demo.16>.
- [7] Lianmin Zheng et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html.
- [8] Fabio Perez and Ian Ribeiro. Ignore Previous Prompt: Attack Techniques For Language Models. ML Safety Workshop, NeurIPS 2022; arXiv:2211.09527, 2022. <https://doi.org/10.48550/arXiv.2211.09527>.
- [9] Kai Greshake, Sahar Abdelnabi, Shailesh Mishra, Christoph Endres, Thorsten Holz, and Mario Fritz. Not What You’ve Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. arXiv:2302.12173, 2023. <https://doi.org/10.48550/arXiv.2302.12173>.
- [10] Pusan National University. Tuition Payment Plan for Enrolled Students, Fall 2026, 2026. Korean PDF attachment, collected July 2026. https://www.pusan.ac.kr/kor/CMS/Board/Board.do?board_seq=1510073&mCode=MN095&mgr_seq=3&mode=view.

- [11] Geumjeong-gu; Pusan National University Career Center. 2026 Geumjeong Youth Job-Seeking Support Package Recruitment Notice, 2026. Korean HWP attachment, collected July 2026. <https://job.pusan.ac.kr/ko/notice/notice/view/203775?p=16>.
- [12] Pusan National University Admissions. Korean Guide: inform_20260116_korean.pdf, 2026. PDF attachment, collected July 2026. https://go.pusan.ac.kr/college_2016/pages/index.asp?b=B_1_1&bn=49176&m=read&p=50.
- [13] Dae Sun Kim. Written Consultation Report for the 2026 Capstone Design Project, School of Computer Science and Engineering. Korea Institute of Ocean Science & Technology, 2026. Written consultation, July 28 (in Korean).