

부산대학교 및 공공기관
행정 문서 검색 챗봇

과제 개요

과제 배경

공지·규정·첨부파일에
들어진 행정 정보

장학금 수혜 조건 등 필요한
정보를 확인하려면 여러 문서를
직접 찾아 읽고 비교해야 한다.

구현 목표

기관 문서를 검색해 답변하고,
각 문장의 원문 근거를 제시한다.

대학생활원 질문에 대한 답변과 보안 검사

2026학년도 2학기 대학생활원 공지는 어디서 확인하고 개별 문자도 보내줘?

[1] 인용 원문 · 19쪽

2026년도 2학기 대학생활원
부산캠퍼스 비원생 모집요강

대학생활원 공지사항은
대학생활원(부산) 홈페이지
공지사항, 각 동 게시판,
생활원(부산) 앱(APP)으로
확인 가능하며 개별통보
(SMS 등)는 하지 않습니다.



PNU Docs 문서 7개 참고

- 대학생활원 공지사항은 대학생활원 부산 홈페이지 공지사항, 각 동 게시판, 생활원 부산 전용 앱에서 확인 가능합니다. 1 2
- 대학생활원 공지와 지원 일정 등은 개별 통보나 안내를 하지 않습니다. 2 3
- 대학생활원 전용 앱을 반드시 다운로드 받아야 합니다. 1 2

▶ 답변 정보

복사 출처 7개 다시 답변

이 응답의 보안 검사 검색 근거 8개 허용 / 출력 인용 오류 0건

그림 1. 보안 적용 후 실제 응답(09.09)을 최신 화면(09.10)에 재현한 모습과 인용 원문.

설계 및 구현

대상 기관 부산대학교 · 금융감독원 · 한국거래소 · 한국예탁결제원 · 한국은행 · 한국인터넷진흥원 · 한국해양과학기술원

행정 문서 수집 및 색인 구축

수집·선별

PDF, HWP/HWPX, HTML, Office

본문·표 추출 및 문서 분할

품질에 따라 파서·OCR 선택
문서·절·표의 위치 정보 보존

Corpus Gate

문서 조각(청크) 품질·무결성 검사

SQLite FTS5 / 벡터 색인(선택)

RAG(검색 증강 생성) 기반 질문 처리

검색한 문서를 근거로 답변하는 방식

질문 입력

기관: 검색 범위
역할: 우선순위·답변 관점

근거 검색

기본 BM25 / 선택 검색

근거가 모두 제외되면
생성 없이 답변 보류

Context Gate

문서 속 공격 지시 검사
허용 / 정제 / 제외

정제 사본

답변 생성

Gemini / 로컬 LLM

생성 실패 시 원문 추출형 답변

답변 / 부분 답변 / 보류

제외되지 않은 원문

근거·인용 검사용으로 보존

문장별 근거 점검

내용 대조·출처 번호 부여

Output Gate · 인용 검사

부산대 구축 규모 2,260건 선별 / 2,247건 파싱 / 44,520개 검색 청크

Dense: KURE-v1 / Snowflake-ko 임베딩·코사인 유사도
Hybrid: BM25+Dense 순위를 RRF로 통합·어휘·제목·다양성 재정렬
별도 연구비 규정 실험: bge-reranker-v2-m3 재재점·상위 절 문맥 확장


그림 2. 문서 준비와 생성 전후 검사를 포함한 질의 처리 구조.

Context Gate: 규칙 기반 탐지·Unicode 정규화
Output Gate: 출력 구조·출처 ID/번호·인용문 해시(SHA-256)
인용문이 원문에 포함되는지 확인하는 무결성 검사

실험 결과

검색 성능

2026.09.02 · 부산대 개발용 45문항
BM25 검색 · 동일 문서에서 튜닝 전후 비교
정답 문서 검색 적중률(Hit@5, %)



상위 5개에서 정답 문서를 찾은 질문의 비율.
튜닝: 질의·문서 우선순위 보정, 문맥 보강
검색 순위 점수(MRR@5) 0.494 → 0.717

※ 반복 튜닝한 개발용 질문·동일 계열 모델의 자동 평가 결과다. 생성 평가에서 완전 정답률의 유의한 향상은 확인하지 못했다.
※ 보안은 소규모·단일 실험의 표식 관측 시험이다. 전체 서비스의 답변 품질·공격 방어 성능은 독립·사람 평가가 필요하다.

기대효과 및
향후 계획

문장별 출처와 원문을 함께 제공해 행정 정보 확인을 돕는다.
독립 질문셋과 사람 평가로 답변 품질을 검증한다.
공격 유형과 대상 문서를 확대해 보안 성능을 검증한다.

생성 답변 품질

2026.09.04 · 보안 도입 전
45문항·조건별 3회 생성, 답변별 1회 평가
완전 정답 문항과 평균 점수

지표	튜닝 전	튜닝 후
완전 정답 문항*	13/45	20/45
완전 정답 비율	28.9%	44.4%
평균(2점 만점)	0.88	1.21

GFC: 근거에 맞고 필요한 내용을 모두 담은 완전 정답.
*생성 평가는 3회 중 2회 이상 GFC인 문항 집계.

보안 실측

2026.09.09 · 병합 서비스의 보안 적용 전후
공격 변형 10개 · 정상 질문 14개
사례·조건별 1회 실행·자동 평가

조건	표식 출력	정상 GFC
보안 적용 전	1/10	6/14
병합 보안본	0/10	6/14

표식 출력: 공격 요구 문자열이 최종 답변에 등장.
공격은 가상 질문 1개의 변형 10개로 구성했다.
보안본은 공격 1건을 생성 전 보류했다.